

Universidad Nacional Autónoma de México

Instituto de Investigaciones en Matemáticas
Aplicadas y en Sistemas
Licenciatura en Ciencia de Datos

Recuperación híbrida multi-turno en dominios especializados: ablación de fusión, reescritura y reranking con implicaciones para producción

T E S I S

QUE PARA OBTENER EL TÍTULO DE:

Licenciada en Ciencia de Datos

P R E S E N T A :

Vania Janet Raya Rios



TUTORA

Dra. Helena Montserrat Gómez Adorno

Ciudad Universitaria, Cd. Mx., 2026

Jurado asignado:

Presidente:	Dra. Gemma Bel Enguix
Vocal:	Dr. Carlos Ignacio Hernández Castellanos
Secretario:	Dra. Helena Montserrat Gómez Adorno
Suplente:	Dra. Grissel Rodríguez Roldán
Suplente:	Dra. Blanca Hilda Vázquez Gómez

Directora de tesis:



Dra. Helena Montserrat Gómez Adorno

La autora, sin perjuicio de la legislación de la Universidad Nacional Autónoma de México, otorga el permiso para el libre uso, reproducción y distribución de esta obra siempre que sea sin fines de lucro, se den los créditos correspondientes y no sea modificada en ningún aspecto.

D.R. © Vania Janet Raya Rios Ciudad de México, 2026.

Dedico esta tesis a mis padres, Rodrigo y Rosa,
quienes con la honradez de su trabajo y esfuerzo
hicieron posible la conclusión de mis estudios.
Su cariño y confianza forjaron a la profesionista que soy.
Mi gratitud eterna es para ustedes.

A mis hermanos, Sergio Daniel y Areli Viridiana,
por ser mi refugio seguro, cuyo apoyo incondicional y honesto
me ha guiado en mi formación académica y profesional.
Sus consejos son tesoros invaluables.
Le agradezco a Dios por la bendición de caminar por la vida a su lado.

Agradecimientos

Al **Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas (IIMAS)** y a la **Universidad Nacional Autónoma de México**, la máxima casa de estudios, por brindarme una formación de excelencia, por desafiar mi intelecto y por convencerme de que ninguna meta es demasiado grande si se persigue con disciplina.

A la **Dra. Helena Montserrat Gómez Adorno**, por creer en mi potencial cuando apenas iniciaba en este camino. Su guía experta, sus enseñanzas y las oportunidades que me brindó en el ámbito estudiantil transformaron por completo mi visión profesional. Trabajar bajo su dirección ha sido uno de los mayores privilegios de mi formación.

A mis entrañables amigos de **Actuaría** y a toda la **Sexta Generación de Ciencia de Datos**. Gracias por el crecimiento compartido en cada etapa de la carrera y, sobre todo, por regalarme una sonrisa sincera y un abrazo fuerte incluso en los momentos más difíciles. Se llevan una parte fundamental de este logro.

Ciudad Universitaria, IIMAS, 2026

Índice general

Agradecimientos iv

Resumen xiv

Summary xvii

1. Introducción 1

1.1. Contexto y motivación 1
1.2. Planteamiento del problema 4
1.3. Preguntas de investigación 7
1.4. Hipótesis 7
1.5. Objetivos de la investigación 9
1.5.1. Objetivo general 9
1.5.2. Objetivos específicos 9
1.6. Delimitación del estudio 10

2. Marco Teórico 11

2.1. Arquitecturas de recuperación de información 11
2.1.1. Recuperación léxica: BM25 11
2.1.2. Recuperación densa: bi-encoders 13
2.1.3. Recuperación sparse aprendida: SPLADE 14
2.2. Métodos de fusión 16
2.2.1. Reciprocal Rank Fusion (RRF) 17

2.2.2. Interpolación lineal de puntajes 18
2.3. Reescritura de consultas en diálogos multi-turno 19
2.3.1. Correferencia y elipsis en contextos conversacionales . . . 19
2.3.2. Enfoques de reescritura 20
2.4. Reranking neuronal con cross-encoders 21
2.4.1. Arquitectura cross-encoder 21
2.4.2. Reranking como etapa de refinamiento 22
2.4.3. Modelos de reranking evaluados 22
2.5. Arquitectura de generación aumentada por recuperación (RAG) . . 22
2.6. Fundamentos de evaluación y significancia en IR 23
2.6.1. Métricas de evaluación basadas en rankings 24
2.6.2. Pruebas de significancia estadística 25

3. Estado del Arte **27**
3.1. Recuperación y fusión híbrida 27
3.1.1. Evidencia reciente sobre fusión híbrida 27
3.1.2. Sensibilidad de RRF y alternativas de fusión 28
3.1.3. Fusión híbrida con *learned sparse* y BEIR 29
3.2. Reescritura de consultas conversacionales 30
3.2.1. De la reescritura supervisada al *prompting* con LLMs . . . 30
3.2.2. El problema del *context drift* 31
3.3. Reranking sobre *pipelines* híbridos 32
3.3.1. El giro hacia el *reranking* con LLMs 32
3.3.2. Interacción entre *reranking* y recuperación híbrida 32
3.4. *Benchmarks* multi-turno y dominios especializados 33
3.5. Brechas abiertas: sensibilidad, interacción entre componentes y *trade-offs* de producción 34
3.5.1. Brecha 1: ausencia de estudios de ablación sistemáticos en *pipelines* híbridos multi-turno 35
3.5.2. Brecha 2: escasa evidencia sobre sensibilidad de hiperparámetros en dominios especializados 35

3.5.3. Brecha 3: evaluación insuficiente de la reescritura como variable independiente 35
3.5.4. Brecha 4: ausencia de análisis de compromisos calidad-latencia-costo 36
3.6. Síntesis del estado del arte 36

4. Descripción de los Datos **38**
4.1. *Benchmark* MTRAG: características generales 38
4.1.1. Justificación de la selección 38
4.1.2. Escala y composición del *benchmark* 39
4.1.3. Estructura de una conversación 39
4.1.4. Modos de consulta disponibles 40
4.2. Dominios especializados 40
4.2.1. ClapNQ: preguntas de conocimiento general 41
4.2.2. Cloud: documentación técnica de IBM 41
4.2.3. FiQA: finanzas y regulación 42
4.2.4. Govt: documentos gubernamentales 42
4.3. Formato BEIR y estructura de archivos 42
4.4. Preprocesamiento e indexación del corpus 43
4.4.1. Segmentación en pasajes (realizada por el *benchmark*) . . 43
4.4.2. Filtrado y limpieza de texto 44
4.4.3. Construcción de índices 44
4.5. Criterios de inclusión y juicios de relevancia 46
4.5.1. Esquema de anotación 46
4.5.2. Distribución de los juicios de relevancia 46

5. Metodología **48**
5.1. Diseño experimental de ablación controlada (OFAT) 48
5.2. Definición de variables 49
5.2.1. Variables independientes y niveles experimentales 49
5.2.2. Variables dependientes (métricas de evaluación) 50

5.2.3. Variables de control 51
5.3. Arquitectura del *pipeline* de recuperación 52
5.3.1. Preprocesamiento de consultas 53
5.3.2. Módulos de recuperación 53
5.3.3. Fusión de resultados 54
5.3.4. Reescritura de consultas 54
5.3.5. *Reranking* 55
5.4. Protocolo experimental: estudios de ablación 56
5.4.1. Tabla maestra de ablaciones 56
5.4.2. Matriz de cobertura del espacio experimental 57
5.4.3. Protocolo de comparaciones pareadas 58
5.5. Infraestructura, instrumentos y herramientas computacionales . . 59
5.6. Análisis estadístico 60
5.6.1. Pruebas de hipótesis y corrección de comparaciones múltiples 60
5.6.2. Tamaño del efecto e intervalos de confianza 61
5.6.3. Concordancia inter-dominio 61
5.6.4. Frontera de Pareto 61
5.7. Aspectos éticos y privacidad 62

6. Evaluación y Resultados **63**
6.1. EA1: Comparación de modelos de recuperación 63
6.1.1. Resultados principales 64
6.1.2. Significancia estadística 65
6.2. EA2: Operadores de fusión 67
6.3. Impacto de las estrategias de consulta y reescritura 68
6.3.1. EA3: Modos de consulta 68
6.3.2. EA4: Variantes de reescritura automática 69
6.4. Sensibilidad de hiperparámetros 71
6.4.1. EA5: Parámetro k de RRF 71
6.4.2. EA6: Profundidad de recuperación 71
6.5. EA7: Evaluación del *reranking* 72

6.6. Consistencia inter-dominio 74
6.7. Frontera de Pareto: calidad–latencia–costo 75
6.8. Análisis cualitativo de errores 77
6.8.1. Distribución de tipos de error 78
6.8.2. Degradación por profundidad de turno 78
6.8.3. Ejemplo de error 79
6.9. Resumen de hallazgos estadísticos 79
6.10. Posicionamiento en el *benchmark* oficial MTRAGEval 81

7. Discusión **82**
7.1. Interpretación de los resultados 82
7.1.1. La lógica de la fusión híbrida 83
7.1.2. El efecto del historial completo 83
7.1.3. La sensibilidad de RRF y la profundidad de recuperación . 83
7.1.4. La paradoja del *reranking* 84
7.2. Contraste con la literatura previa 84
7.2.1. Fusión híbrida: complementariedad confirmada 84
7.2.2. Reescritura: consistencia con la literatura y un resultado inesperado 85
7.2.3. *Reranking*: divergencia con las expectativas del estado del arte 85
7.2.4. Sensibilidad de hiperparámetros 86
7.3. Implicaciones prácticas y teóricas 86
7.3.1. Implicaciones para el despliegue en producción 86
7.4. Limitaciones del estudio 87
7.5. Líneas futuras de investigación 87

8. Conclusiones y Trabajo Futuro **88**
8.1. Síntesis de los hallazgos 88
8.2. Respuesta a las preguntas de investigación 89
8.3. Contribuciones 90

8.4. Limitaciones y trabajo futuro 91

A. Muestras de datos y ejemplos cualitativos **92**
A.1. Estructura de una conversación multi-turno 92
A.2. Comparación de métodos de reescritura 93
A.3. Casos de éxito y fallo en la recuperación 93
A.3.1. Caso 1: Recuperación exitosa (CLAPNQ, `dd6b6ffd`, turno 4) 95
A.3.2. Caso 2: Éxito parcial con correferencia (FIQA) 96
A.3.3. Caso 3: Fallo por dependencia de contexto a larga distancia (CLOUD) 97

B. Prompts completos para reescritura de consultas **98**

C. Detalles de implementación **101**

D. Tablas de resultados extendidas **103**

Índice de figuras

1.1. Búsqueda tradicional frente a búsqueda conversacional 3
1.2. Ejemplo de falla por correferencia no resuelta 5

2.1. Arquitectura IIMAS-RAG de extremo a extremo 23

5.1. Arquitectura del pipeline de recuperación 52
5.2. Mapa de calor de cobertura experimental 58

6.1. Panel de impacto por ablación 73
6.2. Frontera de Pareto calidad–latencia–costo 76
6.3. Tablero integrado de producción y errores 77

Índice de tablas

2.1. Comparación de los tres paradigmas de recuperación de información evaluados en este trabajo. 16
2.2. Comparación de los operadores de fusión evaluados en este trabajo. 19
2.3. Comparación de las métricas de evaluación empleadas en este trabajo. 25

3.1. Comparación de *benchmarks* para búsqueda conversacional 34
3.2. Síntesis del estado del arte en recuperación conversacional 37

4.1. Estadísticas de los cuatro dominios de MTRAG 41
4.2. Estructura de archivos BEIR por dominio 43
4.3. Tamaño de los índices por dominio y modelo 45
4.4. Distribución de juicios de relevancia por dominio 47

5.1. Variables independientes y sus niveles 50
5.2. Modelos de recuperación evaluados 53
5.3. Modelos de reescritura evaluados 55
5.4. Modelos de *reranking* evaluados 56
5.5. Tabla maestra de ablaciones 57
5.6. Infraestructura computacional 59
5.7. Costos de servicios API 60

6.1. EA1: nDCG@10 por dominio 64
6.2. EA1: pruebas estadísticas 66

6.3. EA1: S+V vs. SPLADE — prueba pareada directa 67
6.4. EA2: operadores de fusión 68
6.5. EA3: modos de consulta 69
6.6. EA4: variantes de reescritura 70
6.7. EA5: sensibilidad de k en RRF 71
6.8. EA7: *reranking* 72
6.9. τ de Kendall inter-dominio 74
6.10. Configuraciones Pareto-óptimas 75
6.11. Perfiles de producción 76
6.12. Distribución de tipos de error 78
6.13. Rendimiento por profundidad de turno 79
6.14. Resumen estadístico por estudio 80
6.15. Posicionamiento en MTRAGEval Tarea A 81

A.1. Ejemplo de conversación multi-turno del dominio ClapNQ (ID: `dd6b6ffd`). 93
A.2. Ejemplos de reescritura por dominio y fenómeno ilustrado (EA4). 94

C.1. Dependencias principales del proyecto (Python 3.11, CUDA 12.1). 102

D.1. Pruebas pareadas para EA1_baselines 104
D.2. Consistencia inter-dominio (τ de Kendall) — EA1_baselines . . . 105
D.3. Pruebas pareadas para EA2_fusion 105
D.4. Pruebas pareadas para EA3_query_mode 106
D.5. Pruebas pareadas para EA4_rewrite 107
D.6. Frontera de Pareto calidad–latencia–costo (tabla completa) 108

Recuperación híbrida multi-turno en dominios especializados: ablación de fusión, reescritura y reranking con implicaciones para producción

Vania Janet Raya Rios
Licenciatura en Ciencia de Datos
Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas
Universidad Nacional Autónoma de México

Resumen

Los sistemas de recuperación de información basados en *Retrieval-Augmented Generation* (RAG) enfrentan un gran reto en el contexto conversacional multi-turno: las consultas del usuario suelen estar incompletas, con anáforas y ligadas al contexto del historial conversacional. Esta tesis presenta un estudio de ablación sistemático sobre un sistema de recuperación híbrida multi-turno. La evaluación se realiza sobre el benchmark MT-RAG en el marco de SemEval-2026 Task A, ACL, el cual está comprendido por 777 consultas con anotaciones de relevancia (de un total de 842 turnos; los 65 restantes carecen de anotación y fueron excluidos de la evaluación de recuperación) distribuidas en cuatro dominios especializados (ClapNQ, Cloud, FiQA y Govt).

Mediante siete estudios de ablación y 168 experimentos controlados se analizan los cuatro componentes principales del *pipeline*: la elección del recuperador de primera etapa, el operador de fusión, la estrategia de formulación de la consulta y el *reranking*. Los resultados muestran que la fusión híbrida SPLADE + Voyage supera consistentemente a los recuperadores individuales (nDCG@10: 0.497 frente a 0.457 de SPLADE solo), confirmando que las señales léxicas aprendidas y densas son complementarias en el escenario conversacional. El operador RRF con $k = 60$ supera a la interpolación lineal y además resulta insensible a variaciones en los

valores $[20, 40, 60, 100]$, lo que valida la elección de escoger 60, muy común entre la literatura que se examinó.

La estrategia de formulación de la consulta es el factor de mayor impacto en el *pipeline*. La concatenación del historial conversacional completo produce una degradación de hasta -0.184 puntos de nDCG@10 respecto al último turno, mientras que la reescritura automática con Command-R (réplica) supera incluso a la reescritura de referencia de los organizadores (0.519 frente a 0.497 de media), siendo estadísticamente significativa en ClapNQ. El modelo local Flan-T5 resulta significativamente inferior en los cuatro dominios.

En contraste, el *reranking* con modelos de tipo *cross-encoder* (BGE-rr-v2 local y Cohere Rerank v3.5) no produce mejoras estadísticamente significativas sobre el *pipeline* híbrido en ninguna configuración evaluada. Asimismo, otro estudio demostró que la profundidad de recuperación a partir de top-100 no aporta ganancia, lo que permite reducir el costo computacional sin pérdida de calidad.

El análisis de errores sobre 12 432 pares sistema-consulta reveló que el 23.9 % corresponde a errores de *ranking* (documento relevante en el *pool* pero fuera del top-5), frente al 11.2 % de errores de cobertura, por lo que la prioridad a futuro es experimentar en el ordenamiento de candidatos y no necesariamente con la ampliación del *pool*. Además, la tasa de fallo se duplica entre el primer turno (17.6 %) y el turno 4 en adelante (40.6 %), evidenciando que la ambigüedad aumenta en consultas tardías.

La frontera de Pareto identifica el Híbrido S+V como la configuración de mayor calidad con costo de API de \$0.12/1K consultas (solo VoyageAI; SPLADE se ejecuta localmente sin costo de API), y Command-R + S+V como la de máxima calidad global.

Los resultados tienen implicaciones directas para el despliegue en producción: es preferible invertir en un recuperador híbrido de alta calidad antes que añadir un *reranker*; la concatenación del historial debe evitarse y es preferible invertir en un sistema de reescritura cuando se necesita de mayor calidad (a cambio de mayor latencia y costo); y el parámetro k de RRF no requiere optimización. La

consistencia inter-dominio de los hallazgos principales (coeficiente τ de Kendall ≥ 0.796 en los estudios de mayor efecto) sugiere que estas recomendaciones son transferibles a nuevos dominios especializados.

Palabras clave: recuperación de información conversacional, recuperación híbrida, fusión de rangos recíprocos, reescritura de consultas, *reranking*, sistemas RAG, dominios especializados, ablación.

Hybrid Multi-Turn Retrieval in Specialized Domains: Ablation of Fusion, Query Rewriting, and Reranking with Implications for Production

Vania Janet Raya Rios
Bachelor's Programme in Data Science
Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas
Universidad Nacional Autónoma de México

Summary

Retrieval-Augmented Generation (RAG) systems face a distinctive challenge in conversational settings: user queries are often incomplete, contain anaphora, and are closely linked to the conversation history. This thesis presents a systematic ablation study of a hybrid multi-turn retrieval pipeline, evaluated on the MT-RAG benchmark from SemEval-2026 Task A, comprising 777 queries with relevance annotations (out of 842 total turns; the remaining 65 lack qrels and were excluded from retrieval evaluation) across four specialized domains (ClapNQ, Cloud, FiQA, and Govt).

Seven ablation studies and 168 controlled experiments analyze the four main pipeline components: the first-stage retriever, the fusion operator, the query formulation strategy, and reranking. Results show that hybrid SPLADE + Voyage fusion consistently outperforms individual retrievers (nDCG@10: 0.497 vs. 0.457 for SPLADE alone), confirming the complementarity of learned sparse and dense signals in the conversational setting. RRF with $k = 60$ outperforms linear interpolation and is furthermore insensitive to variations of k across the values $[20, 40, 60, 100]$, validating the choice of the canonical value of 60.

Query formulation is the highest-impact pipeline factor. Concatenating the full conversation history causes a severe drop of up to -0.184 nDCG@10 points relative

to the last turn alone, whereas automatic rewriting with Command-R (replica mode) surpasses even the organizers' reference rewrites (mean 0.519 vs. 0.497), achieving statistical significance in the ClapNQ domain. The local Flan-T5 model is significantly inferior across all four domains.

In contrast, cross-encoder reranking with local BGE-rr-v2 and Cohere Rerank v3.5 produces no statistically significant improvements over the hybrid pipeline in any evaluated configuration. Likewise, retrieval depth beyond top-100 provides no relevant gain, allowing for computational cost reduction without quality loss.

Error analysis over 12 432 system-query pairs revealed that 23.9 % correspond to ranking errors (relevant document in the pool but outside top-5), versus 11.2 % coverage errors, indicating that future improvement should focus on candidate ordering rather than pool expansion. The failure rate doubles from turn 1 (17.6 %) to turn 4+ (40.6 %), evidencing the increasing ambiguity of late-turn queries. The Pareto frontier identifies Hybrid S+V as the highest-quality configuration with an API cost of $0.12/1K queries (VoyageAI only; SPLADE runs locally at no API cost), and Command-R + S+V as the highest-quality configuration overall.

Findings have direct production implications: it is preferable to invest in a high-quality hybrid first stage rather than adding a reranker; history concatenation should be avoided, and investing in a rewriting system is preferred when higher quality is needed (trading off latency and cost); and the RRF parameter k requires no optimization. Cross-domain consistency of the main findings (Kendall coefficient $\tau \geq 0.796$ in the highest-effect studies) suggests that these recommendations are transferable to new specialized domains.

Keywords: conversational information retrieval, hybrid retrieval, reciprocal rank fusion, query rewriting, reranking, RAG systems, specialized domains, ablation study.

Capítulo 1

Introducción

Desde hace décadas, la recuperación de información (RI) desempeña un papel fundamental en la interacción entre los usuarios y los sistemas digitales. Un referente histórico fue Microsoft Encarta [Ling et al., 2002], tecnología que en los años 90 democratizó el acceso al conocimiento mediante contenidos multimedia. Aunque su motor de búsqueda era eficiente para la época, operaba bajo una lógica rígida de coincidencias exactas. No obstante, esta enciclopedia fue pionera en integrar los principios de los modelos basados en espacios vectoriales propuestos por Salton et al. [1975]. A partir de este marco histórico, los siguientes apartados detallan el contexto de la investigación, el problema central, así como las preguntas, hipótesis y objetivos que estructuran este estudio.

1.1. Contexto y motivación

Durante décadas, el paradigma dominante fue la búsqueda por palabras clave: el usuario formulaba una consulta breve, el sistema la comparaba con un índice invertido (un diccionario con parejas de palabras y los artículos que las contienen) y devolvía una lista ordenada de documentos. Este esquema presentaba múltiples problemas. El mayor de ellos era el *vocabulary mismatch*. Por ejemplo, si el usuario busca ”auto” y el documento dice ”vehículo” o ”coche”, el sistema no lo

encontrará. Modelos probabilísticos como BM25 (*Best Matching 25*) [Robertson and Zaragoza, 2009] perfeccionaron este enfoque mediante: 1. la saturación de la frecuencia de términos, evitando que un artículo gane debido a que contiene muchas repeticiones de la palabra buscada, y 2. la normalización por longitud del documento, penalizando a los artículos que son demasiado largos y premiando a los cortos cuando ambos tienen la misma palabra clave.

La llegada de los grandes modelos de lenguaje (*Large Language Models*, LLMs) como GPT (*Generative Pre-trained Transformer*) [OpenAI, 2025], transformó las expectativas de los usuarios. Estos sistemas demostraron que era posible mantener conversaciones coherentes a lo largo de múltiples turnos (pregunta-respuesta). La búsqueda de información pasó de escribir palabras clave a un diálogo progresivo en el que cada pregunta refina, amplía o redirige la conversación. La Figura 1.1 ilustra esta diferencia.

Ahora bien, los LLMs por sí solos no son infalibles: tienden a generar información falsa con apariencia verosímil (fenómeno mejor conocido como *alucinación*), no actualizan su conocimiento tras el entrenamiento (salvo que usen herramientas como búsqueda web, archivos o bases de datos) y carecen de mecanismos para citar fuentes verificables [OpenAI, 2024]. En aplicaciones especializadas se ve un impacto negativo muy notorio. Por ejemplo, en medicina, finanzas o derecho una respuesta inventada con confianza es peor que ninguna respuesta. Se pueden evitar diagnósticos falsos, inversiones arriesgadas o el uso de jurisprudencia falsa que comprometa una estrategia legal. Para aminorar estas limitaciones, Lewis et al. [2020] propusieron el paradigma de *generación aumentada por recuperación* (*Retrieval-Augmented Generation*, RAG). Este se divide en 3 componentes: la recuperación, la generación y la unión de estos dos módulos que finalmente genera una respuesta fundamentada en fragmentos relevantes de una base de conocimiento externa. De esta manera, el sistema reduce las alucinaciones y mantiene el conocimiento actualizado sin necesidad de reentrenar el modelo completo.

En la actualidad existen otros métodos como el *fine-tuning*, herramientas propias

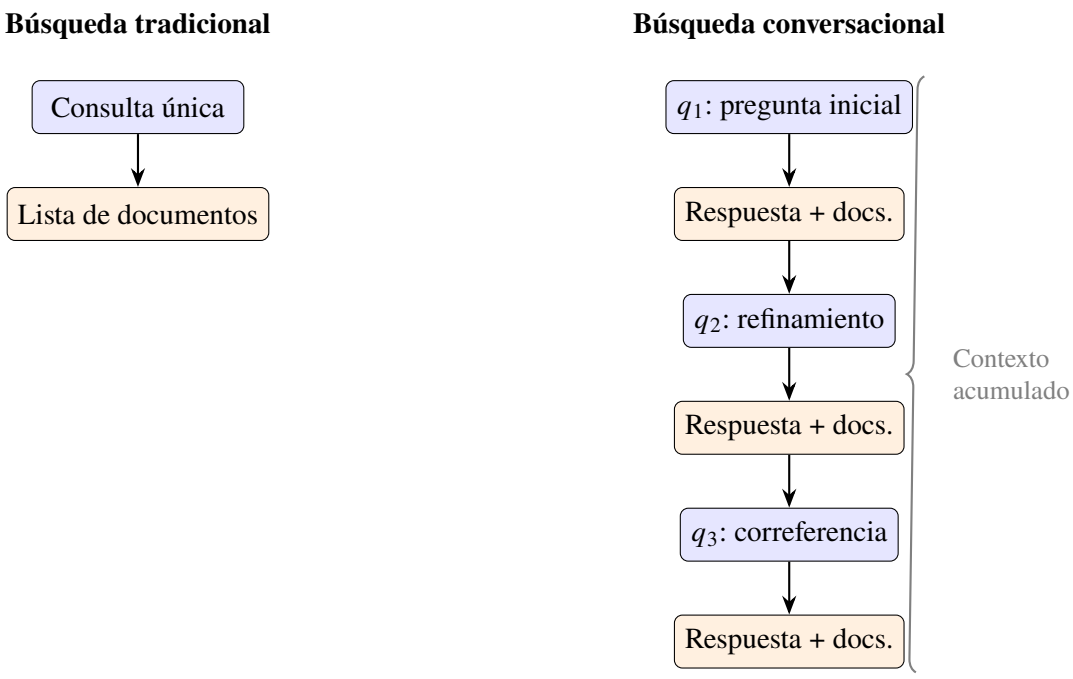


Figura 1.1: Comparación entre la búsqueda tradicional de un solo turno y la búsqueda conversacional multi-turno. En el esquema conversacional, cada consulta q_t se formula en el contexto del historial previo, lo que introduce fenómenos de correferencia y elipsis que deben resolverse para recuperar documentos relevantes y continuar con una conversación coherente.

de agentes (*web search*) y el aumento en la ventana de contexto. Sin embargo, el primero implica un costo computacional y requiere de reentrenamiento para mantenerse al día. El segundo depende de la disponibilidad de internet y la calidad de los sitios web investigados. Por último, ampliar la ventana de contexto resulta costoso y ralentiza el procesamiento. Debido a esto, la arquitectura RAG no tardó en convertirse en la norma para aplicaciones intensivas en conocimiento [Gao et al., 2024]. Aún así, tiene ciertas limitaciones. Si el módulo de recuperación entrega documentos irrelevantes o erróneos, el LLM generará una respuesta equivocada basándose en esa información [Lewis et al., 2020]. Este fenómeno se vuelve incluso más problemático en escenarios conversacionales multi-turno, donde la consulta del usuario en turnos avanzados depende, cada vez más, del contexto acumulado

en turnos previos. Esto ha sido documentado en TREC CAsT [Dalton et al., 2019] y MTRAG [Katsis et al., 2025].

Por ese motivo, esta investigación aborda el problema de mejorar la etapa de recuperación en un sistema RAG multi-turno; la estrategia es un análisis de ablación controlado que aísla la contribución de cada componente del *pipeline*: la fusión híbrida de señales léxicas y semánticas, la reescritura de consultas dependientes del contexto y el reordenamiento neuronal de candidatos.

1.2. Planteamiento del problema

El problema central de un sistema RAG conversacional multi-turno es que la consulta del usuario en el turno t no es autocontenida. En la búsqueda *ad hoc* tradicional, cada consulta puede leerse de forma independiente; en el diálogo, las preguntas contienen pronombres sin referente explícito (*correferencia*), entidades mencionadas en turnos anteriores que se omiten por economía discursiva (*elipsis*) y cambios graduales de tema que solo cobran sentido en el contexto de la secuencia completa [Lin et al., 2021]. Estos fenómenos lingüísticos son completamente naturales en la comunicación humana; para los modelos de recuperación que procesan cada consulta de forma aislada, son indescifrables.

Para ilustrar la magnitud del problema, veamos el siguiente ejemplo de la Figura 1.2. Es una conversación sobre política fiscal en la que el usuario formula tres preguntas sucesivas. La tercera pregunta, "¿Cuándo se reformó por última vez?", contiene un pronombre implícito que se refiere a la "ley del impuesto sobre la renta" mencionada dos turnos antes. Un sistema de recuperación que procese únicamente el texto del turno actual intentará buscar documentos sobre "reformas" sin saber *qué* se reformó, lo que produce resultados irrelevantes.

Turno 1 (usuario): ¿Qué establece la ley del impuesto sobre la renta en México respecto a deducciones personales?

Turno 1 (sistema): La ley establece que las personas físicas pueden deducir gastos médicos, colegiaturas y donativos... [Doc. relevante recuperado correctamente]

Turno 2 (usuario): ¿Cuáles son los límites máximos de esas deducciones?

Turno 2 (sistema): El límite anual es de 5 UMA elevadas al año o el 15 % de los ingresos totales... [Doc. relevante recuperado correctamente]

Turno 3 (usuario): ¿Cuándo se reformó por última vez?

Turno 3 (sistema sin reescritura): Consulta enviada al motor: "¿Cuándo se reformó por última vez?"
→ Documentos recuperados sobre reformas educativas, reformas energéticas...
[Falla: el sistema no resuelve que "se reformó" refiere a la ley del ISR]

Figura 1.2: Ejemplo de una conversación en la que la correferencia no resuelta provoca una falla de recuperación. La consulta del turno 3, leída sin contexto, carece del referente necesario para identificar los documentos relevantes. Un módulo de reescritura transformaría la consulta en: "¿Cuándo se reformó por última vez la **ley del impuesto sobre la renta en México**?", resolviendo la ambigüedad.

Este ejemplo ilustra tres situaciones que se acumulan sobre cualquier sistema RAG en escenarios conversacionales reales.

La primera es la **dependencia contextual**: las consultas en turnos avanzados son semánticamente incompletas si se leen sin el historial de la conversación [Elgohary et al., 2019]. De hecho, en MTRAG, aproximadamente el 60 % de las preguntas a partir del cuarto turno contienen correferencia o elipsis [Katsis et al., 2025].

La segunda son los **modelos de recuperación individuales**, ya que, ninguno

cubre la complejidad del problema por sí solo. Los modelos léxicos como BM25 [Robertson and Zaragoza, 2009] capturan coincidencias exactas pero ignoran sinónimos, mientras que los modelos densos como DPR [Karpukhin et al., 2020] capturan similitud semántica pero pierden precisión en vocabulario técnico exacto. Además, BEIR documenta caídas de hasta 15 puntos de nDCG@10 cuando los modelos densos se evalúan fuera de su dominio de entrenamiento [Thakur et al., 2021]. Cada paradigma tiene su punto ciego, pero un sistema híbrido obtiene lo mejor de ambos mundos.

La tercera es la **complejidad del *pipeline* de recuperación**. Un sistema RAG conversacional completo integra reescritura de consultas, recuperación con varios modelos, fusión de resultados y reordenamiento neuronal: cuatro etapas, cada una con sus propios hiperparámetros. La interacción entre estas etapas genera un espacio de configuración enorme, y un error en cualquiera de ellas puede anular las ganancias de los componentes anteriores [Katsis et al., 2025].

Para hacer frente a estos problemas, la comunidad ha desarrollado técnicas específicas para cada etapa: fusión híbrida RRF [Cormack et al., 2009], reescritura de consultas [Elgohary et al., 2019] y reranking con cross-encoders [Nogueira and Cho, 2019]. Sin embargo, desarrollar técnicas no equivale a entender su interacción. La investigación científica sobre la **contribución individual** de cada componente en conversaciones multi-turno y más aún, en dominios especializados, sigue estando en desarrollo [Cheng et al., 2025, Katsis et al., 2025]. Estudios recientes de ablación se limitan a dominios médicos *single-turn* [Emekci and Roxas, 2026] o a datasets generales sin interdependencia contextual [Alushi et al., 2026]. Asimismo, faltan estudios de **sensibilidad de hiperparámetros** y de **compromisos calidad-latencia-costo** [Shen et al., 2024] que permitan derivar recomendaciones prácticas de configuración.

1.3. Preguntas de investigación

La brecha señalada en la sección anterior da lugar a la siguiente pregunta central:

> *¿En qué medida la fusión híbrida, la reescritura de consultas y el reranking mejoran la recuperación en diálogos multi-turno, y cuál es la sensibilidad del rendimiento ante los hiperparámetros de cada componente?*

De ella se desprenden seis preguntas específicas, cada una orientada a un aspecto distinto del *pipeline*:

PI1. ¿Cuál es la ganancia en nDCG@10 de la fusión híbrida *sparse-dense* frente al mejor modelo de recuperación individual en cada uno de los cuatro dominios del *benchmark* MTRAG?

PI2. ¿La reescritura de consultas produce una mejora significativa frente al último turno de la conversación?

PI3. ¿Cuál es el impacto de la variación del hiperparámetro k de RRF en el rendimiento del ranking final?

PI4. ¿Cómo afecta la profundidad del *reranking* al rendimiento de la recuperación?

PI5. ¿Qué configuraciones del *pipeline* ofrecen el mejor compromiso entre calidad de recuperación, latencia y costo para un despliegue en producción?

PI6. ¿Las configuraciones óptimas de la etapa de recuperación son consistentes entre los cuatro dominios temáticos del corpus?

1.4. Hipótesis

Apoyadas en las preguntas anteriores y en la evidencia reportada en la literatura, las hipótesis de trabajo son las siguientes:

H1. La fusión híbrida *sparse-dense* mediante RRF supera al mejor modelo de recuperación individual en la mayoría de los dominios evaluados, en términos de nDCG@10.

H2. La reescritura de consultas produce una mejora estadísticamente significativa en nDCG@10 respecto al uso del último turno como consulta.

H3. La elección del hiperparámetro k de RRF afecta el rendimiento de la recuperación en nDCG@10.

La cuarta hipótesis comprende dos vertientes complementarias:

H4a. El incremento marginal en nDCG@10 disminuye conforme aumenta la profundidad del *reranking* (de 50 a 200 candidatos). Esto se le puede atribuir al incremento en la probabilidad de recuperar falsos positivos (documentos que comparten muchas palabras pero no son la respuesta).

H4b. El *reranking* puede degradar el rendimiento (nDCG@10) cuando se aplica sobre configuraciones de recuperación híbrida que ya presentan una alta efectividad. Debido a que el modelo de reordenamiento puede introducir un sesgo de dominio general por los datos vistos durante su entrenamiento.

Debido a que las métricas de recuperación de información no suelen seguir una distribución normal, las hipótesis H1, H2 y H3 se evalúan mediante comparaciones pareadas con la prueba de rangos con signo de Wilcoxon [Wilcoxon, 1945], aplicando la corrección de Holm-Bonferroni [Holm, 1979] para controlar la tasa de error familiar en comparaciones múltiples, siguiendo las recomendaciones de Benavoli et al. [2016] sobre la fragilidad de las pruebas basadas en rangos promedio como el test de Nemenyi. La magnitud de las diferencias se cuantifica con el estadístico δ de Cliff [Cliff, 1993], que opera sobre rangos ordinales y resulta compatible con pruebas no paramétricas. Finalmente, la consistencia de los resultados a través de los diversos dominios temáticos se analiza mediante el coeficiente τ de Kendall [Kendall, 1938].

1.5. Objetivos de la investigación

1.5.1. Objetivo general

Evaluar el impacto de la fusión híbrida, la reescritura de consultas y el *reranking* en la calidad de la recuperación en diálogos multi-turno sobre cuatro dominios especializados del *benchmark* MTRAG, y determinar la sensibilidad del rendimiento ante la variación de los hiperparámetros, mediante un análisis de ablación controlado y pruebas de significancia estadística.

1.5.2. Objetivos específicos

Para alcanzar el objetivo general, se establecen los siguientes objetivos específicos:

OE1. Comparar el desempeño de las estrategias de fusión híbrida (combinando señales *sparse* y *dense*) frente a cinco modelos individuales (BM25, SPLADE, BGE-1.5, Voyage-3-large y BGE-M3), contrastando la efectividad del operador RRF frente a la interpolación lineal, mediante pruebas de Wilcoxon con corrección de Holm-Bonferroni (vinculado a **H1**).

OE2. Evaluar el impacto de las estrategias de consulta (último turno, historial completo y reescritura) sobre una configuración híbrida fija (**H2**).

OE3. Evaluar la sensibilidad del *pipeline* ante variaciones de hiperparámetros: el parámetro k de RRF (**H3**).

OE4. Evaluar el rendimiento de los modelos de *reranking* (BGE-Reranker-v2-m3 y Cohere Rerank v3.5) a profundidades de $\{50, 100, 200\}$ candidatos (**H4a** y **H4b**).

OE5. Evaluar la consistencia de los rankings de configuraciones entre los cuatro dominios mediante el coeficiente τ de Kendall, y contrastar mediante Wilcoxon pareado si la configuración óptima del dominio A se mantiene superior contra el dominio B (**PI6**).

OE6. Construir la frontera de Pareto calidad-latencia-costo y derivar

recomendaciones prácticas de configuración para despliegue en producción. (**PI5**).

1.6. Delimitación del estudio

El estudio está acotado exclusivamente a la etapa de **recuperación de pasajes** (*retrieval*) del *pipeline* RAG, sin abarcar la fase de generación de respuesta final. El análisis se realiza sobre el *benchmark* MTRAG en sus cuatro dominios (ClapNQ, Cloud, FiQA y Govt), evaluando el rendimiento de cinco modelos de recuperación, dos operadores de fusión y cuatro modos de consulta. Asimismo, se consideran variantes de reescritura de consultas y dos modelos de *reranking*. Para aislar el impacto de cada componente, se emplea un diseño de ablación bajo el esquema *One Factor at a Time* (OFAT) [Bosch, 2010, Lammers and Badia, 2004], que manipula una variable a la vez manteniendo fijas las demás. Este enfoque garantiza la interpretabilidad directa de los resultados y la viabilidad computacional frente a la explosión de combinaciones en un diseño factorial completo.

Capítulo 2

Marco Teórico

Los fundamentos sobre los que se apoya la presente investigación se detallan en este capítulo. Examinaremos tres paradigmas de recuperación de información y las técnicas de reescritura y reordenamiento que completan el *pipeline*.

2.1. Arquitecturas de recuperación de información

La tarea de recuperación de información (*Information Retrieval*, IR) puede plantearse así: dada una consulta q y una colección $\mathcal{D} = \{d_1, d_2, \ldots, d_N\}$, producir una lista de documentos ordenada por relevancia estimada. Los modelos que realizan esta tarea se clasifican en tres paradigmas según la naturaleza de la representación que emplean: léxico (basado en coincidencia exacta de términos), denso (basado en *embeddings* continuos en un espacio latente) y *sparse* aprendido (representaciones dispersas generadas por un modelo neuronal). A continuación explicaremos cada uno de ellos.

2.1.1. Recuperación léxica: BM25

BM25 [Robertson and Zaragoza, 2009] es el algoritmo de recuperación léxica más utilizado en la práctica; aparece como línea base en casi todos los *benchmarks*

del área [Thakur et al., 2021]. Su objetivo es estimar la relevancia de un documento d respecto a una consulta q utilizando exclusivamente la coincidencia exacta de los términos compartidos.

BM25 extiende el clásico modelo TF-IDF con dos correcciones: la *saturación de la frecuencia de término* y la *normalización por longitud de documento*.

Formalmente, dado un documento d y una consulta q compuesta por los términos $\{q_1, q_2, \ldots, q_m\}$, el puntaje BM25 se define como:

$$\text{BM25}(q, d) = \sum_{i=1}^{m} \text{IDF}(q_i) \cdot \frac{f(q_i, d) \cdot (k_1 + 1)}{f(q_i, d) + k_1 \cdot \left(1 - b + b \cdot \dfrac{|d|}{\text{avgdl}}\right)} \tag{2.1}$$

donde $f(q_i, d)$ es la frecuencia del término q_i en el documento d, $|d|$ es la longitud del documento medida en número de términos, avgdl es la longitud promedio de los documentos en la colección, y k_1 y b son hiperparámetros. El componente de frecuencia inversa de documento se calcula como:

$$\text{IDF}(q_i) = \log \frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} \tag{2.2}$$

donde N es el número total de documentos en la colección y $n(q_i)$ es el número de documentos que contienen el término q_i.

El hiperparámetro $k_1 \in [1.2, 2.0]$ controla la **saturación de la frecuencia de término**; $b \in [0, 1]$ controla la **normalización por longitud de documento** ($b = 0$: sin normalización; $b = 1$: completa).

Ventajas y utilidad práctica. BM25 opera sobre un índice invertido, lo que permite búsquedas en tiempo sublineal, muy rápidas, sin requerir entrenamiento previo. Se mantiene competitivo en dominios con vocabulario técnico especializado, donde la coincidencia léxica exacta aporta una señal fuerte [Thakur et al., 2021].

Esa dependencia de la coincidencia exacta es también su principal límite: BM25 no captura relaciones semánticas. Un documento que usa “automóvil” no será

recuperado por una consulta con "coche", aunque ambos términos se refieran al mismo concepto. Además, el modelo carece de mecanismos para capturar el orden de las palabras o las dependencias sintácticas: las consultas "perro muerde hombre" y "hombre muerde perro" producen el mismo puntaje. Estas limitaciones motivaron el desarrollo de los modelos de recuperación densa, que se describen a continuación.

2.1.2. Recuperación densa: bi-encoders

Los modelos densos atacan directamente la limitación semántica de BM25: proyectan consultas y documentos en un *espacio latente* continuo donde la proximidad geométrica refleja similitud semántica [Karpukhin et al., 2020]. En este espacio, dos textos que expresan la misma idea con palabras diferentes (por ejemplo, "enfermedad cardíaca" y "patología del corazón") obtienen representaciones cercanas, resolviendo el problema del *vocabulary mismatch* que afecta a los modelos léxicos.

La arquitectura predominante para recuperación densa es el **bi-encoder** (también denominado *dual-encoder*). Consiste en dos redes codificadoras, típicamente basadas en modelos Transformer preentrenados [Devlin et al., 2019], que operan de manera independiente sobre la consulta y el documento:

$$\text{sim}(q, d) = \mathbf{E}_q(q)^\top \mathbf{E}_d(d) \tag{2.3}$$

donde $\mathbf{E}_q$ y $\mathbf{E}_d$ son los codificadores de consulta y documento, h es la dimensionalidad del espacio de *embeddings*, y la similitud se calcula mediante el producto punto de los vectores resultantes.

Lo que hace viable la recuperación densa a gran escala es el cálculo anticipado y el almacenamiento de los *embeddings* de toda la colección antes de recibir cualquier consulta. En tiempo de inferencia, solo se codifica la consulta (una operación que toma milisegundos) y se buscan los vectores más cercanos en el espacio precalculado. Esta búsqueda de vecinos más cercanos aproximada (ANN)

se implementa mediante bibliotecas como FAISS [Johnson et al., 2021], reduciendo la complejidad a tiempos sublineales.

El entrenamiento se realiza mediante *fine-tuning* contrastivo sobre ternas (q, d^+, d^-): se acercan las representaciones de (q, d^+) y se alejan las de (q, d^-). Karpukhin et al. [2020] demostraron que este esquema supera a BM25 en preguntas abiertas; modelos posteriores como BGE-base-en-v1.5 [BAAI, 2024], BGE-M3 [Chen et al., 2024] y Voyage-3-large [Voyage AI, 2025] lo refinaron con destilación de conocimiento y soporte multilingüe.

Qué gana y qué pierde el bi-encoder. Los bi-encoders capturan relaciones semánticas que los modelos léxicos no pueden detectar: sinónimos, paráfrasis, implicaciones y relaciones conceptuales. Además, su arquitectura permite la búsqueda en tiempo sublineal mediante índices ANN, lo que los hace viables para colecciones de millones de documentos. Sin embargo, este modelo funciona codificando, de forma independiente, la consulta y los documentos. sin poder ver ambos textos a la vez, el modelo no puede modelar interacciones sutiles entre sus tokens. Además, esta compresión de información en un único vector de dimensión h implica pérdida de matices. Como consecuencia, los modelos densos se degradan en dominios con vocabulario técnico especializado, donde la coincidencia léxica exacta sigue siendo una señal fuerte de relevancia. Thakur et al. [2021] lo cuantificaron: en BEIR (18 *datasets*, nueve dominios), los modelos densos entrenados en MS MARCO pierden hasta 15 puntos de nDCG@10 fuera de su distribución de entrenamiento, mientras BM25 se mantiene más estable. Este hallazgo motivó el desarrollo de modelos *sparse* aprendidos que combinan la capacidad semántica de las redes neuronales con la eficiencia de los índices invertidos.

2.1.3. Recuperación sparse aprendida: SPLADE

Los modelos de recuperación *sparse* aprendida ocupan una posición intermedia entre los paradigmas léxico y denso siendo su objetivo principal generar

representaciones dispersas (*sparse*) de consultas y documentos que, al igual que BM25, puedan indexarse en un índice invertido para búsqueda eficiente, pero que incorporen capacidad de *expansión semántica*: la habilidad de asignar pesos no nulos a términos que no aparecen literalmente en el texto pero que son semánticamente relevantes [Formal et al., 2021].

SPLADE (*Sparse Lexical and Expansion Model*) logra esto mediante un modelo de lenguaje enmascarado (*Masked Language Model*, MLM) basado en BERT [Devlin et al., 2019]. Dado un texto de entrada t (consulta o documento), SPLADE produce un vector *sparse* $\mathbf{w}_t \in \mathbb{R}^{|\mathcal{V}|}$, donde $|\mathcal{V}|$ es el tamaño del vocabulario del tokenizador, mediante la siguiente operación:

$$w_{t,j} = \max_{i \in t} \log\big(1 + \mathrm{ReLU}\big(h_{ij}\big)\big) \tag{2.4}$$

donde h_{ij} es el *logit* de salida de la capa MLM para el token i del texto de entrada y el término j del vocabulario $\mathcal{V}$. La operación máx sobre los tokens de entrada (denominada *max pooling*) selecciona la activación más alta para cada término del vocabulario. La transformación $\log(1 + \mathrm{ReLU}(\cdot))$ introduce saturación logarítmica (análoga a la de BM25) y garantiza la no negatividad de los pesos, lo que produce representaciones dispersas.

El puntaje de relevancia entre una consulta q y un documento d se calcula como el producto punto de sus representaciones *sparse*:

$$\mathrm{sim}(q, d) = \mathbf{w}_q^\top \mathbf{w}_d = \sum_{j \in \mathcal{V}} w_{q,j} \cdot w_{d,j} \tag{2.5}$$

El mecanismo de expansión permite que la capa MLM asigne pesos no nulos a sinónimos y términos semánticamente cercanos que no aparecen literalmente en el texto, actuando como puente entre la coincidencia léxica de BM25 y la similitud semántica de los bi-encoders. SPLADEv2 [Formal et al., 2022] mejoró su eficacia mediante destilación de conocimiento y expansión solo del lado del documento.

SPLADE combina lo mejor de ambos paradigmas: indexa en estructura invertida (eficiencia de BM25) y expande semánticamente los términos (capacidad de

los modelos densos). Su principal limitación es la dependencia del dominio de entrenamiento al igual que en los modelos densos: aunque más robusto que los bi-encoders puros ante cambios de dominio [Thakur et al., 2021], el rendimiento se degrada en vocabularios muy especializados. El costo de indexación es mayor que en BM25, pero se incurre en este una sola vez.

La Tabla 2.1 resume las propiedades de los tres paradigmas de recuperación descritos.

Tabla 2.1: Comparación de los tres paradigmas de recuperación de información evaluados en este trabajo.

Modelo	**Tipo de señal**	**Costo de indexación**	**Estructura de índice**	**Capacidad de generalización**
BM25	léxica	bajo (índice invertido)	invertido	alta en dominios técnicos; falla en sinónimos
Bi-encoder	semántica	medio (codificación neural)	ANN (FAISS)	alta en dominios cercanos al entrenamiento; se degrada *out-of-distribution*
SPLADE	léxica y semántica	alto (MLM por documento)	invertido	intermedia; más robusta que bi-encoders puros

Las limitaciones de estos tres paradigmas son, curiosamente, complementarias: BM25 falla en semántica, los bi-encoders fallan en coincidencia léxica exacta y SPLADE ocupa una posición intermedia. Esa complementariedad es el argumento principal a favor de la fusión híbrida, que se describe a continuación.

2.2. Métodos de fusión

La fusión de resultados (*rank fusion*) consiste en combinar las listas ordenadas producidas por dos o más modelos de recuperación con el objetivo de obtener una

lista única cuya eficacia supere la de cualquier modelo individual [Vogt and Cottrell, 1999]. El principio subyacente es que modelos con señales complementarias (por ejemplo, uno léxico más otro semántico) cometen errores en documentos diferentes: los documentos relevantes que uno pierde tienden a ser recuperados por el otro.

En este trabajo se evalúan dos operadores de fusión: Reciprocal Rank Fusion (RRF), que opera sobre las posiciones de los documentos en cada lista, e interpolación lineal de puntajes, que opera sobre los valores numéricos de relevancia. A continuación se detalla cada uno de ellos.

2.2.1. Reciprocal Rank Fusion (RRF)

RRF surgió como respuesta a una necesidad práctica: combinar listas de resultados sin tener que calibrar pesos ni entrenar ningún modelo [Cormack et al., 2009]. Dado un conjunto de listas de resultados $R = \{r_1, r_2, \ldots, r_L\}$ producidas por L modelos, RRF asigna a cada documento d un puntaje combinado:

$$\mathrm{RRF}(d) = \sum_{\ell=1}^{L} \frac{1}{k + \mathrm{rank}_\ell(d)} \tag{2.6}$$

donde $\mathrm{rank}_\ell(d)$ es la posición (comenzando en 1) del documento d en la lista r_ℓ, y k es un hiperparámetro de suavizado. Si el documento d no aparece en la lista r_ℓ, su contribución es cero (o se le asigna un rango artificialmente alto).

El hiperparámetro k actúa como un factor de amortiguamiento: valores pequeños enfatizan las primeras posiciones, mientras que valores grandes suavizan las diferencias entre rankings. El valor $k = 60$, propuesto originalmente, es el estándar en la práctica; su sensibilidad en escenarios conversacionales motiva el estudio de ablación EA5 de esta investigación.

Ventajas. La propiedad más relevante de RRF es que opera exclusivamente sobre posiciones ordinales, no sobre puntajes numéricos. Esta característica lo hace **agnóstico a la escala**: puede combinar listas producidas por modelos con distribuciones de puntaje completamente heterogéneas (por ejemplo, los puntajes

de BM25, que siguen una distribución sesgada con cola larga, con los del producto punto de un bi-encoder, que tienden a concentrarse en un rango estrecho) sin requerir ninguna normalización previa. Además, RRF no tiene parámetros que deban estimarse a partir de datos etiquetados, lo que lo convierte en un método del tipo *zero-shot* inmediatamente aplicable a cualquier dominio.

Limitaciones. Al operar sobre posiciones, RRF descarta información sobre la magnitud de los puntajes. Dos documentos con puntajes de 0.95 y 0.94 (prácticamente equivalentes) reciben tratamientos distintos si sus posiciones difieren. Además, el hiperparámetro k se ha mantenido fijo en $k = 60$ por convención desde el trabajo original de Cormack et al. [2009], sin que exista un análisis sistemático de su sensibilidad en contextos conversacionales multi-turno. Esta brecha motiva directamente el estudio de ablación EA5 de la presente investigación.

2.2.2. Interpolación lineal de puntajes

A diferencia de RRF, la interpolación lineal opera directamente sobre los puntajes numéricos [Vogt and Cottrell, 1999]:

$$\text{score}(d) = \alpha \cdot \hat{s}_1(d) + (1 - \alpha) \cdot \hat{s}_2(d) \tag{2.7}$$

donde $\alpha \in [0, 1]$ pondera la contribución de cada modelo y $\hat{s}$ denota los puntajes normalizados con *min-max* al intervalo $[0, 1]$. La normalización es obligatoria porque los puntajes de distintos modelos residen en escalas incompatibles; su desventaja es la sensibilidad a valores atípicos que comprimen el resto de la distribución. Además, α requiere ajuste mediante validación cruzada, introduciendo dependencia del dominio de calibración.

La Tabla 2.2 resume las diferencias entre ambos métodos.

La fusión, sin embargo, opera sobre la consulta tal como la formula el usuario. En diálogos multi-turno, esa consulta puede ser ambigua o incompleta debido a fenómenos de correferencia y elipsis. La sección siguiente aborda las técnicas

Tabla 2.2: Comparación de los operadores de fusión evaluados en este trabajo.

Propiedad	**RRF**	**Interpolación lineal**
Opera sobre	posiciones (rangos)	puntajes numéricos
Requiere normalización	no	sí (*min-max*)
Hiperparámetros	k (suavizado)	α (peso)
Sensible a *outliers*	no	sí
Preserva magnitud	no	sí
Entrenamiento requerido	ninguno	ajuste de α

de reescritura que transforman estas consultas dependientes del contexto en una consulta autocontenida.

2.3. Reescritura de consultas en diálogos multi-turno

A partir del segundo turno de una conversación, las consultas tienden a ser lingüísticamente incompletas: contienen pronombres cuyo referente se estableció en turnos previos (*correferencia*) u omiten entidades que el usuario asume ya compartidas (*elipsis*). Estos fenómenos son naturales en el diálogo humano, pero para los modelos de recuperación, que procesan cada consulta de forma aislada sin acceso al historial conversacional, es algo realmente indescifrable [Elgohary et al., 2019].

2.3.1. Correferencia y elipsis en contextos conversacionales

Dos fenómenos explican la mayoría de estas ambigüedades. La **correferencia** ocurre cuando una expresión lingüística, típicamente un pronombre, se refiere a una entidad ya mencionada previamente en el discurso; la **elipsis** ocurre cuando se omite un constituyente recuperable del contexto (un ejemplo concreto se ilustró en la Figura 1.2 del capítulo 1).

Elgohary et al. [2019] formalizaron la tarea de reescritura conversacional como una función R que transforma la consulta del turno actual q_t, condicionada en el

historial $H_t = \{(q_1, r_1), \ldots, (q_{t-1}, r_{t-1})\}$, en una consulta autocontenida $\hat{q}_t$:

$$\hat{q}_t = R(q_t, H_t) \tag{2.8}$$

donde $\hat{q}_t$ debe ser interpretable sin acceso a H_t y preservar la intención informativa del turno original. Los autores demostraron que la resolución explícita de correferencias y elipsis mejora significativamente la recuperación de pasajes frente al uso directo de q_t.

2.3.2. Enfoques de reescritura

Los métodos de reescritura se clasifican en dos familias principales según su mecanismo de transformación.

Modelos generativos (*sequence-to-sequence*). Estos modelos entrenan un codificador-decodificador para generar $\hat{q}_t$ a partir de H_t y q_t. El codificador se encarga de transformar la consulta original en una representación matemática que captura el significado real de la pregunta (vectores de contexto), mientras que el decodificador toma ese vector de contexto y genera una secuencia de palabras nueva para construir una oración más clara y rica en terminología. Su ventaja es la capacidad de generar consultas fluidas y naturales; su limitación es la dependencia de datos de entrenamiento anotados con pares $(q_t, \hat{q}_t)$ [Anantha et al., 2021].

Reescritura con LLMs. Un enfoque más reciente utiliza un LLM con un *prompt zero-shot* para resolver correferencias y elipsis, sin necesidad de datos de entrenamiento específicos. Lin et al. [2021] mostraron que la reescritura complementa al recuperador sin reemplazarlo: El reescribir una consulta permite al recuperador obtener documentos más precisos, mientras que la original permite retener términos técnicos (la reescritura puede parafrasear inadvertidamente). En cualquier caso, la reescritura añade latencia y puede introducir errores en conversaciones largas con cambios de tema.

2.4. Reranking neuronal con cross-encoders

Una vez que el *pipeline* de primera etapa ha producido una lista de candidatos, queda abierta una pregunta: ¿puede ese ordenamiento mejorarse? Los modelos de *reranking* ofrecen la respuesta: reciben los n candidatos recuperados y los reordenan con un modelo de mayor capacidad, sacrificando velocidad por mayor precisión [Nogueira and Cho, 2019].

2.4.1. Arquitectura cross-encoder

A diferencia de los bi-encoders, que codifican consulta y documento de manera independiente, un **cross-encoder** concatena ambos textos y los procesa conjuntamente a través de un modelo Transformer:

$$\text{rel}(q, d) = \sigma\big(\mathbf{W}^\top \cdot \text{Transformer}([q\,;\,d])_{\texttt{[CLS]}} + b\big) \tag{2.9}$$

donde $[q\,;\,d]$ denota la concatenación de la consulta y el documento separados por un token especial, $\text{Transformer}(\cdot)_{\texttt{[CLS]}}$ es la representación del token `[CLS]` de la última capa del modelo, $\mathbf{W}$ y b son los parámetros de la capa de clasificación, y σ es la función sigmoide que produce un puntaje de relevancia en $[0, 1]$.

La diferencia respecto al bi-encoder es que el cross-encoder permite *interacciones de atención cruzada entre todos los tokens* de la consulta y el documento. Mientras que un bi-encoder comprime cada texto en un único vector antes de compararlos, el cross-encoder modela dependencias sutiles; por ejemplo, establecer que el término “banco” proviene de institución financiera porque el documento menciona “préstamo hipotecario”, lo que se traduce en estimaciones de relevancia más precisas. Sin embargo, esta precisión tiene un costo: el cross-encoder procesa la concatenación (q, d) para cada par candidato con complejidad $O(n)$, lo que lo hace inviable como primera etapa de recuperación. Nogueira and Cho [2019] demostraron que un cross-encoder basado en BERT mejora el MRR@10 en MS MARCO en más de 10 puntos respecto a BM25.

2.4.2. Reranking como etapa de refinamiento

En la práctica, el cross-encoder se aplica como etapa de *reranking* sobre los n candidatos recuperados por la primera etapa ($n \in \{50, 100, 200\}$). La **profundidad de reranking** introduce un compromiso: un n mayor aumenta la probabilidad de promover documentos relevantes en posiciones bajas y además, cada candidato requiere una pasada completa por el Transformer aumentando el costo computacional.

2.4.3. Modelos de reranking evaluados

En esta tesis se considera tanto un reranker *open-source* (BGE-Reranker-v2-m3 [Beijing Academy of Artificial Intelligence, 2024], ejecutado localmente en GPU) como uno comercial (Cohere Rerank v3.5 [Cohere, 2025], accesible por API); su configuración experimental se detalla en el Capítulo 5.

2.5. Arquitectura de generación aumentada por recuperación (RAG)

Las secciones anteriores describieron los componentes individuales del *pipeline* de recuperación: modelos de primera etapa, operadores de fusión, reescritura de consultas y reranking. El paradigma de *generación aumentada por recuperación* (*Retrieval-Augmented Generation*, RAG) [Lewis et al., 2020] integra estos componentes con un modelo de lenguaje generativo para producir respuestas fundamentadas en evidencia documental, reduciendo las alucinaciones y permitiendo el acceso a conocimiento actualizado sin reentrenamiento.

La Figura 2.1 presenta el diagrama de bloques de la arquitectura IIMAS-RAG de extremo a extremo presentada originalmente en el marco de la competencia SemEval 2026, ACL, como parte de un trabajo colaborativo. El flujo comprende dos grandes bloques: *recuperación* (resaltado en azul) y *generación* (resaltado en naranja). La contribución de esta investigación se centra en el bloque de recuperación.

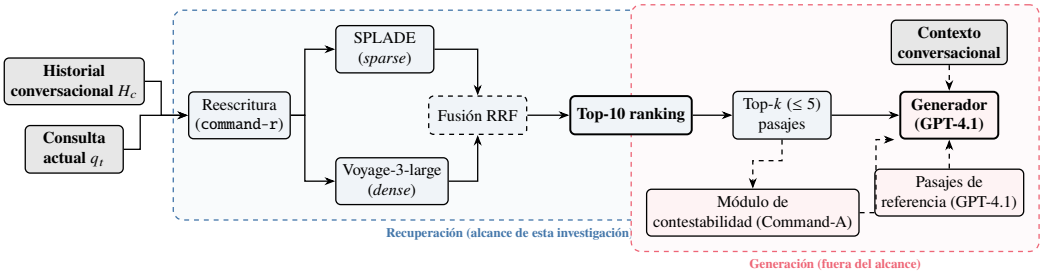


Figura 2.1: Arquitectura IIMAS-RAG de extremo a extremo. Las flechas continuas trazan el *pipeline* principal: entradas → reescritura → SPLADE / Voyage-3 → fusión RRF → ranking top-10 → selección de pasajes → generador. El bloque de recuperación (resaltado en azul) constituye el alcance de esta investigación: reescritura de consultas, recuperación con fusión híbrida y selección de pasajes. El bloque de generación (resaltado en naranja) incorpora el contexto conversacional, un módulo de contestabilidad (que clasifica la pregunta en parcial o completamente respondible) y pasajes de referencia; queda fuera del presente estudio.

RAG formaliza la generación como marginalización sobre los documentos recuperados: dada la consulta $\hat{q}_t$ y los K documentos mejor ranqueados, la respuesta se genera como:

$$p(r_t \mid \hat{q}_t) \approx \sum_{k=1}^{K} p(d_k \mid \hat{q}_t) \cdot p(r_t \mid \hat{q}_t, d_k) \tag{2.10}$$

En la práctica los K documentos se integran en el *prompt*.

2.6. Fundamentos de evaluación y significancia en IR

En un *pipeline* RAG, el orden de los documentos recuperados determina directamente la calidad de la respuesta generada: un documento relevante en posición 1 alimenta al LLM, mientras que uno en posición 50 queda fuera de la ventana de contexto del LLM. Esta sección formaliza las métricas de

evaluación empleadas en este trabajo y los fundamentos estadísticos que sustentan las comparaciones entre configuraciones experimentales.

2.6.1. Métricas de evaluación basadas en rankings

Precisión, Recall y sus limitaciones. Dada una consulta q y un conjunto de documentos recuperados $\mathcal{R}$:

$$\text{Precisión} = \frac{|\mathcal{R} \cap \mathcal{R}\rceil\updownarrow|}{|\mathcal{R}|} \qquad \text{Recall} = \frac{|\mathcal{R} \cap \mathcal{R}\rceil\updownarrow|}{|\mathcal{R}\rceil\updownarrow|} \tag{2.11}$$

donde $\mathcal{R}\rceil\updownarrow$ es el conjunto de documentos relevantes. Las variantes Precisión@k y Recall@k evalúan sobre los primeros k documentos de la lista ordenada [Manning et al., 2009]. Ambas métricas presentan una limitación: no distinguen entre posiciones (Recall@10 = 1.0 tanto si el documento relevante está en posición 1 como en posición 10) y operan con juicios binarios, sin capturar grados de relevancia.

Ganancia Acumulada con Descuento Normalizada (nDCG@k). Propuesta por Järvelin and Kekäläinen [2002], nDCG@k pondera la relevancia de cada documento por un descuento logarítmico que penaliza posiciones tardías:

$$\text{DCG@}k = \sum_{i=1}^{k} \frac{2^{\text{rel}_i} - 1}{\log_2(i+1)} \tag{2.12}$$

donde $\text{rel}_i \in \{0, 1, 2, \ldots\}$ es el grado de relevancia en la posición i. La normalización por el DCG ideal produce:

$$\text{nDCG@}k = \frac{\text{DCG@}k}{\text{IDCG@}k} \in [0, 1] \tag{2.13}$$

Se emplea nDCG@10 como métrica principal, siguiendo el protocolo de MTRAG [Katsis et al., 2025].

Mean Reciprocal Rank (MRR). Mide la posición del *primer* documento relevante, promediando sobre un conjunto de consultas Q [Manning et al., 2009]:

$$\text{MRR} = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{\text{rank}_q} \tag{2.14}$$

La Tabla 2.3 resume las propiedades de las cuatro métricas.

Tabla 2.3: Comparación de las métricas de evaluación empleadas en este trabajo.

Métrica	Sensible al orden	Relevancia graduada	Normalizada	Uso principal
Precisión@k	no	no	sí ($[0, 1]$)	eficacia general
Recall@k	no	no	sí ($[0, 1]$)	cobertura
MRR	sí	no	sí ($[0, 1]$)	primer resultado
nDCG@k	sí	sí	sí ($[0, 1]$)	calidad del ranking

2.6.2. Pruebas de significancia estadística

Las métricas de IR son acotadas, asimétricas y de naturaleza ordinal, lo que invalida los supuestos de las pruebas paramétricas [Sakai, 2014]; este trabajo emplea exclusivamente pruebas no paramétricas.

La **prueba de Wilcoxon de rangos con signo** compara dos sistemas sobre las mismas consultas: las diferencias por consulta se ordenan por valor absoluto, se suman los rangos positivos (W^+) y negativos (W^-), y si $W = \min(W^+, W^-)$ es suficientemente pequeño se rechaza la hipótesis de equivalencia [Wilcoxon, 1945]. Dado que se realizan múltiples comparaciones, se aplica la **corrección de Holm-Bonferroni**, que ordena los p-valores y los compara con umbrales $\alpha/(n - i + 1)$, menos conservadores que la corrección clásica [Holm, 1979]. Para cuantificar la magnitud de las diferencias se emplea el δ **de Cliff** [Cliff, 1993]:

$$\delta = \frac{\#(x_i > y_j) - \#(x_i < y_j)}{n_1 \cdot n_2} \in [-1, 1] \tag{2.15}$$

con umbrales $|\delta| < 0.147$ (despreciable), < 0.33 (pequeño), < 0.474 (mediano) y

≥ 0.474 (grande). Finalmente, el τ **de Kendall** [Kendall, 1938] mide la concordancia entre rankings de configuraciones a través de dominios ($\tau = 1$: concordancia perfecta; 0: independencia; -1: inversión completa). El protocolo estadístico completo se detalla en el Capítulo 5.

Capítulo 3

Estado del Arte

La literatura encontrada sobre recuperación de información conversacional en entornos multi-turno ha crecido notoriamente en los últimos años. Este capítulo organiza los hallazgos más relevantes del período 2022–2025. Más recientemente (2025–2026), han surgido otros *benchmarks* conversacionales multi-turno que exploraremos más adelante, así como ”wikis personales” mantenidas por LLMs, que combinan diálogo, razonamiento intensivo y memoria persistente y están redefiniendo los límites del estado del arte en RAG conversacional [Karpathy, 2026].

3.1. Recuperación y fusión híbrida

Esta sección contextualiza la necesidad de explorar las preguntas: PI1 (ganancia de la fusión frente al mejor modelo individual) y PI3 (sensibilidad del hiperparámetro k de RRF).

3.1.1. Evidencia reciente sobre fusión híbrida

Los *benchmarks* BEIR y MTEB (*Massive Text Embedding Benchmark*) [Muennighoff et al., 2023] se han posicionado como el estándar de

evaluación en sistemas de búsqueda léxicos y dispersos. MTEB se caracteriza porque cubre más de 50 conjuntos de datos y supera los 100 idiomas, incluyendo el español.

BGE-M3 [Chen et al., 2024] combinó recuperación densa, léxica aprendida y multi-vector en un solo modelo; la fusión de sus tres señales mediante RRF superó a cada señal individual en BEIR, confirmando que la combinación de representaciones heterogéneas persiste incluso cuando provienen del mismo codificador. Por otro lado, E5-Mistral [Wang et al., 2024a] demostró que los LLMs decodificadores generan *embeddings* bastante competitivos, pero a costa de un mayor costo computacional y menor interpretabilidad.

En ambos casos, combinar las señales heterogéneas supera al mejor paradigma individual en la mayoría de los dominios, con ganancias de +2 a +8 puntos de nDCG@10 según la diversidad del corpus [Chen et al., 2024, Thakur et al., 2021]. Este hallazgo apoya PI1. Aún así, la evidencia disponible sigue siendo limitada sobre si estas ganancias se mantienen en escenarios conversacionales multi-turno, y más aún, sobre dominios especializados.

3.1.2. Sensibilidad de RRF y alternativas de fusión

Elasticsearch 8.8 [Elastic NV, 2023] es una actualización de la plataforma ”Elastic Stack” que integra IA generativa (mediante el modelo ELSER, *Elastic Learned Sparse Encode*) para realizar búsquedas semánticas por significado y no solo por palabras clave. Utiliza RRF [Cormack et al., 2009] con $k = 60$; esta decisión está basada en investigaciones empíricas que demuestran que este valor ofrece el mejor equilibrio para combinar múltiples sistemas de búsqueda. En la web, este valor de 60 permite filtrar el ruido (e. g. el spam) que se encuentra constantemente en los datos masivos. Sin embargo, en un sistema conversacional, el objetivo no es proporcionar una lista de opciones (como lo hace Google), sino entregar una sola respuesta correcta al LLM.

Con $k = 60$, la puntuación del resultado, por ejemplo, de #1 y #5, son casi idénticas. En una conversación, esto es problemático porque el sistema RAG podría

acabar enviándole al LLM el resultado #5 en lugar del #1 (que era la respuesta correcta pero solo la encontró un motor).

RRF nació para la web (ya que controla el ruido), no para finanzas o documentación técnica y es esta precisamente la motivación de PI3.

Dos trabajos recientes ilustran los riesgos de asumir la configuración por defecto. Rackauckas [2024] mostraron que la fusión RRF de múltiples consultas expandidas por un LLM (técnica conocida como query expansion) mejora la cobertura, pero propaga errores cuando las consultas expandidas se alejan del tema original, lo que subraya la interacción entre reescritura y fusión (interacción entre las preguntas de investigación PI2 y PI3). Para mitigar este error, se podría haber establecido un umbral de $K = 10$, permitiendo que el sistema priorice exclusivamente aquellas consultas con resultados de alta confianza y relevancia clara. Si el LLM generó una variante que se alejó del tema, es probable que los resultados que traiga tengan un rango bajo.

El trabajo de Wang et al. [2024b], titulado *Searching for Best Practices in Retrieval-Augmented Generation* realiza un estudio de ablación masivo sobre cada paso del flujo RAG. Encontraron que la configuración óptima de fusión varía significativamente entre tareas, reforzando la necesidad de estudios de ablación en dominio especializados como el que esta tesis propone.

3.1.3. Fusión híbrida con *learned sparse* y BEIR

Los modelos *learned sparse* como SPLADE [Formal et al., 2021, 2022] representan un punto intermedio entre la señal léxica clásica y la densa. En evaluaciones sobre BEIR, la fusión híbrida de SPLADE y un recuperador denso (Contriever [Izacard et al., 2022]) obtuvo, en general, un rendimiento superior al de cada componente individual. En términos de nDCG@10, el modelo híbrido superó al mejor componente individual en 14 de los 18 conjuntos de datos evaluados y a BM25 en 16 de ellos [Kamalloo et al., 2024], con las mayores ganancias en dominios especializados (biomédico, legal). La presente tesis evalúa esta misma hipótesis en el contexto multi-turno de MTRAG [Katsis et al., 2025]. En el capítulo

5 veremos como es que Voyage-3-large con SPLADE tiene una mejora significativa sobre los modelos individuales.

Además, en escenarios de consulta única (*single-turn*) la evidencia está consolidada. La búsqueda conversacional multi-turno es otra historia: los estudios de ablación tratan configuraciones como bloques monolíticos. Descomponer el efecto de hiperparámetros como k de RRF, y la interacción entre fusión, reescritura y *reranking* rara vez se estudia de manera conjunta.

3.2. Reescritura de consultas conversacionales

Si el usuario pregunta ”¿Cuándo se reformó por última vez?” sin explicitar el referente, tanto el recuperador léxico como el denso buscarán ”reformas” en general, no la ley específica mencionada turnos atrás. Esta sección revisa la evidencia empírica sobre métodos de reescritura, centrada en PI2 (impacto de la reescritura frente al uso del último turno).

3.2.1. De la reescritura supervisada al *prompting* con LLMs

El problema de la reescritura conversacional tomó forma a partir de CANARD [Elgohary et al., 2019] y QReCC [Anantha et al., 2021], los primeros datasets dedicados a esta tarea. Ambos establecieron que la calidad de la reformulación es el factor primordial para obtener el mejor rendimiento, pero sus modelos supervisados (T5 *fine-tuned*) requerían datos anotados por dominio, lo que limitaba su escalabilidad.

A partir de 2023, el *prompting* con LLMs desplazó a los enfoques supervisados.

Mao et al. [2023] demostraron que un LLM con *prompting* captura la intención contextual de forma competitiva en comparación con un T5 supervisado en CAsT 2021, y mejor aún, sin datos de entrenamiento. Sin embargo, no hay control de calidad, es decir, el LLM genera un sola variante, por lo que, no se sabe realmente si el LLM confundió pronombres o si parafraseó terminología técnica. Esta limitante fue atacada por ConvGQR [Mo et al., 2023] mediante la generación de múltiples

candidatos y posterior selección del que maximiza la señal del recuperador. Esto funciona bien en turnos con alta ambigüedad referencial, pero el costo escala linealmente con el número de candidatos generados. Otra alternativa, que en combinación de la reescritura simple llego a superar métodos *zero-shot* en 11 de 15 conjuntos de BEIR es HyDE [Gao et al., 2023]. HyDE genera un documento hipotético y lo codifica directamente. La ganancia se paga con latencia y costo (una llamada generativa adicional por consulta) lo que la hace más adecuada para escenarios con bajo volumen.

Un hallazgo documentado por Lin et al. [2021], es que la fusión RRF de la consulta reescrita con la original supera a cualquier estrategia individual. Esta observación motiva directamente el diseño de PI2, donde la reescritura se evalúa *sobre una configuración híbrida fija* para aislar su contribución.

3.2.2. El problema del *context drift*

Cuando la conversación cambia de tema (riesgo conocido como *context drift*), la consulta reformulada se ve contaminada con el contexto irrelevante que le precede. Dalton et al. [2021] documentaron caídas drásticas en el rendimiento de recuperación (medido a través de métricas como nDCG@3) en aquellos turnos donde los usuarios introducen cambios abruptos de tema, lo que deja en evidencia la dificultad de los modelos para mantener un contexto histórico coherente en TREC CAsT 2020. Las estrategias de mitigación propuestas hasta la fecha, como la detección de cambios de tema [Lin et al., 2023] y el decaimiento temporal del historial [Lin et al., 2021], no se han evaluado en *pipelines* híbridos multi-turno.

Una dirección prometedora es la resolución de correferencias *sin* reformulación completa: aproximaciones basadas en la extracción y vinculación de regiones de texto o *spans* [Joshi et al., 2019] resuelven correferencias a nivel de turno preservando la estructura original. Esto reduce el riesgo de parafraseo inadvertido, lo cual es valioso en dominios especializados donde la terminología es una señal léxica muy importante.

3.3. Reranking sobre *pipelines* híbridos

La reescritura actúa *antes* de la recuperación mientras que el *reranking* actúa *después*. Su tarea es refinar el ordenamiento una vez que los candidatos han sido recuperados. Esta sección se centra en PI4 (efecto de la profundidad del *reranking*) y parte de PI5 (compromisos calidad-latencia-costo), con énfasis en la interacción entre *reranking* y recuperación híbrida.

3.3.1. El giro hacia el *reranking* con LLMs

Desde el 2023, Sun et al. [2023], mostraron que GPT-4 en modo *listwise* supera a los *cross-encoders* supervisados en varios conjuntos de BEIR. El problema: un costo por consulta dos órdenes de magnitud mayor, es decir, el proceso es 100 veces más caro que el método estandar.

La pregunta más interesante es si esa efectividad es alcanzable disminuyendo estos costos. RankZephyr [Pradeep et al., 2023] (7B) demostró que sí: el destilado de GPT-4 para *reranking listwise*, iguala su rendimiento a una fracción del precio. RankLLaMA [Ma et al., 2024] (7–13B) tomó otra ruta usando *fine-tuning* puntual sobre LLaMA y obtuvo efectividad en *zero-shot* comparable en BEIR. NV-RerankQA-Mistral-4B-v3 [de Souza P. Moreira et al., 2024] (4B) identificó un hallazgo relevante para los fines de esta investigación: la elección del *reranker* tuvo mayor impacto sobre el rendimiento final que la del recuperador de primera etapa.

Sin embargo, toda esa evidencia se construyó sobre escenarios *ad hoc* de consulta única. Asimismo, los compromisos entre tamaño del modelo, precisión y latencia varían por dominio [de Souza P. Moreira et al., 2024], lo que hace imposible recomendar una configuración universal, un resultado notable para PI5.

3.3.2. Interacción entre *reranking* y recuperación híbrida

La hipótesis H4b se basa en que la calidad de la recuperación inicial actúa como un límite máximo para el éxito del *reranker*. Glass et al. [2022] ya advertían que

el *reranking* funciona muy bien para BM25, pero su impacto se diluye (y a veces desaparece) cuando se aplica sobre una fusión híbrida ya optimizada.

Al incrementar la profundidad de reordenamiento de 100 a 1 000 documentos, Thakur et al. [2021] observaron que el modelo empieza a asignar relevancia espuria a documentos marginales, degradando el nDCG@10. Eibich et al. [2024] confirmaron el patrón en sistemas RAG con LLMs: Cohere Rerank y MMR no mostraron ventajas consistentes sobre configuraciones híbridas ya optimizadas. Forzar un *reranking* profundo a una primera etapa que de por sí ya es fuerte implica añadir latencia innecesaria.

El estudio de ablación EA7 del capítulo 5 pone a prueba esa saturación, buscando el punto donde el costo computacional deja de justificar la ganancia marginal en nDCG@10 en el contexto conversacional.

3.4. *Benchmarks* multi-turno y dominios especializados

Esta sección compara los principales *benchmarks* conversacionales para situar la elección de MTRAG en el contexto de PI6 (consistencia entre dominios); la descripción de los datos se presenta en el capítulo 4.

La Tabla 3.1 resume las características de los siete *benchmarks* más utilizados en búsqueda conversacional.

Como muestra la tabla, los *benchmarks* previos presentan al menos una de tres carencias: ausencia de juicios humanos a nivel de pasaje (CANARD, QReCC, ORConvQA, TopiOCQA), un único dominio general que impide evaluar la consistencia de configuraciones entre dominios (todos los previos), o un número reducido de conversaciones que limita el alcance de las pruebas estadísticas (TREC CAsT). MTRAG [Katsis et al., 2025] es el único *benchmark* que combina simultáneamente dominios especializados heterogéneos, juicios de relevancia humanos y cambios de tema; estas son las tres condiciones necesarias para abordar PI6. Las características de sus cuatro dominios, su estructura de archivos y sus

Tabla 3.1: Comparación de los principales *benchmarks* para búsqueda conversacional multi-turno. Los turnos promedio se indican por conversación.

Benchmark	Convs.	Turnos prom.	Dominios	Corpus	Juicios humanos	Cambio tema
CANARD [Elgohary et al., 2019]	40 000 (pares)	4.6	Wikipedia (general)	QuAC	No	No
TREC CAsT 2019 [Dalton et al., 2019]	50	10	1 (general)	MS MARCO + TREC CAR	Sí	No
TREC CAsT 2020 [Dalton et al., 2021]	25	12	1 (general)	MS MARCO + TREC CAR	Sí	No
QReCC [Anantha et al., 2021]	14 000	5.7	1 (general)	54M pasajes web	No	No
ORConvQA [Qu et al., 2020]	831	5.2	1 (general)	Wikipedia	No	No
TopiOCQA [Adlakha et al., 2022]	3 920	13	1 (general)	Wikipedia	No	Sí
MTRAG [Katsis et al., 2025]	**110**	**7.7**	**4 (especial.)**	**4 corpus especial.**	**Sí**	**Sí**

juicios de relevancia se describen a detalle en el capítulo 4.

3.5. Brechas abiertas: sensibilidad, interacción entre componentes y *trade-offs* de producción

La revisión del estado del arte deja en claro que, aunque cada componente del *pipeline* se ha investigado activamente, persisten vacíos. Se identifican cuatro brechas que motivan el diseño experimental.

3.5.1. Brecha 1: ausencia de estudios de ablación sistemáticos en *pipelines* híbridos multi-turno

La fusión híbrida, la reescritura y el *reranking* se han evaluado predominantemente por separado: RRF sin reescritura [Cormack et al., 2009], *reranking* sobre BM25 sin fusión [Nogueira and Cho, 2019], y reescritura sin *reranking* [Anantha et al., 2021]. Los sistemas TREC CAsT combinan múltiples componentes pero no descomponen la contribución marginal de cada módulo. Hasta donde alcanza esta revisión, no se identifica un estudio que aplique un diseño de ablación OFAT sobre un *pipeline* completo en contexto multi-turno.

3.5.2. Brecha 2: escasa evidencia sobre sensibilidad de hiperparámetros en dominios especializados

El parámetro k de RRF, la profundidad de recuperación y la profundidad de *reranking* constituyen hiperparámetros cuya influencia rara vez se reporta. El $k = 60$ canónico carece de validación en dominios especializados [Cormack et al., 2009]; BEIR evaluó múltiples dominios pero no varió hiperparámetros de fusión [Thakur et al., 2021]; y los compromisos documentados por de Souza P. Moreira et al. [2024] se limitan a escenarios ad hoc. La ausencia de curvas de sensibilidad en dominios financiero, gubernamental o técnico impide decisiones informadas en producción.

3.5.3. Brecha 3: evaluación insuficiente de la reescritura como variable independiente

La literatura evalúa la reescritura mediante métricas de QA (F1, EM) o sobre un único recuperador. Hasta donde alcanza esta revisión, la evidencia sobre el impacto de la reescritura *sobre una fusión híbrida fija*, controlando simultáneamente tipo de fusión, modelos de recuperación y profundidad de *reranking*, sigue siendo escasa. Este vacío es relevante porque la reescritura puede interactuar sustancialmente con

componentes posteriores: una reescritura que parafrasea términos técnicos puede mejorar la recuperación densa pero degradar la léxica.

3.5.4. Brecha 4: ausencia de análisis de compromisos calidad-latencia-costo

La decisión de incorporar un *reranker* propietario, un modelo de reescritura basado en LLM o un recuperador denso con API comercial implica compromisos que rara vez se cuantifican integralmente. Estudios recientes han documentado costos de GPT-4 para *reranking* [Sun et al., 2023], latencias de modelos destilados [Pradeep et al., 2023] y *trade-offs* de producción [de Souza P. Moreira et al., 2024]; pero hasta donde alcanza esta revisión, no se identifican estudios que construyan una frontera de Pareto calidad-latencia-costo para un *pipeline* conversacional completo.

En conjunto, estas cuatro brechas delimitan el espacio de contribución de esta tesis: un estudio de ablación sistemático (brecha 1) que evalúe la sensibilidad de hiperparámetros (brecha 2) y el efecto de la reescritura como variable independiente (brecha 3) sobre múltiples dominios especializados, con un análisis de compromisos calidad-latencia-costo (brecha 4) que permita derivar recomendaciones prácticas de configuración.

3.6. Síntesis del estado del arte

La Tabla 3.2 resume los trabajos más representativos organizados por componente del *pipeline* y su conexión con las preguntas de investigación.

Tabla 3.2: Tabla de síntesis del estado del arte. Se presentan los trabajos más representativos por componente del *pipeline*, indicando la propuesta principal, el *dataset*, la métrica reportada, la limitación y la Pregunta de Investigación (PI) que motivan.

Autor/Año	Propuesta	Dataset	Métrica	Limitación	PI
Recuperación y fusión híbrida					
Chen et al. [2024]	BGE-M3 (multi)	BEIR	nDCG@10	Sin contexto conv.	1, 3
Muennighoff et al. [2024]	GritLM	MTEB	nDCG@10	Sin multi-turno	1
Zhuang et al. [2024]	PromptReps	BEIR	nDCG@10	Solo zero-shot	1, 3
Rackauckas [2024]	RAG-Fusion*	MS MARCO	nDCG@10	Sin eval. multi-turno	3
Reescritura de consultas					
Mo et al. [2023]	ConvGQR	CAsT 20-21	nDCG@3	Costo multi-reform.	2
Mao et al. [2023]	LLM prompting	CAsT 2021	nDCG@3	Sin control hiperp.	2
Joshi et al. [2019]	BERT-e2e (Spans)	OntoNotes	F1 (Coref.)	Sin eval. en IR conv.	2
Reranking					
Sun et al. [2023]	LLM listwise	BEIR	nDCG@10	Alto costo, sensib.	4, 5
Pradeep et al. [2023]	RankZephyr	BEIR	nDCG@10	Sin eval. conv.	4
Ma et al. [2024]	RankLLaMA	BEIR	nDCG@10	Sin multi-turno	4
de Souza P. Moreira et al. [2024]	NV-RerankQA	MS MARCO	nDCG@10	Solo ad hoc	4, 5
Benchmarks conversacionales					
Dalton et al. [2021]	TREC CAsT	MS MARCO	nDCG@10	1 dominio general	6
Adlakha et al. [2022]	TopiOCQA	Wikipedia	F1	Sin juicios humanos	6
Katsis et al. [2025]	MTRAG	4 dom. esp.	nDCG@10	Escala moderada†	6

*RRF multi-query.

†MTRAG compensa su escala moderada (110 conversaciones) con tres propiedades ausentes en los demás *benchmarks*: dominios especializados heterogéneos, juicios de relevancia humanos a nivel de pasaje y cambios de tema intra-conversación (véase la Tabla 3.1).

Capítulo 4

Descripción de los Datos

Este capítulo describe el *benchmark* MTRAG [Katsis et al., 2025]: sus cuatro dominios especializados, la estructura de las conversaciones, los juicios de relevancia humanos y el preprocesamiento aplicado antes de la indexación.

4.1. *Benchmark* MTRAG: características generales

MTRAG (*Multi-Turn Retrieval-Augmented Generation*) [Katsis et al., 2025] fue diseñado por investigadores de IBM Research para medir el rendimiento de sistemas RAG en conversaciones multi-turno. A diferencia de los *benchmarks* conversacionales anteriores, centrados principalmente en la búsqueda de información, MTRAG evalúa el *pipeline* completo de RAG (recuperación + generación), aunque esta tesis se limita a la etapa de recuperación.

4.1.1. Justificación de la selección

En el capítulo 3 (Tabla 3.1) se comparó MTRAG con los principales *benchmarks* conversacionales y se concluyó que es el único que combina simultáneamente dominios especializados heterogéneos, juicios de relevancia humanos y cambios de tema dentro de las conversaciones. Además, las conversaciones fueron creadas

por anotadores humanos que interactuaban con un sistema RAG real (basado en Mixtral 8x7B), lo que genera patrones de conversación naturales con correferencia, elipsis y preguntas no respondibles.

4.1.2. Escala y composición del *benchmark*

MTRAG reúne **110 conversaciones** en cuatro dominios, con **842 turnos** de consulta en total. Cada conversación tiene en promedio 7.7 turnos (mínimo 3, máximo 12). El corpus completo suma **366 479 pasajes** según el *benchmark* original [Katsis et al., 2025]; tras el filtrado de pasajes vacíos descrito en la sección 4.4.2, esta tesis trabajó con **366 438 pasajes**. Ambos totales se distribuyen de forma desigual entre dominios, lo que crea un escenario de recuperación a escala realista.

El **86.9 %** de los turnos corresponde a consultas no iniciales (732/842), es decir, consultas formuladas dentro de una conversación ya en curso. Aunque no todas necesariamente contienen correferencia o elipsis (es decir, que puede tratarse de preguntas nuevas y autocontenidas), este porcentaje muestra que la mayor parte de la evaluación ocurre en condiciones donde el contexto conversacional *puede* afectar la interpretación de la consulta, lo que hace de MTRAG un *benchmark* especialmente exigente para sistemas de recuperación sin mecanismos de resolución de contexto.

4.1.3. Estructura de una conversación

Cada conversación en MTRAG sigue una estructura de diálogo entre un usuario humano y un agente RAG. Los turnos sucesivos introducen **correferencia** (e.g., el pronombre “it” refiere a una entidad mencionada en turnos previos) y **elipsis** (e.g., “a document” omite que se trata de un documento Cloudant). Si el sistema procesa únicamente el texto del último turno, pierde estas dependencias; de ahí la necesidad de los modos de consulta descritos a continuación.

4.1.4. Modos de consulta disponibles

MTRAG proporciona tres representaciones alternativas de cada consulta; esta tesis añade una cuarta construida a partir de los datos estructurados del *benchmark*.

El modo **último turno** (`last_turn`) contiene únicamente el texto de la pregunta del usuario en el turno actual, sin ningún contexto conversacional previo.

El modo **historial completo** (`full_history`) concatena todos los turnos del usuario hasta el turno actual, sin incluir las respuestas del agente. Incorpora el hilo de preguntas del usuario, pero no las respuestas del agente.

El modo **contexto completo** (`full_context`) incluye las respuestas del usuario y del agente, proporcionando así el contexto conversacional máximo disponible.

El modo **reescritura** (`rewrite`) contiene una versión autocontenida de la pregunta, generada automáticamente por los creadores del *benchmark* mediante el modelo Mixtral 8x7B Instruct [Katsis et al., 2025]. Los autores advierten que mejores implementaciones podrían obtenerse usando modelos más grandes.

Además de estas tres representaciones, la presente tesis evalúa un cuarto modo: una **reescritura automática propia** mediante un LLM (véase la sección 5.3.4 del capítulo 5).

4.2. Dominios especializados

MTRAG fue construido deliberadamente con cuatro dominios de características lingüísticas muy distintas. Cada dominio plantea desafíos específicos que permiten evaluar qué tan robustas son las configuraciones del *pipeline*. La Tabla 4.1 resume las estadísticas principales.

La distribución de pasajes es asimétrica (ClapNQ contiene casi cuatro veces más pasajes que Govt), la longitud promedio difiere por un factor de dos (119 vs. 236 palabras), y el número de pasajes relevantes por consulta es consistentemente bajo (2.6–3.0).

Tabla 4.1: Estadísticas descriptivas de los cuatro dominios del *benchmark* MTRAG. Se reportan el número de conversaciones, el total de turnos (consultas), el número de pasajes en el corpus, el promedio de palabras por pasaje, los turnos promedio por conversación y el número promedio de pasajes relevantes por consulta según los juicios humanos (*qrels*).

Dominio	**Convs.**	**Turnos totales**	**Pasajes corpus**	**Palabras/ pasaje**	**Turnos/ conv.**	**Rels./ consulta**
ClapNQ	29	224	183 408	119.0	7.7	2.8
Cloud	26	205	72 439	186.1	7.9	2.6
FiQA	27	199	60 984	130.2	7.4	3.0
Govt	28	214	49 607	235.8	7.6	2.6
Total	**110**	**842**	**366 438**	**167.8**	**7.7**	**2.7**

4.2.1. ClapNQ: preguntas de conocimiento general

ClapNQ (*Curation with LLM-Augmented Passage-level Natural Questions*) constituye el dominio con el corpus más grande del *benchmark*: 183 408 pasajes derivados de artículos de Wikipedia en inglés. A pesar de su carácter de "conocimiento general", el dominio no es trivial: el vocabulario extenso de Wikipedia implica alta ambigüedad léxica, los pasajes son los más cortos del *benchmark* (119 palabras en promedio), lo que reduce la señal para los modelos léxicos, y el tamaño del corpus (183 408 pasajes) incrementa la probabilidad de falsos positivos. Funciona como la línea base de conocimiento general frente a los tres dominios especializados.

4.2.2. Cloud: documentación técnica de IBM

Cloud comprende 72 439 pasajes de documentación técnica de IBM Cloud, con alta densidad de acrónimos (VPC, CDN, IAM) y nombres de productos. Los pasajes tienen estructura no narrativa (instrucciones, tablas de configuración, listas de parámetros).

4.2.3. FiQA: finanzas y regulación

FiQA comprende 60 984 pasajes de foros financieros (Reddit, StackExchange Money). Requiere precisión numérica, terminología financiera técnica (e.g. *amortization*, *capital gains*) y manejo de un estilo informal con abreviaciones y jerga. Es el dominio con mayor densidad de pasajes relevantes por consulta (3.0).

4.2.4. Govt: documentos gubernamentales

Govt comprende 49 607 pasajes de sitios gubernamentales de EE. UU., con lenguaje administrativo-legal, los pasajes más largos del *benchmark* (236 palabras en promedio) e información estructurada (tablas, formularios) convertida a texto plano.

Estas diferencias de tamaño de corpus, longitud de pasaje, densidad terminológica y estilo discursivo permiten evaluar si las configuraciones óptimas del *pipeline* se mantienen estables ante cambios de dominio, que es precisamente el objeto de PI6.

4.3. Formato BEIR y estructura de archivos

Los datos de MTRAG se encuentran disponibles en el formato BEIR [Thakur et al., 2021], lo que permite utilizar directamente las bibliotecas de evaluación existentes como *Pyserini*, *beir* y *mteb*.

Cada dominio contiene los mismos seis tipos de archivo. El corpus (`corpus.jsonl`) almacena un registro JSONL por pasaje con campos `_id`, `text` y `title`; el identificador sigue la convención `docID_inicio-fin-seccion-longitud`, que codifica la posición del fragmento dentro del documento fuente. Las consultas se distribuyen en tres variantes (*all turns*, *last turn* y *rewrite*) correspondientes a los modos descritos en la sección 4.1.4, con identificador `conversationID<::>turn`. El archivo `tasks.jsonl` contiene la representación estructurada de cada tarea (secuencia de turnos como objetos

`{speaker, text}`), utilizado para generar variantes de consulta y reconstruir el contexto conversacional (capítulo 5). Los juicios de relevancia humanos (`qrels/dev.tsv`) registran los pares consulta-pasaje con su nivel de relevancia; la sección 4.5 analiza su distribución.

La Tabla 4.2 resume esta estructura.

Tabla 4.2: Estructura de archivos del *benchmark*. Cada dominio contiene los mismos tipos de archivo con el formato BEIR estándar.

Archivo	Formato	Registros (ClapNQ)	Función
`corpus.jsonl`	JSONL	183 408	Pasajes del corpus
`*_questions.jsonl`	JSONL	224	Consultas (*all turns*)
`*_lastturn.jsonl`	JSONL	224	Consultas (*last turn*)
`*_rewrite.jsonl`	JSONL	224	Consultas reescritas
`*_tasks.jsonl`	JSONL	224	Tareas estructuradas
`qrels/dev.tsv`	TSV	578	Juicios de relevancia

4.4. Preprocesamiento e indexación del corpus

El *benchmark* MTRAG distribuye los corpus ya segmentados a nivel de pasaje; la segmentación fue realizada por los creadores del *benchmark* en IBM Research. En esta sección se documentan los parámetros de esa segmentación original, el filtrado aplicado antes de la indexación y la construcción de los índices utilizados en los experimentos.

4.4.1. Segmentación en pasajes (realizada por el *benchmark*)

Los documentos fuente de cada dominio fueron segmentados por los autores de MTRAG [Katsis et al., 2025] mediante una estrategia de ventana deslizante (*sliding window*) con los siguientes parámetros:

- **Tamaño de ventana:** 512 *tokens*.

- **Solapamiento:** 100 *tokens* entre ventanas consecutivas.

Estos parámetros se verificaron a partir de los identificadores de pasaje del corpus (`docID_inicio-fin-seccion-longitud`), que codifican la posición y longitud de cada fragmento. El tamaño de ventana de 512 *tokens* es compatible con la longitud máxima de entrada de los modelos de *embeddings* evaluados (BGE-base-v1.5: 512, BGE-M3: 8 192, Voyage: 4 096; SPLADE ~256 efectivos).

4.4.2. Filtrado y limpieza de texto

Antes de la indexación, el único filtro que se aplicó sobre los pasajes proporcionados por el *benchmark* fue la **eliminación de pasajes vacíos**. Se descartaron los registros cuyo campo `text` estaba vacío o contenía únicamente espacios en blanco. El análisis de sanidad del corpus detectó 3 pasajes vacíos en Cloud (72 442 → 72 439) y 38 en FiQA (61 022 → 60 984); ClapNQ y Govt no presentaron pasajes vacíos. Los recuentos de la Tabla 4.1 reflejan los totales tras este filtrado. No se aplico normalización adicional como conversión a minúsculas ni eliminación de caracteres especiales.

En consecuencia, los modelos de recuperación recibieron el texto en un estado muy cercano al original, delegando la normalización a cada modelo (tokenización interna de BM25, codificación de subpalabras en los modelos densos).

4.4.3. Construcción de índices

Para cada dominio se construyeron índices independientes para cada uno de los modelos de recuperación evaluados en la tesis. Los tipos de índice utilizados se describen a continuación:

1. **Índice invertido (BM25).** Se construyó un índice invertido con los parámetros $k_1 = 1.2$ y $b = 0.75$ [Robertson et al., 1995]. El índice almacena las frecuencias de términos y las estadísticas de colección necesarias para el cálculo de la puntuación BM25.

2. **Índice disperso (SPLADE).** Se generaron representaciones dispersas expandidas mediante el modelo SPLADE [Formal et al., 2022] y se almacenaron en formato `.npz` (*compressed sparse matrix*). A diferencia del índice BM25, el índice SPLADE contiene pesos de términos aprendidos que incluyen tanto los términos originales como los términos expandidos por el modelo.

3. **Índice denso (FAISS).** Se codificaron los pasajes mediante modelos de *embeddings* densos (BGE-base-v1.5 de 768 dimensiones, BGE-M3 de 1 024 dimensiones y Voyage de 1 024 dimensiones) y se almacenaron en índices FAISS (*Facebook AI Similarity Search*) [Johnson et al., 2021] con búsqueda exacta por producto interno.

La Tabla 4.3 presenta el tamaño en disco de cada índice por dominio. Se observa que los índices densos son entre cuatro y seis veces más grandes que los índices léxicos, lo que refleja el costo de almacenar un vector de alta dimensionalidad por pasaje en lugar de una lista invertida de términos. El tamaño total de los índices para los cuatro dominios asciende a aproximadamente 6.3 GB, lo que los hace manejables para ejecución en una estación de trabajo con GPU.

Tabla 4.3: Tamaño en disco (MB) de los índices de recuperación por dominio y modelo de representación.

Modelo	ClapNQ	Cloud	FiQA	Govt	Total
BM25	137	90	53	74	354
SPLADE	156	56	55	49	316
BGE-base	811	320	269	219	1 619
Voyage	870	400	287	287	1 844
BGE-M3	1 100	426	358	292	2 176
Total	**3 074**	**1 292**	**1 022**	**921**	**6 309**

Cabe destacar que el dominio ClapNQ, con el corpus más extenso (183 408 pasajes), concentra el 49 % del espacio total de índices, lo que ilustra la relación

directa entre el tamaño del corpus y el costo de almacenamiento.

4.5. Criterios de inclusión y juicios de relevancia

La evaluación de la calidad de la recuperación requiere juicios de relevancia confiables. En esta sección se describen los criterios de anotación empleados en MTRAG, la distribución de los juicios y las implicaciones para las métricas de evaluación.

4.5.1. Esquema de anotación

Los juicios de relevancia de MTRAG fueron realizados por anotadores humanos de IBM Research que participaron en la construcción del *benchmark* [Katsis et al., 2025]. Se empleó un esquema de relevancia **binaria**. Los archivos *qrels* registran los pares consulta-pasaje considerados relevantes (*score* = 1); para efectos de evaluación con `pytrec_eval`, los pasajes no listados se tratan como no relevantes (*score* = 0).

La elección de un esquema binario, en contraposición a un esquema graduado (con niveles de relevancia como 0, 1, 2, 3, como en TREC CAsT), simplifica la tarea de anotación y reduce la variabilidad inter-anotador, a costa de perder la distinción entre documentos parcialmente relevantes y completamente relevantes.

4.5.2. Distribución de los juicios de relevancia

La Tabla 4.4 presenta la distribución de los juicios de relevancia por dominio. En total, se anotaron **2 128 pares relevantes** distribuidos entre **777 consultas** únicas con al menos un pasaje relevante. El número promedio de pasajes relevantes por consulta oscila entre 2.59 (Govt) y 2.97 (FiQA), con un promedio global de 2.74.

La densidad de relevancia, del orden de 10^{-3} %, hace evidente la dispersión extrema: en ClapNQ, el sistema debe identificar 2.78 pasajes relevantes entre

Tabla 4.4: Distribución de los juicios de relevancia por dominio. Se reportan las consultas con al menos un pasaje relevante, el total de pares relevantes y el promedio de pasajes relevantes por consulta.

Dominio	**Consultas**	**Pares rel.**	**Prom. rel./consulta**	**Densidad rel.**
ClapNQ	208	578	2.78	3.15×10^{-3} %
Cloud	188	494	2.63	3.63×10^{-3} %
FiQA	180	535	2.97	4.87×10^{-3} %
Govt	201	521	2.59	5.23×10^{-3} %
Total	**777**	**2 128**	**2.74**	—

183 408 candidatos. La moda del número de pasajes relevantes por consulta se ubica en dos o tres en los cuatro dominios, lo que hace de nDCG@10 una métrica adecuada: pondera la posición de cada pasaje recuperado y penaliza de manera logarítmica la ubicación en posiciones inferiores.

En conjunto, estas propiedades hacen de MTRAG un escenario adecuado para evaluar no solo la efectividad promedio de los modelos de recuperación, sino también su robustez ante dominios heterogéneos, consultas dependientes del contexto y baja proporción en la cantidad de documentos a recuperar vs el total de documentos. El Apéndice A ofrece ejemplos de conversaciones del *benchmark* y comparaciones de reescrituras. El siguiente capítulo describe el diseño experimental utilizado.

Capítulo 5

Metodología

> "All models are wrong, but some are useful."
>
> George E. P. Box

Este capítulo documenta el diseño experimental, la implementación del *pipeline* y el protocolo estadístico. El diseño adoptado es OFAT (*One-Factor-at-a-Time*); las secciones siguientes definen el espacio de variables, especifican los modelos y parámetros exactos, escriben el marco estadístico y las medidas de reproducibilidad.

5.1. Diseño experimental de ablación controlada (OFAT)

El diseño adoptado es la **ablación controlada un-factor-a-la-vez** (OFAT) [Bosch, 2010]: se parte de una configuración base del *pipeline* y se modifica una única variable independiente por estudio, comparando estadísticamente contra una línea base. La elección de OFAT sobre un factorial completo se justifica por tres razones: (i) el espacio experimental tiene siete grados de libertad, cuyo cruce genera 7×4×4×4×5×4×7 = 62,720 configuraciones por dominio; (ii) cada diferencia

observada es directamente atribuible al factor manipulado, y (iii) este esquema refleja la evaluación típica de *pipelines* RAG en la industria. La principal limitación es la incapacidad de capturar interacciones entre factores, lo cual discutiremos más adelante en el capítulo 6.

5.2. Definición de variables

A continuación, se introducen las variables bajo estudio y sus respectivas configuraciones.

5.2.1. Variables independientes y niveles experimentales

Las variables independientes corresponden a los componentes configurables del *pipeline* de recuperación. La Tabla 5.1 resume cada variable, los niveles evaluados y el estudio de ablación asociado.

Tabla 5.1: Variables independientes del diseño experimental. Cada variable se evalúa en un estudio de ablación dedicado, manteniendo constantes las demás. *n* indica la cantidad de configuraciones.

Variable	**EA**	**Niveles evaluados**	*n*
Modelo de recuperación	EA1	BM25, SPLADE, BGE-1.5, BGE-M3, Voyage, Híbrido S+B, Híbrido S+V	7
Operador de fusión	EA2	RRF (k=60), Lineal α=0.3, 0.5, 0.7	4
Modo de consulta	EA3	Último turno, historial completo, contexto completo, reescritura GT	4
Modelo de reescritura	EA4	GT, Flan-T5 (local), Command-R (réplica), *few-shot* mejorado	4
Parámetro k de RRF	EA5	$k \in \{1, 20, 40, 60, 100\}$	5
Profundidad de recuperación	EA6	top-$k \in \{100, 200, 300, 500\}$	4
Profundidad de *reranking*	EA7	Sin *reranking*; BGE-rr a profundidad $\{50, 100, 200\}$; Cohere a profundidad $\{50, 100, 200\}$, evaluado sobre dos bases: SPLADE+BGE-1.5 y SPLADE+Voyage	7[c]

[c] 7 niveles por base; 14 condiciones en total (véase la sección 5.2.3).

En total, el diseño suma **42 condiciones estudio–base–nivel**: 28 condiciones correspondientes a EA1–EA6 y 14 condiciones en EA7 (7 configuraciones de *reranking* evaluadas sobre dos bases de primera etapa). Ejecutadas en los cuatro dominios, producen **168 ejecuciones** experimentales.

5.2.2. Variables dependientes (métricas de evaluación)

Todas las métricas se calculan con `pytrec_eval` [Van Gysel and de Rijke, 2018]. La métrica principal es **nDCG@10**, por su sensibilidad al orden de los documentos relevantes. **Recall@100** se utiliza como métrica de cobertura para el *reranking*, **MRR** como indicador de la posición del primer documento relevante, y las métricas complementarias (nDCG@5, nDCG@20, Recall@5/10/20, MAP@10, P@5/10, Success@k) para análisis de robustez.

5.2.3. Variables de control

Para cada estudio de ablación, las variables no manipuladas se fijan en los valores de la **configuración base**. Esta configuración se definió a partir de evidencia preliminar del sistema IIMAS-RAG y de criterios prácticos de desempeño observados antes del análisis estadístico formal.

- **Recuperadores:** SPLADE (`naver/splade-cocondenser-ensembledistil`) + Voyage (`voyage-3-large`), fusión RRF con $k = 60$.
- **Profundidad de recuperación:** top-300 candidatos por recuperador.[1]
- **Modo de consulta:** reescritura de los organizadores. [2]
- **Reranking:** desactivado (salvo en EA7, donde es la variable manipulada).
- **Corpus y juicios de relevancia:** los proporcionados por MTRAG.
- **Semilla aleatoria:** 42 (fija para todos los componentes estocásticos).

La excepción es EA7: para evaluar H4a (ganancia del *reranking* con margen de mejora) se usa SPLADE + BGE-1.5 como base; para evaluar H4b (rendimientos decrecientes sobre una base fuerte) se añade SPLADE + Voyage como segunda base. Esto permite probar ambas hipótesis dentro del mismo estudio.[3]

[1] Los resultados muestran que pasar de top-300 a top-200 o top-500 produce cambios nulos en nDCG@5 en todos los dominios (sin significancia estadística tras corrección Holm-Bonferroni). Por ello, top-300 se fija como el equilibrio óptimo entre cobertura y costo computacional.

[2] Se utiliza la reescritura de los organizadores (GT) como control. El reescritor propio Command-R réplica es estadísticamente equivalente al GT (diferencia no significativa en 3 de 4 dominios), pero introducirlo como control añadiría una dependencia a decisiones de implementación propias.

[3] SPLADE + BGE-1.5 es la combinación de menor desempeño entre las bases exploradas, por lo que es una área de oportunidad para que el *reranking* muestre ganancia (H4a). SPLADE + Voyage es la configuración de primera etapa más fuerte, donde cualquier mejora adicional sería más difícil de obtener (H4b).

5.3. Arquitectura del *pipeline* de recuperación

La Figura 5.1 ilustra la arquitectura del *pipeline*. La consulta se transforma según el modo seleccionado, se envía en paralelo a los recuperadores, sus resultados se fusionan y, opcionalmente, se aplica *reranking*. Los modelos, versiones y parámetros exactos se detallan en las tablas de esta sección.

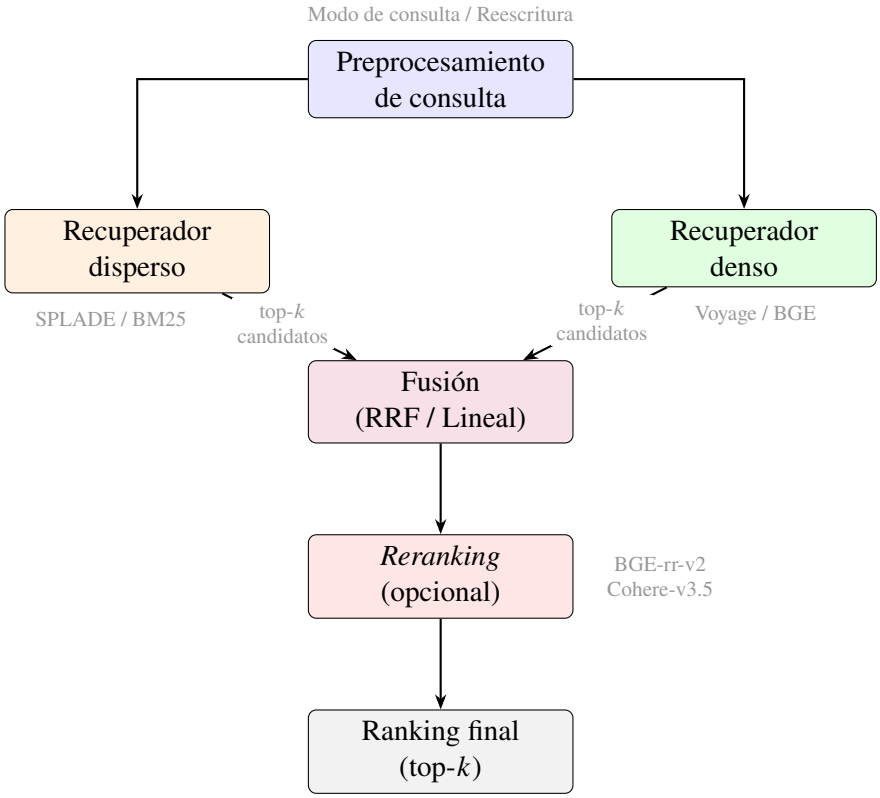


Figura 5.1: Arquitectura del *pipeline* de recuperación implementado. La consulta se procesa según el modo seleccionado, luego se envía en paralelo a un recuperador disperso y uno denso, cuyos resultados se fusionan mediante RRF o interpolación lineal. Opcionalmente, un modelo de *reranking* reordena los candidatos fusionados antes de producir el ranking final.

5.3.1. Preprocesamiento de consultas

Se implementaron cuatro modos: **último turno** (`last_turn`), **historial completo** (`all_turns`, solo intervenciones del usuario), **contexto completo** (`full_context`, usuario y agente), y **reescritura** (`rewrite`, versión de los organizadores y propia). En todos los estudios excepto EA3 y EA4 el modo se fija en el `rewrite` de los organizadores.

5.3.2. Módulos de recuperación

Se evaluaron cinco modelos de recuperación de primera etapa, agrupados en tres paradigmas. La Tabla 5.2 detalla cada modelo con su versión exacta, dimensión de representación, tipo de similitud y los parámetros de ejecución utilizados.

Tabla 5.2: Modelos de recuperación de primera etapa. Se indican la versión exacta, la dimensionalidad de la representación, la función de similitud utilizada y el tamaño de lote (*batch size*) para la codificación de consultas.

Modelo	Identificador / versión	Dim.	Similitud	Batch
BM25	`rank_bm25` (BM25Okapi, k_1=1.2, b=0.75)	—	Léxica	—
SPLADE	`naver/splade-cocondenser-ensembledistil`	Vocab	Prod. interno	64
BGE-1.5	`BAAI/bge-base-en-v1.5`	768	Coseno	128
BGE-M3	`BAAI/bge-m3`	1 024	Coseno	128
Voyage	`voyage-3-large` (API VoyageAI)	1 024	Coseno	API

Los índices se construyeron por dominio: BM25 en memoria (`rank_bm25`), SPLADE en formato `.npz` (producto interno exacto) y los modelos densos en FAISS (`IndexFlatIP`, representaciones L2-normalizadas). La profundidad por defecto es top-300 (variable en EA6).

5.3.3. Fusión de resultados

Cuando se utiliza una configuración híbrida, los *rankings* individuales se combinan mediante uno de dos operadores. La **fusión por rango recíproco** (RRF) asigna a cada documento el puntaje $\mathrm{RRF}(d) = \sum_{r \in R} \frac{1}{k + \mathrm{rank}_r(d)}$, donde k es un parámetro de suavizado fijado en 60 por defecto y variado en EA5. La **interpolación lineal** normaliza las puntuaciones de cada recuperador al rango $[0, 1]$ mediante normalización min-max por consulta y calcula $s(d) = \alpha \cdot s_{\mathrm{sparse}}(d) + (1 - \alpha) \cdot s_{\mathrm{dense}}(d)$; el parámetro α se evalúa en EA2 con tres valores $\{0.3, 0.5, 0.7\}$. En todos los estudios excepto EA2, el operador de fusión se fija en RRF con $k = 60$, que es la configuración por defecto en sistemas de producción como Elasticsearch 8.8.

5.3.4. Reescritura de consultas

Para el estudio EA4, se implementaron tres estrategias de reescritura automática que se comparan contra la reescritura de los organizadores de referencia. La Tabla 5.3 presenta los modelos y sus características.

Tabla 5.3: Modelos de reescritura de consultas evaluados en EA4. Se indica el modelo exacto, el tipo de ejecución (local o API), el costo estimado por cada 1 000 consultas y la estrategia de *prompting*.

Reescritor	**Modelo**	**Ejecución**	**Costo**	**Estrategia**
Organizadores (GT)	—	Dataset	\$0.00	reescritura automática de referencia provista por MTRAG
Flan-T5	`google/flan-t5-large`	Local (GPU)	\$0.00	*Prompt* de condensación: resolver correferencias y producir una consulta autocontenida
Command-R réplica	Cohere Command-R	API	\$0.50/1K	*Prompt* que replica el estilo de reescritura del *benchmark* original
Few-shot mejorado	Cohere Command-R	API	\$0.50/1K	Prompt reformulado con reglas de preservación de vocabulario técnico por dominio (Cloud, FiQA) más 3 ejemplos GT seleccionados automáticamente por similitud

Los *prompts* completos se reportan en el Apéndice B.

5.3.5. *Reranking*

La etapa de *reranking* reordena los candidatos recuperados en la primera etapa. Se evaluaron dos modelos, detallados en la Tabla 5.4.

Tabla 5.4: Modelos de *reranking* evaluados en EA7. Se indica la versión exacta, el tipo de ejecución, la precisión numérica y el tamaño de lote.

Modelo	Identificador / versión	Ejecución	Precisión	Batch
BGE-rr-v2	`BAAI/bge-reranker-v2-m3`	Local (GPU)	FP16	32
Cohere-v3.5	`rerank-v3.5`	API (Cohere)	—	API

El *reranker* reordena los primeros n candidatos de la etapa de fusión ($n \in \{50, 100, 200\}$). Para Cohere se usa `max_chunks_per_doc = 10`.

5.4. Protocolo experimental: estudios de ablación

Esta sección define, para cada uno de los siete estudios de ablación, la variable manipulada, los niveles evaluados, la línea base y la hipótesis correspondiente.

5.4.1. Tabla maestra de ablaciones

La Tabla 5.5 proporciona una vista panorámica de los siete estudios.

Tabla 5.5: Tabla maestra de los siete estudios de ablación. Cada fila corresponde a un estudio completo. Las columnas *Variable* y *Niveles* definen el factor manipulado; *Config. fija* indica qué permanece constante; *Línea base* es la condición de referencia para las pruebas pareadas; *PI/H* vincula el estudio con las preguntas de investigación e hipótesis.

EA	Objetivo	Variable	Niveles evaluados	Config. fija	Línea base	PI/H
1	Comparar recuperadores base	Modelo de recuperación	BM25, SPLADE, BGE-1.5, BGE-M3, Voyage, Híbrido S+B, Híbrido S+V	Reescritura GT, sin *reranking*	Mejor recuperador individual por dominio	PI1, H1
2	Comparar operadores de fusión	Método de fusión	RRF (k=60), Lineal $\alpha \in \{0.3, 0.5, 0.7\}$	SPLADE + Voyage, top-300, reescritura GT	RRF (k=60)	PI1, H1
3	Evaluar modos de consulta	Modo de consulta	Último turno, historial completo, contexto completo, reescritura GT	SPLADE + Voyage, RRF k=60, top-300	Último turno	PI2, H2
4	Evaluar reescritura automática	Modelo de reescritura	GT, Flan-T5, Command-R réplica, *few-shot* mejorado	SPLADE + Voyage, RRF k=60, top-300	GT	PI2‡
5	Sensibilidad de k en RRF	Parámetro k	$k \in \{1, 20, 40, 60, 100\}$	SPLADE + Voyage, top-300, reescritura GT	$k = 60$	PI3, H3
6	Sensibilidad de profundidad	top-k candidatos	$\{100, 200, 300, 500\}$	SPLADE + Voyage, RRF k=60, reescritura GT	top-300	PI1
7	Evaluar *reranking*	Configuración de *reranking*†	Sin *reranking*; BGE-rr a $\{50, 100, 200\}$; Cohere a $\{50, 100, 200\}$	SPLADE + BGE-1.5 (H4a) y SPLADE + Voyage (H4b), RRF k=60, top-300, reescritura GT	Sin *reranking*	PI4, H4a, H4b

†EA7 trata la combinación modelo × profundidad como un único factor "configuración de *reranking*" con siete niveles (incluyendo la ausencia de *reranking*), evaluado sobre dos bases de primera etapa (SPLADE + BGE-1.5 para H4a y SPLADE + Voyage para H4b) para separar el efecto del *reranking* según el nivel de calidad inicial. ‡EA3 evalúa directamente H2 al comparar el último turno contra la reescritura de los organizadores. EA4 no prueba H2 de forma independiente, sino que busca medir la diferencia entre una reescritura propia y la proporcionada por los organizadores.

5.4.2. Matriz de cobertura del espacio experimental

El diseño OFAT garantiza que cada estudio de ablación modifica un solo eje del *pipeline* mientras mantiene fijos los demás. La Figura 5.2 explica visualmente

este diseño.

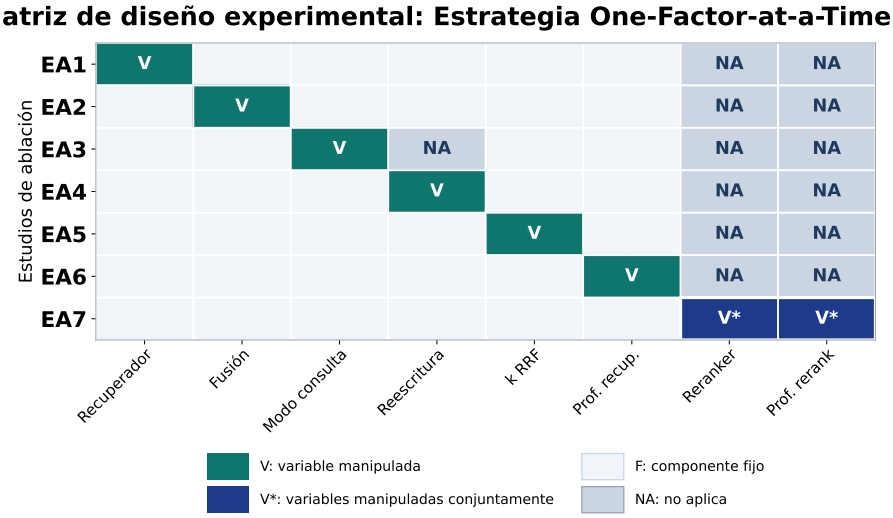


Figura 5.2: Mapa de calor de la estructura OFAT del diseño experimental. El color turquesa oscuro indica variables manipuladas (V), el azul oscuro indica variables compuestas manipuladas en conjunto (V*), el blanco indica componentes mantenidos fijos (F), y el azul claro los componentes no aplicables (NA) en cada estudio de ablación.

La Figura 5.2 muestra que EA1–EA6 manipulan un único eje del *pipeline*; EA7 es la excepción, ya que, evalúa la combinación modelo–profundidad sobre dos bases de primera etapa.

5.4.3. Protocolo de comparaciones pareadas

Las comparaciones pareadas toman cada condición contra la línea base correspondiente en cada dominio. EA1 produce **8 pruebas principales para H1** (dos híbridos contra el mejor recuperador individual por dominio); EA2, EA3, EA4 y EA6 producen 12; EA5 produce 16; y EA7 produce 48 (24 por base). Todas emplean Wilcoxon pareado con corrección Holm-Bonferroni ($\alpha = 0.05$); el criterio de aceptación es efecto significativo con $|\delta| > 0.147$ en al menos tres de cuatro dominios para demostrar generalización y robustez en todo tipo de datos.

5.5. Infraestructura, instrumentos y herramientas computacionales

Los experimentos se ejecutaron en una estación de trabajo con la configuración que se detalla en la Tabla 5.6.

Tabla 5.6: Especificaciones de la infraestructura utilizada para la ejecución de los experimentos.

Componente	**Especificación**
GPU	NVIDIA RTX 4090 (24 GB VRAM)
CPU	16 núcleos (hilos)
RAM	128 GB
Almacenamiento	~100 GB (índices + modelos + resultados)
Sistema operativo	Linux (contenedor Docker)
Imagen base	PyTorch 2.0, CUDA 12.1
Lenguaje	Python 3.11
Orquestación	Docker Compose

Las principales bibliotecas y servicios utilizados son:

- **Recuperación:** `rank_bm25` (BM25Okapi), `transformers` (SPLADE), `sentence-transformers` (BGE-1.5, BGE-M3), `voyageai` (Voyage API), `faiss-gpu` (indexación y búsqueda densa).
- **Reranking:** `FlagEmbedding` (BGE-reranker), `cohere` (API de *reranking*).
- **Reescritura:** `transformers` (Flan-T5), `cohere` (Command-R API).
- **Evaluación:** `pytrec_eval` [Van Gysel and de Rijke, 2018] para todas las métricas de recuperación.
- **Análisis estadístico:** `scipy.stats` (Wilcoxon), implementación propia de Cliff's δ, corrección Holm-Bonferroni e intervalos de confianza bootstrap.

- **Servicios externos (API):** VoyageAI (recuperación densa), Cohere (*reranking* y reescritura).

La Tabla 5.7 resume los costos de los servicios de API utilizados, que constituyen el principal componente de costo variable del *pipeline*.

Tabla 5.7: Costo estimado de los servicios de API por cada 1 000 consultas procesadas. Precios consultados en enero de 2026. Los modelos locales no tienen costo de API; el costo de infraestructura GPU no se incluye en esta tabla.

Servicio	**Componente**	**Costo/1K consultas**
VoyageAI (`voyage-3-large`)	Recuperación densa	\$0.12
Cohere (`rerank-v3.5`)	*Reranking*	\$1.00
Cohere (Command-R)	Reescritura	\$0.50
Modelos locales (BM25, SPLADE, BGE, Flan-T5)	Varios	\$0.00 (API)

Los detalles de dependencias y la organización de los archivos de configuración se documentan en el Apéndice C.

5.6. Análisis estadístico

El análisis estadístico se diseñó para responder tres preguntas sobre cada estudio de ablación: (1) ¿la diferencia observada es estadísticamente significativa?, (2) ¿cuál es la magnitud de la diferencia?, y (3) ¿los resultados son consistentes entre dominios? Cada pregunta se aborda con una herramienta estadística específica.

5.6.1. Pruebas de hipótesis y corrección de comparaciones múltiples

Las métricas de recuperación (nDCG@10, Recall, MRR) no siguen en general una distribución normal, como han documentado Benavoli et al. [2016]. Por esta razón, se utiliza la **prueba de rangos con signo de Wilcoxon** [Wilcoxon, 1945] como prueba de hipótesis principal, que no requiere supuestos distribucionales.

La prueba se aplica de manera **pareada por consulta**: para cada par de sistemas (A, B) y cada dominio, se calcula la diferencia $d_i = \text{nDCG@10}_A(q_i) - \text{nDCG@10}_B(q_i)$ para cada consulta q_i del dominio, y se evalúa la hipótesis nula $H_0 : \text{mediana}(d) = 0$.

Dado que cada estudio involucra entre 12 y 48 comparaciones, se aplica la **corrección de Holm-Bonferroni** [Holm, 1979]. Este es un procedimiento secuencial descendente conocido por ser menos conservador que el método de Bonferroni clásico, lo que permite controlar la tasa de error por familia (FWER) al nivel $\alpha = 0.05$.

5.6.2. Tamaño del efecto e intervalos de confianza

Para cuantificar la magnitud práctica de las diferencias se utiliza δ de Cliff [Cliff, 1993], que opera sobre rangos ordinales (compatible con Wilcoxon) y oscila entre -1 y $+1$. Los umbrales estándar [Romano et al., 2006] son: $|\delta| < 0.147$ (negligible), < 0.33 (pequeño), < 0.474 (mediano), ≥ 0.474 (grande). Adicionalmente, se calculan intervalos de confianza al 95 % sobre la diferencia media de nDCG@10 mediante *bootstrap* percentil con 10 000 remuestreos.

5.6.3. Concordancia inter-dominio

Para evaluar la consistencia entre dominios (PI6), se calcula el coeficiente τ de Kendall [Kendall, 1938] sobre los *rankings* de sistemas (por nDCG@10) para cada par de dominios. Se reporta el τ promedio sobre los $\binom{4}{2} = 6$ pares por estudio ($\tau = 1$: concordancia perfecta; $\tau = 0$: independencia).

5.6.4. Frontera de Pareto

Para responder a PI5 (compromiso calidad-latencia-costo), se construye la **frontera de Pareto** tridimensional sobre las 42 condiciones evaluadas. Para EA7, cada combinación base–configuración se trata como una condición independiente

en el espacio Pareto. Las tres dimensiones son:

1. **Calidad:** nDCG@10 promedio sobre los cuatro dominios (a maximizar).
2. **Latencia:** percentil 50 de la latencia por consulta, promediada sobre dominios (a minimizar).
3. **Costo:** costo estimado por 1 000 consultas, calculado como la suma de los costos de los componentes de API de cada configuración (a minimizar).

Una configuración se dice **Pareto-dominada** si existe otra configuración que es al menos tan buena en las tres dimensiones y estrictamente mejor en al menos una. La frontera de Pareto está formada por las configuraciones no dominadas.

5.7. Aspectos éticos y privacidad

Los datos provienen del *benchmark* MTRAG [Katsis et al., 2025], publicado por IBM Research para fines de investigación. Los cuatro corpus son de dominio público (Wikipedia, documentación IBM Cloud, foros financieros, sitios web gubernamentales de EE.UU.) y las conversaciones fueron creadas por anotadores contratados por IBM Research. Este trabajo no recopiló datos personales, no condujo experimentos con participantes humanos y utilizó los servicios de API externos únicamente para procesar consultas derivadas del *benchmark* público.

Capítulo 6

Evaluación y Resultados

> "The goal is to turn data into information, and information into insight."
>
> Carly Fiorina

Los resultados de los siete estudios de ablación (EA1–EA7) se presentan en este capítulo. Para cada estudio se reportan los valores de nDCG@10 por dominio, las pruebas de significancia estadística (Wilcoxon con corrección Holm-Bonferroni), el tamaño del efecto (Cliff's δ) y los intervalos de confianza *bootstrap* al 95 %. Se realizan tres análisis transversales: la concordancia inter-dominio (Kendall τ), la frontera de Pareto calidad–latencia–costo y un análisis cualitativo de errores.

Notación. En todas las tablas: $^{***}\ p_{\text{adj}} < 0.001$, $^{**}\ p_{\text{adj}} < 0.01$, $^{*}\ p_{\text{adj}} < 0.05$; (N) negligible, (S) pequeño, (M) mediano, (L) grande (según Cliff's δ).

6.1. EA1: Comparación de modelos de recuperación

EA1 compara siete configuraciones de recuperación (cinco modelos individuales y dos sistemas híbridos) para dar respuesta a PI1: ¿la fusión híbrida supera al mejor

modelo individual?

Las 8 pruebas pareadas principales para H1 comparan los dos sistemas híbridos (Híbrido S+B e Híbrido S+V) contra el mejor modelo individual en cada uno de los cuatro dominios. La tabla de resultados usa Voyage como referencia porque es el modelo denso con mayor rendimiento promedio en la exploración previa; sin embargo, en dominios donde SPLADE supera a Voyage (Cloud y FiQA), la línea base efectiva para H1 es SPLADE.

6.1.1. Resultados principales

La Tabla 6.1 presenta los valores de nDCG@10 por dominio y la media aritmética.

Tabla 6.1: EA1 — nDCG@10 por dominio para los siete modelos de recuperación evaluados. Los valores en **negrita** indican el mejor resultado por columna. La línea base para H1 es el mejor individual por dominio.

Sistema	ClapNQ	Cloud	FiQA	Govt	Media	Δ vs. Voyage
BM25	0.247	0.217	0.128	0.307	0.225	−0.183
BGE-M3	0.429	0.288	0.272	0.339	0.332	−0.076
Voyage (base)	0.522	0.355	0.311	0.446	0.408	—
BGE-1.5	0.498	0.379	0.350	0.428	0.414	+0.006
SPLADE	0.524	0.428	0.392	0.483	0.457	+0.049
Híbrido S+B	0.552	0.438	0.406	0.497	0.473	+0.065
Híbrido S+V	**0.563**	**0.451**	**0.442**	**0.534**	**0.497**	+0.089

Lo primero que llama la atención es la jerarquía de los paradigmas. BM25 (*léxico puro*) obtiene la puntuación más baja en todos los dominios (media 0.225). Los modelos neuronales individuales (BGE-M3, Voyage, BGE-1.5, SPLADE) se sitúan en el rango 0.332–0.457, con SPLADE como el mejor modelo individual. Finalmente, los sistemas híbridos ocupan las posiciones más altas, y el Híbrido S+V (SPLADE + Voyage, fusionados con RRF) alcanza una media de **0.497**, lo que representa una mejora de +0.089 sobre Voyage y de +0.040 sobre SPLADE.

6.1.2. Significancia estadística

La Tabla 6.2 resume las pruebas pareadas (Wilcoxon, corrección Holm-Bonferroni). Se muestran todas las comparaciones contra Voyage más los resultados de las 8 pruebas principales para H1.

Tabla 6.2: EA1 — Pruebas pareadas contra Voyage. Se reporta la diferencia media (Δ), la significancia tras corrección Holm-Bonferroni y el tamaño del efecto (Cliff's δ). N = negligible, S = pequeño, M = mediano.

Sistema	**Dominio**	Δ	$p_{\mathbf{adj}}$	δ	**Efecto**
BM25	ClapNQ	−0.274	$< 0.001^{***}$	−0.437	M
	Cloud	−0.138	$< 0.001^{***}$	−0.231	S
	FiQA	−0.183	$< 0.001^{***}$	−0.362	M
	Govt	−0.139	$< 0.001^{***}$	−0.215	S
SPLADE	ClapNQ	+0.002	1.000	+0.006	N
	Cloud	+0.073	0.006^{**}	+0.114	N
	FiQA	+0.081	0.010^{**}	+0.137	N
	Govt	+0.038	0.417	+0.056	N
BGE-1.5	ClapNQ	−0.023	0.396	−0.045	N
	Cloud	+0.024	1.000	+0.042	N
	FiQA	+0.039	0.307	+0.063	N
	Govt	−0.018	1.000	−0.028	N
BGE-M3	ClapNQ	−0.093	$< 0.001^{***}$	−0.152	S
	Cloud	−0.067	0.046^{*}	−0.100	N
	FiQA	−0.039	0.396	−0.075	N
	Govt	−0.107	$< 0.001^{***}$	−0.165	S
Híbrido S+B	ClapNQ	+0.030	0.396	+0.046	N
	Cloud	+0.083	$< 0.001^{***}$	+0.139	N
	FiQA	+0.095	$< 0.001^{***}$	+0.174	S
	Govt	+0.051	0.098	+0.080	N
Híbrido S+V	ClapNQ	+0.041	0.003^{**}	+0.074	N
	Cloud	+0.096	$< 0.001^{***}$	+0.146	N
	FiQA	+0.131	$< 0.001^{***}$	+0.241	S
	Govt	+0.089	$< 0.001^{***}$	+0.133	N

BM25 queda **significativamente por debajo** en los cuatro dominios (efectos medianos en ClapNQ y FiQA), evidenciando que la coincidencia léxica exacta no es la mejor opción para el escenario multi-turno. BGE-1.5 y Voyage son

estadísticamente indistinguibles. El Híbrido S+V supera a Voyage en los cuatro dominios ($p_{\text{adj}} \leq 0.003$), con la mayor ganancia en FiQA ($\Delta = +0.131$). SPLADE supera significativamente a Voyage en Cloud y FiQA, lo que sugiere que la recuperación dispersa aprendida aporta valor en dominios específicos, aunque no de forma generalizada.

La Tabla 6.3 muestra la comparación pareada directa entre el Híbrido S+V y SPLADE (mejor recuperador individual) por dominio, usando Wilcoxon con corrección Holm-Bonferroni (familia de 4 comparaciones).

Tabla 6.3: EA1 — Comparación pareada directa entre el Híbrido S+V y SPLADE por dominio. Se reportan la diferencia media (Δ), el p_{adj} (Holm-Bonferroni) y el tamaño del efecto (Cliff's δ).

Dominio	**Δ (S+V−SPLADE)**	**p_{adj}**	**δ**	**Efecto**
ClapNQ	+0.039	0.001^{**}	+0.072	N
Cloud	+0.023	0.023^{*}	+0.039	N
FiQA	+0.050	0.001^{**}	+0.097	N
Govt	+0.051	$< 0.001^{***}$	+0.084	N

Estos resultados **confirman H1**: el Híbrido S+V supera significativamente a SPLADE en los cuatro dominios ($p_{\text{adj}} \leq 0.023$), con ganancias de +0.023 a +0.051 puntos de nDCG@10. El tamaño del efecto es **negligible** en los cuatro casos ($|\delta| < 0.147$), lo que indica una mejora consistente pero de magnitud pequeña.

6.2. EA2: Operadores de fusión

El segundo estudio compara RRF ($k = 60$) contra interpolación lineal con tres valores de α (0.3, 0.5 y 0.7), sobre el *pipeline* Híbrido S+V. La Tabla 6.4 muestra los valores de nDCG@10 por dominio.

RRF supera a las salidas obtenidas con fusión lineal en ≈0.040 puntos; 9 de 12 pruebas son significativas, aunque todos los efectos son **negligibles** ($|\delta| < 0.10$). Entre las variantes lineales, α=0.3 muestra una ligera ventaja numérica frente

Tabla 6.4: EA2 — nDCG@10 por dominio para los operadores de fusión. Las tres variantes de interpolación lineal producen resultados prácticamente idénticos. La línea base es RRF ($k = 60$).

Fusión	ClapNQ	Cloud	FiQA	Govt	Media
RRF k=60 (base)	**0.563**	**0.451**	**0.442**	**0.534**	**0.497**
Lineal α=0.3	0.524	0.431	0.392	0.486	0.458
Lineal α=0.5	0.524	0.428	0.392	0.483	0.457
Lineal α=0.7	0.524	0.428	0.392	0.483	0.457

a α=0.5/0.7 en algunos dominios, pero las diferencias entre variantes de α son pequeñas y no modifican la conclusión central: en este escenario, RRF se mantiene como la opción más robusta.

6.3. Impacto de las estrategias de consulta y reescritura

Los estudios EA3 y EA4 evalúan cómo llega la consulta del usuario a los recuperadores: EA3 varía el *modo* de construir la consulta (qué información del historial se incluye) y EA4 compara modelos de reescritura automática propios contra la reescritura hecha por los organizadores.

6.3.1. EA3: Modos de consulta

Se evaluaron cuatro modos: último turno (línea base), historial completo, contexto completo y reescritura de los organizadores (*ground truth*, GT). La Tabla 6.5 presenta los resultados por dominio.

EA3 produce el resultado más contundente de toda la investigación. De 12 pruebas, **10 son significativas**:

- **El historial completo degrada notablemente el rendimiento.** Concatenar todos los turnos previos produce una caída de −0.154 a −0.201 en nDCG@10

Tabla 6.5: EA3 — nDCG@10 por dominio para los cuatro modos de consulta. El historial completo y el contexto completo producen resultados idénticos. La línea base es el último turno.

Modo de consulta	ClapNQ	Cloud	FiQA	Govt	Media
Historial completo	0.334	0.233	0.194	0.321	0.270
Contexto completo	0.334	0.233	0.194	0.321	0.270
Último turno (base)	0.532	0.435	0.374	0.475	0.454
Reescritura GT	**0.563**	**0.451**	**0.442**	**0.534**	**0.497**

respecto al último turno, con efectos **pequeños** (δ entre -0.221 y -0.330) en los cuatro dominios. Este resultado muestra que los recuperadores se confunden cuando reciben texto largo y heterogéneo.

- **El historial completo y el contexto completo son idénticos.** Incluir las respuestas del agente (contexto completo) no aporta ni perjudica respecto a incluir solo las preguntas del usuario (historial completo).
- **La reescritura GT mejora sobre el último turno**, pero solo de manera significativa en FiQA (+0.068, $p = 0.003$) y Govt (+0.060, $p = 0.013$). Esto sugiere que la resolución de correferencias y la contextualización benefician especialmente a dominios con vocabulario especializado.

Por lo tanto, es preferible enviar **solo el último turno** a concatenar todo el historial. Por otra parte, la reescritura ofrece una mejora adicional, pero requiere un componente dedicado.

6.3.2. EA4: Variantes de reescritura automática

La Tabla 6.6 compara los tres modelos de reescritura automática contra la reescritura de los organizadores:

De 12 pruebas pareadas, 5 resultaron significativas:

Tabla 6.6: EA4 — nDCG@10 por dominio para las cuatro estrategias de reescritura. La línea base es la reescritura de los organizadores (GT). Las reescrituras automáticas de Cohere se aproximan y en algunos casos superan a la reescritura de referencia.

Reescritor	**ClapNQ**	**Cloud**	**FiQA**	**Govt**	**Media**
Flan-T5 (local)	0.476	0.353	0.315	0.430	0.394
GT (base)	0.563	0.451	0.442	0.534	0.497
Few-shot mejorado	0.621	0.453	0.417	0.549	0.510
Command-R réplica	**0.639**	**0.471**	0.421	0.544	**0.523**

- **Flan-T5 es significativamente peor que GT en los cuatro dominios** (Δ entre -0.087 y -0.126; efecto pequeño en Cloud, FiQA y Govt). El modelo local gratuito no logra producir reescrituras de calidad comparable a la de los organizadores.
- **Command-R réplica es comparable o superior a GT.** Su media (0.519) supera a GT (0.497), y alcanza significancia solo en ClapNQ (+0.076, $p = 0.012$). En los demás dominios la diferencia no es significativa.
- **El *few-shot* mejorado se comporta de manera similar** a Command-R (media 0.510), sin diferencias significativas con GT en ningún dominio tras la corrección.

Para PI2, esto implica que no hace falta intentar replicar con total exactitud la reescritura de los organizadores (generada con Mixtral 8x7B Instruct) para obtener rendimiento competitivo. Un modelo como Command-R, con un *prompt* adecuado, puede igualar (e incluso superar) esa línea base a un costo de aproximadamente \$0.50 por cada 1 000 consultas. Este resultado cobra especial relevancia dado que los propios organizadores reconocieron que sus reescrituras automáticas se pueden mejorar.

6.4. Sensibilidad de hiperparámetros

Los estudios EA5 y EA6 evalúan la robustez del *pipeline* ante dos hiperparámetros: el parámetro k de RRF y la profundidad de recuperación.

6.4.1. EA5: Parámetro k de RRF

Se evaluaron cinco valores de k: 1, 20, 40, 60 (línea base) y 100. La Tabla 6.7 compara los resultados.

Tabla 6.7: EA5 — nDCG@10 por dominio para cinco valores del parámetro k de RRF. Los resultados son prácticamente idénticos para $k \geq 20$.

k	**ClapNQ**	**Cloud**	**FiQA**	**Govt**	**Media**
$k = 1$	0.561	0.432	0.403	0.511	0.477
$k = 20$	**0.568**	**0.453**	0.441	**0.536**	**0.499**
$k = 40$	0.562	0.451	**0.445**	0.533	0.498
$k = 60$ (base)	0.563	0.451	0.442	0.534	0.497
$k = 100$	0.563	0.451	0.443	0.535	0.498

De 16 pruebas pareadas, **solo 1 resultó significativa**: $k = 1$ en FiQA ($\Delta = -0.039$, $p_{\text{adj}} = 0.050$). El rango $k \in [20, 100]$ produce resultados **estadísticamente indistinguibles** de $k = 60$, lo que **refuta H3**: el valor por defecto de 60 no requiere *tuning* en este caso.

6.4.2. EA6: Profundidad de recuperación

Se evaluaron cuatro profundidades (top-100, 200, 300, 500). **Ninguna de las 12 pruebas resultó significativa**; las diferencias son inferiores a 0.001 en todos los dominios. Dado que nDCG@10 depende de las primeras diez posiciones y los documentos relevantes se concentran en el top-100, **se puede reducir la profundidad a top-100 sin pérdida de calidad**.

6.5. EA7: Evaluación del *reranking*

Se evaluaron dos modelos de *reranking* (BGE-rr-v2 local y Cohere-v3.5 por API) a tres profundidades (50, 100, 200), comparados contra la línea base sin *reranking* sobre dos bases de primera etapa: SPLADE + BGE-1.5 (para evaluar H4a: ¿aporta el *reranking* cuando la base es más débil?) y SPLADE + Voyage (para evaluar H4b: ¿hay rendimientos decrecientes sobre una base ya fuerte?). La Tabla 6.8 muestra los resultados sobre la base SPLADE + BGE-1.5; los resultados sobre SPLADE + Voyage muestran el mismo patrón de no-significancia.

Tabla 6.8: EA7 — nDCG@10 por dominio para dos modelos de *reranking* a tres profundidades (base SPLADE + BGE-1.5, H4a). La línea base es el Híbrido S+B sin *reranking*. Ninguna diferencia resulta significativa tras corrección Holm-Bonferroni (patrón idéntico sobre la base SPLADE + Voyage para H4b).

Configuración	ClapNQ	Cloud	FiQA	Govt	Media
Sin reranking (base)	0.552	0.438	0.406	0.497	0.473
BGE-rr prof. 50	0.552	0.443	0.402	0.494	0.473
BGE-rr prof. 100	0.543	0.429	0.368	0.454	0.448
BGE-rr prof. 200	0.541	0.430	0.366	0.456	0.448
Cohere prof. 50	**0.570**	**0.445**	**0.414**	**0.510**	**0.485**
Cohere prof. 100	0.552	0.438	0.406	0.497	0.473
Cohere prof. 200	0.567	0.431	0.400	0.502	0.475

De las **48 pruebas pareadas** (24 por base), **ninguna resultó significativa** tras la corrección (5 de 24 tenían $p_{\text{raw}} < 0.05$ sobre S+B, pero no sobrevivieron a la prueba de Holm-Bonferroni; patrón idéntico sobre S+V). BGE-rr **degrada** el rendimiento a profundidades 100 y 200 (hasta -0.040 en FiQA); Cohere muestra un patrón variable con la mejor media en profundidad 50 (0.485) pero sin diferencia significativa con la línea base.

Estos resultados **no apoyan una ganancia significativa del *reranking*** bajo las condiciones evaluadas. En particular, **H4a no se confirma**: si se esperaba que el *reranking* aportara ganancia sobre una base más débil (S+B), los datos no lo

respaldan. **H4b queda respaldada** en el sentido de que sobre la base fuerte (S+V) tampoco aparecen ganancias marginales relevantes, lo que es consistente con la hipótesis de rendimientos decrecientes. En ambos casos, el *reranking* no justifica su costo, ni computacional (BGE-rr) ni económico ($1.00/1K consultas para Cohere).

La Figura 6.1 resume las medias de nDCG@10 de los estudios con mayor señal experimental (EA1–EA5, EA7). Se puede visualizar que el mayor impacto proviene de la elección de recuperador (EA1), el modo de consulta (EA3) y la estrategia de reescritura (EA4), mientras que k de RRF (EA5) y *reranking* (EA7) aportan variaciones pequeñas.

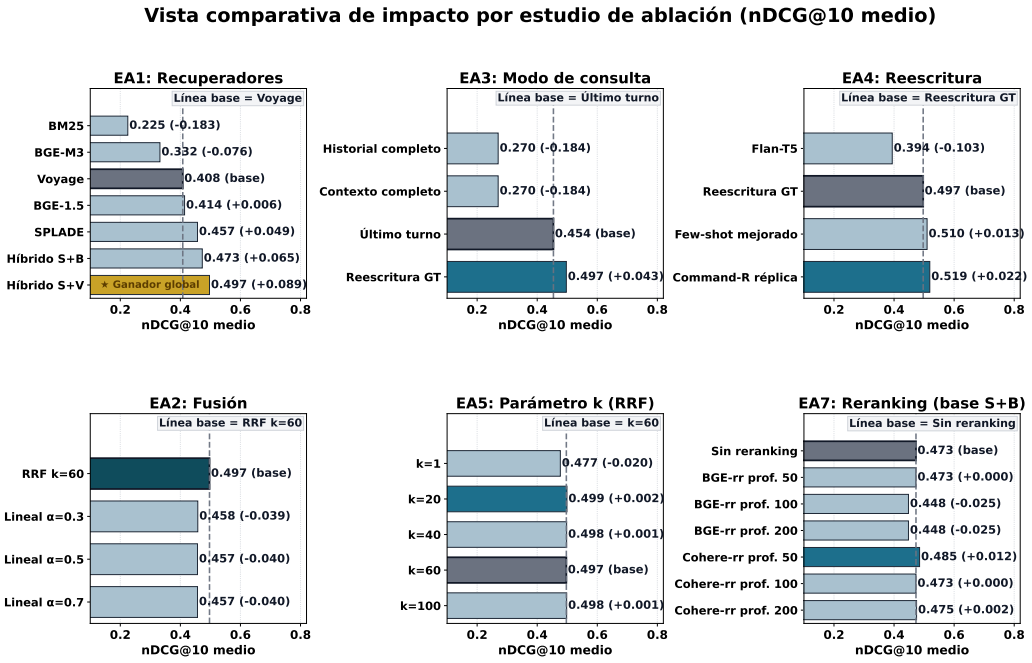


Figura 6.1: Comparativa visual de impacto por estudio de ablación usando nDCG@10 medio. Fila superior: estudios de alto impacto (EA1, EA3, EA4). Fila inferior: ajustes más finos (EA2, EA5, EA7). Cada subfigura resalta en dorado el ganador global del experimento y con el color más oscuro la mejor configuración dentro del bloque. La línea discontinua vertical marca la línea base de referencia.

6.6. Consistencia inter-dominio

Para evaluar si los resultados son transferibles entre dominios (PI6), se calculó el coeficiente τ de Kendall entre cada par de dominios, midiendo la concordancia en el *ranking* de sistemas dentro de cada estudio. La Tabla 6.9 reporta el τ promedio por estudio.

Tabla 6.9: Coeficiente τ de Kendall promedio por estudio de ablación, calculado sobre los $\binom{4}{2} = 6$ pares de dominios. Valores cercanos a 1 indican concordancia.

Estudio	$\bar{\tau}$	n **pares sig.**	**Interpretación**
EA1 (recuperadores)	0.796	6/6	Alta concordancia: la jerarquía de sistemas es estable entre dominios
EA3 (modo consulta)	1.000	6/6	Concordancia perfecta: el orden es idéntico en los cuatro dominios
EA2 (fusión)	0.621	—	Concordancia moderada
EA4 (reescritura)	0.500	—	Concordancia baja: el mejor reescritor varía según el dominio
EA5 (k de RRF)	0.500	—	Concordancia baja, pero las diferencias absolutas son negligibles
EA6 (profundidad)	—	—	No calculable (diferencias cero entre configuraciones)
EA7 (*reranking*)	0.000	—	Sin concordancia, pero las diferencias absolutas son negligibles

Los estudios con efectos grandes (EA1, EA3) muestran **alta concordancia** ($\tau \geq 0.796$): las conclusiones principales son **transferibles entre dominios**. La excepción es EA4 ($\tau = 0.500$): el mejor reescritor varía según el dominio (Command-R en ClapNQ, *few-shot* en Govt), lo que sugiere que la estrategia de *prompting* puede requerir adaptación por dominio. Las tablas completas de pruebas estadísticas pareadas, tamaños de efecto e intervalos de confianza para cada estudio de ablación se presentan en el Apéndice D.

6.7. Frontera de Pareto: calidad–latencia–costo

Para responder a PI5 (¿qué configuración ofrece el mejor compromiso entre calidad, velocidad y costo?), se construyó la frontera de Pareto sobre las 31 configuraciones evaluadas. La Tabla 6.10 muestra las configuraciones Pareto-óptimas en el espacio tridimensional.

Tabla 6.10: Configuraciones Pareto-óptimas en el espacio calidad (nDCG@10) × latencia (segundos/consulta) × costo (USD/1K consultas). Una configuración es Pareto-óptima si no existe otra que la iguale o supere en las tres dimensiones simultáneamente.

Configuración	nDCG@10	Latencia (s/q)	Costo/1K	Perfil
BGE-1.5	0.414	0.14	$0.00	Mínimo costo
SPLADE	0.457	0.47	$0.00	Calidad local
Híbrido S+B	0.473	0.65	$0.00	Mejor calidad gratuita
Voyage	0.408	0.10	$0.12	Mínima latencia
Híbrido S+V	0.497	0.46	$0.12	Mejor calidad
Command-R réplica	0.519	0.77	$0.62	Máxima calidad

La Figura 6.2 visualiza las 31 configuraciones evaluadas en el espacio calidad–latencia, codificando el costo con el color de cada punto. La frontera identifica seis configuraciones no dominadas en 3D (círculos con borde). El Híbrido S+V ofrece la mejor calidad al menor costo de API ($0.12/1K), mientras que Command-R alcanza la máxima calidad a mayor costo y latencia. El *reranking* no aparece en la frontera porque no mejora significativamente la calidad sobre las configuraciones base. La interpretación detallada de los perfiles de despliegue se discute en la sección 7.3.1.

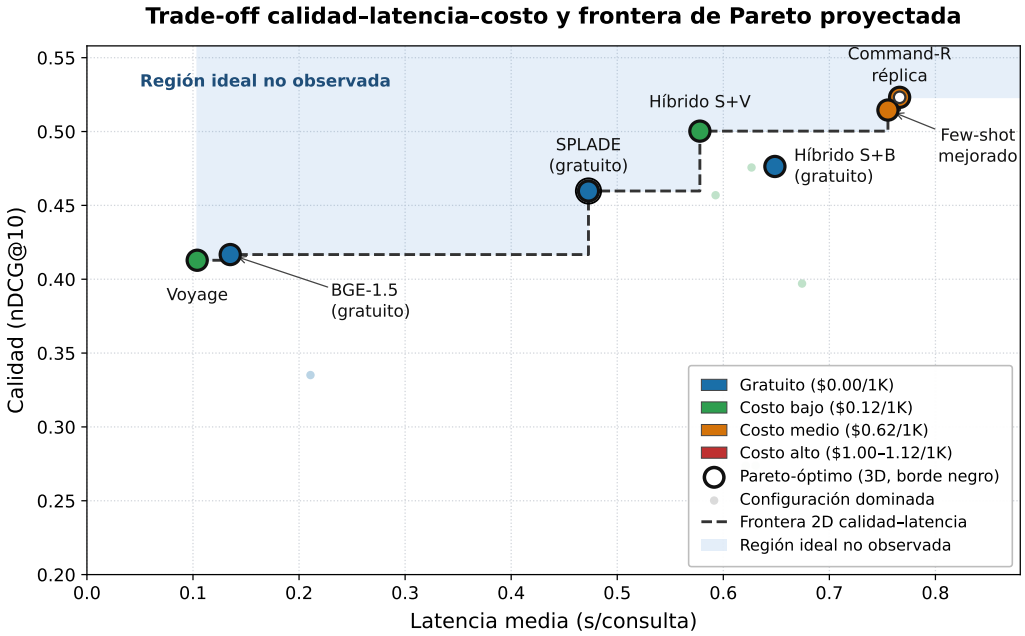


Figura 6.2: Espacio calidad (nDCG@10) × latencia (s/consulta) para las 31 configuraciones evaluadas. El color indica el costo de API. Los círculos con borde negro son las configuraciones Pareto-óptimas en el espacio tridimensional; la línea discontinua traza la frontera 2D calidad–latencia.

La Tabla 6.11 complementa el análisis con métricas orientadas a producción para las configuraciones más representativas.

Tabla 6.11: Métricas de producción para las configuraciones principales. Se reporta la latencia en percentiles (p50 y p95), el cumplimiento de un SLA de 2 segundos y la tasa de fallo (porcentaje de consultas sin documento relevante en el top-5).

Configuración	nDCG@10	p50 (s)	p95 (s)	SLA ≤2 s	Fallo %
BM25	0.225	1.10	1.96	75 %	53.5 %
SPLADE	0.457	0.38	0.45	100 %	25.1 %
Voyage	0.408	0.08	0.12	100 %	30.0 %
Híbrido S+V	0.497	0.46	0.54	100 %	21.2 %
Command-R réplica	0.519	0.78	0.95	100 %	26.8 %

Todas las configuraciones basadas en modelos neuronales cumplen el SLA de 2 segundos al 100 %. BM25 es el único que incumple (75 %), debido a que su implementación en memoria es ineficiente para corpus grandes. La tasa de fallo más baja la tiene el Híbrido S+V (21.2 %), confirmando que es la configuración más equilibrada. Command-R réplica alcanza la mayor calidad (0.519), a un costo de \$0.62/1K consultas y latencia media de 0.77 s, siendo la única opción si el objetivo es maximizar el rendimiento sin restricción económica. Nótese que aunque la reescritura de Command-R mejora la calidad media, también introduce errores en algunas consultas donde se altera la intención.

La Figura 6.3 integra este resultado con la distribución global de errores y su perfil por dominio, para visualizar simultáneamente el compromiso calidad–latencia, la composición de fallos y la variación entre dominios.

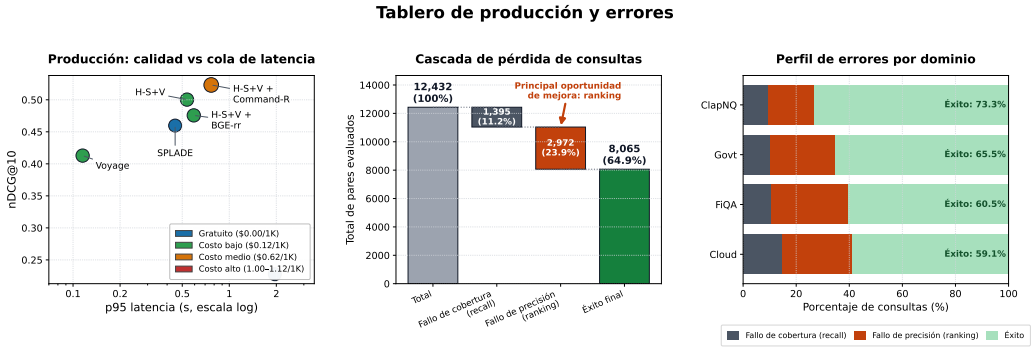


Figura 6.3: Tablero de tres paneles: (izquierda) calidad nDCG@10 frente a latencia de cola p95 con codificación de costo, (centro) pérdidas con separación entre fallo de cobertura (recall) y fallo de precisión (ranking) sobre 12 432 pares sistema-consulta, y (derecha) fallos por dominio.

6.8. Análisis cualitativo de errores

Esta sección resume los tipos de error y la degradación por profundidad de la conversación; el análisis por dominio, los factores predictivos y ejemplos adicionales se discuten en las secciones siguientes.

6.8.1. Distribución de tipos de error

Se clasificaron los resultados de las 777 consultas × 16 configuraciones principales (12 432 pares sistema-consulta) en tres categorías (Tabla 6.12):

Tabla 6.12: Distribución de tipos de error sobre el conjunto completo de evaluación (12 432 pares sistema-consulta).

Categoría	Cantidad	Tasa	Descripción
Éxito (doc relevante en top-5)	8 065	64.9 %	El sistema recuperó y posicionó correctamente el documento de interés.
Error de *ranking*	2 972	23.9 %	El documento relevante se encuentra dentro del top-k general pero fuera del top-5 prioritario.
Error de recuperación	1 395	11.2 %	El documento relevante no aparece en ninguna posición del top-k devuelto.

La proporción de errores de *ranking* (23.9 %) frente a errores de recuperación (11.2 %) tiene una implicación directa para el diseño del sistema: la prioridad debería ser mejorar el **ordenamiento** de los candidatos que ya están en el *pool*, no ampliar la cobertura del *pool*. Sin embargo, como se mostró en EA7, los *rerankers* evaluados no logran capitalizar esta oportunidad.

6.8.2. Degradación por profundidad de turno

La Tabla 6.13 muestra cómo la tasa de fallo y las métricas se degradan conforme avanza la conversación.

Tabla 6.13: Rendimiento por profundidad de turno. La tasa de fallo se define como el porcentaje de consultas sin documento relevante en el top-5. Las métricas se promedian sobre las 16 configuraciones principales.

Turno	Consultas	Fallo %	MRR	nDCG@5
Turno 1	1 632	17.6 %	0.674	0.603
Turno 2	1 696	26.8 %	0.588	0.450
Turno 3	1 648	36.4 %	0.485	0.370
Turno 4+	7 456	40.6 %	0.455	0.352

La tasa de fallo se duplica entre el turno 1 (17.6 %) y el turno 4+ (40.6 %), y el MRR cae de 0.674 a 0.455. Conforme la conversación avanza, las consultas del usuario se vuelven más ambiguas y dependen más del contexto conversacional previo, lo que dificulta la recuperación incluso con reescritura.

6.8.3. Ejemplo de error

Caso ilustrativo: Reescritura que altera la intención. Consulta original: "*streaming services?*". La reescritura automática generó: "*Where can I stream The Office?*", cuando el usuario en realidad preguntaba sobre servicios de *streaming* de datos en la nube. El nDCG@5 cayó de 0.431 (sin reescritura) a 0.000 (con la reescritura errónea). En total, se identificaron **241 consultas** donde la reescritura *empeoró* el resultado respecto a no reescribir. **Tipo: error inducido por la reescritura**. Un sistema de producción debería implementar un mecanismo de *fallback* que detecte cuándo la reescritura es de baja confianza.

6.9. Resumen de hallazgos estadísticos

La Tabla 6.14 sintetiza los resultados de los siete estudios de ablación.

En síntesis, los componentes de **alto impacto** son la elección del recuperador (EA1), el modo de consulta (EA3) y la calidad de la reescritura (EA4); los componentes de **bajo impacto** son el operador de fusión (EA2), el hiperparámetro

Tabla 6.14: Resumen estadístico de los siete estudios de ablación. Se indica el número de pruebas significativas sobre el total, y el hallazgo principal.

Estudio	Sig./Total	Hallazgo principal
EA1 (recuperadores)	15/24	Híbrido S+V > SPLADE en 4/4 dominios con prueba pareada directa (Wilcoxon + Holm, $p_{\text{adj}} \leq 0.023$). SPLADE > Voyage en Cloud y FiQA. BM25 $\ll$ todos los neurales.
EA2 (fusión)	9/12	RRF > interpolación lineal en 3/4 dominios (efecto negligible). Cambios de α (0.3/0.5/0.7) producen variaciones menores y no alteran la conclusión principal.
EA3 (modo consulta)	10/12	Pasar el historial completo es erróneo (-0.18). GT rewrite mejora en 2/4 dominios.
EA4 (reescritura)	5/12	Flan-T5 $\ll$ GT. Command-R y *few-shot* $\approx$ GT. LLMs comerciales igualan reescritura de referencia de los organizadores.
EA5 (k de RRF)	1/16	RRF es extremadamente robusto a k.
EA6 (profundidad)	0/12	Efecto nulo. top-100 produce los mismos resultados que top-500.
EA7 (*reranking*)	0/48	Ni BGE-rr ni Cohere mejoran significativamente la recuperación híbrida (ambas bases: S+B para H4a y S+V para H4b).

k (EA5), la profundidad de recuperación (EA6) y el *reranking* (EA7). Las tablas completas de pruebas pareadas, tamaños de efecto e intervalos de confianza para los siete estudios se encuentran en el Apéndice D.

Como criterio de despliegue, el **sistema final ganador** es **Híbrido S+V**: mantiene calidad alta (nDCG@10 ≈ 0.500), minimiza latencia dentro del grupo de mayor rendimiento y conserva el costo en \$0.12/1K consultas. Si el objetivo fuera exclusivamente maximizar calidad sin restricciones de costo/latencia, el mejor valor absoluto lo obtiene **Command-R réplica** (nDCG@10 ≈ 0.523).

6.10. Posicionamiento en el *benchmark* oficial MTRAGEval

El sistema IIMAS-RAG fue enviado a la evaluación oficial de la Tarea A de MTRAGEval (SemEval-2026) con la configuración Híbrido S+V con reescritura Command-R réplica. Los resultados de los organizadores posicionaron al sistema en el **4.º lugar de 38 equipos participantes**, con un puntaje de **nDCG@5 = 0.5445**.

Cabe notar que la evaluación oficial emplea nDCG@5 como métrica principal, mientras que los experimentos internos de esta tesis utilizan nDCG@10; por ello, los valores de ambas secciones no son directamente comparables, aunque el comportamiento relativo entre configuraciones se mantiene consistente.

La Tabla 6.15 sitúa el resultado del sistema en el contexto del leaderboard reportado por los organizadores.

Tabla 6.15: Posicionamiento del sistema IIMAS-RAG en la evaluación oficial de la Tarea A de MTRAGEval (SemEval-2026). La línea base oficial es ELSER con reescritura GPT-OSS-20b.

Sistema	**nDCG@5**	**Posición**	**Δ vs. línea base**
Mejor equipo	0.5776	1/38	+0.098
IIMAS-RAG (este trabajo)	**0.5445**	**4/38**	+0.065
Línea base oficial (ELSER + GPT-OSS-20b)	0.4795	—	—

El sistema supera a la línea base oficial en +0.065 puntos de nDCG@5 y se encuentra a solo -0.033 del equipo de mayor puntuación, lo que confirma que la arquitectura híbrida SPLADE + Voyage con reescritura automática es competitiva en condiciones reales de evaluación multi-turno. Es destacable que este resultado fue obtenido sin ajuste de hiperparámetros sobre el conjunto de prueba y con un sistema cuyo costo total de API es inferior a 5 USD para el conjunto completo de experimentos.

Capítulo 7

Discusión

> "Not everything that can be counted counts, and not everything that counts can be counted."
>
> William Bruce Cameron

El capítulo 6 presentó los resultados numéricos de los siete estudios de ablación, las pruebas estadísticas y los análisis transversales. En este capítulo explicaremos la lógica detrás de los patrones observados (sección 7.1), después se contrastan con la evidencia reportada por otros autores (sección 7.2), se discuten las implicaciones para la práctica y la teoría (sección 7.3), y finalmente se reconocen las limitaciones del estudio con posibles líneas futuras de investigación (secciones 7.4 y 7.5).

7.1. Interpretación de los resultados

El propósito de esta sección es explicar la lógica detrás de los patrones observados.

7.1.1. La lógica de la fusión híbrida

Que la fusión SPLADE + Voyage supere consistentemente a todos los modelos individuales no es una coincidencia. SPLADE captura coincidencias léxicas mediante **expansión semántica aprendida** (asignando peso a términos no presentes literalmente en la consulta) mientras que Voyage captura relaciones semánticas como paráfrasis y razonamiento que SPLADE no puede representar. BM25, a pesar de ser el modelo léxico de referencia, queda muy por debajo de SPLADE: en escenarios multi-turno la señal relevante no es la coincidencia exacta de palabras clave sino la expansión aprendida, algo particularmente valioso cuando la consulta es un fragmento breve como "and the cost?".

7.1.2. El efecto del historial completo

El hallazgo de que concatenar el historial conversacional completo degrada severamente el rendimiento parece contraintuitivo. La explicación está en que tanto los modelos dispersos como los densos estiman relevancia respecto a la *totalidad* del texto de entrada: cuando ese texto incluye todos los turnos previos, los términos de turnos anteriores actúan como **ruido léxico y semántico** que diluye la señal actual. El contraste con la reescritura es directo: esta condensa la información relevante en una formulación autocontenida, eliminando ese ruido. Que el último turno supere al historial completo indica que, para los recuperadores actuales, es preferible perder contexto que contaminarse con ruido (sección 7.3).

7.1.3. La sensibilidad de RRF y la profundidad de recuperación

La robustez de k y de la profundidad de recuperación revela que los documentos relevantes ya se concentran en las primeras posiciones de cada recuperador individual: variar k entre 20 y 100 solo altera la ponderación de documentos que de todos modos quedarían en el top-10 fusionado, y ampliar la profundidad de 100 a 500 solo incorpora documentos que ninguno de los dos recuperadores considera relevantes. La excepción es $k = 1$, que amplifica errores al privilegiar drásticamente

a un único recuperador; la recomendación práctica es evitar valores extremadamente bajos de k en RRF y a su vez, no invertir recursos en su optimización.

7.1.4. La paradoja del *reranking*

El resultado más contraintuitivo de la investigación es que ni BGE-rr-v2 ni Cohere-v3.5 mejoran significativamente el *ranking* híbrido. Dos factores explican este resultado. Primero, los *cross-encoders* entrenados en dominios generales (MS MARCO, Wikipedia) pueden **introducir sesgos de dominio general** cuando se aplican sobre un buen primer *ranking*. Segundo, el 23.9 % de los errores son de *ranking* (documento en el *pool* pero fuera del top-5), que ocurren predominantemente en consultas ambiguas donde el *reranker* enfrenta el mismo nivel de confusión que el recuperador. Que BGE-rr degrade el rendimiento a profundidades mayores (100 y 200 candidatos) refuerza esta interpretación: al evaluar más documentos, asigna puntuaciones espurias que desplazan a candidatos que el recuperador original había posicionado correctamente.

7.2. Contraste con la literatura previa

A continuación se contrastan los hallazgos principales con la evidencia de la literatura, organizando la discusión por componente del *pipeline*.

7.2.1. Fusión híbrida: complementariedad confirmada

Los resultados de EA1 son consistentes con Thakur et al. [2021] y Chen et al. [2024]: las señales léxicas aprendidas y las densas son complementarias, y su fusión supera a cada señal individual. Esta tesis extiende esa evidencia al contexto **conversacional multi-turno** con dominios especializados.

7.2.2. Reescritura: consistencia con la literatura y un resultado inesperado

La reescritura mejora la recuperación frente al último turno, consistente con Mao et al. [2023] y Elgohary et al. [2019]. El resultado original de esta tesis es el **efecto del historial completo** (-18 puntos de nDCG@10), no documentado de manera controlada previamente: Dalton et al. [2021] reportaron caídas drásticas en el rendimiento (reflejadas en métricas de corte bajo como nDCG@3) en turnos afectados por un cambio de tema en TREC CAsT 2020, pero sin comparar directamente contra el último turno. A diferencia de Mo et al. [2023], la selección entre reformulaciones no aportó mejora, pues Command-R ya produce reescrituras de alta calidad consistente.

7.2.3. *Reranking*: divergencia con las expectativas del estado del arte

Los resultados de EA7 contradicen la expectativa general de la literatura sobre *reranking*. Nogueira and Cho [2019] demostraron ganancias sustanciales del *reranking* con *cross-encoders* BERT sobre BM25, y Pradeep et al. [2023] mostraron que RankZephyr mantiene rendimiento comparable a GPT-4 a una fracción del costo. Sin embargo, estos resultados se documentaron sobre recuperación de primera etapa con un único modelo léxico, un escenario donde la oportunidad de mejora del *reranker* es máxima.

Los hallazgos de esta tesis son **consistentes** con la observación de Glass et al. [2022], quienes documentaron que las ganancias del *reranking* se reducen progresivamente sobre recuperación densa y fusión híbrida, y con Eibich et al. [2024], quienes no encontraron ventajas consistentes de Cohere Rerank sobre configuraciones híbridas ya optimizadas. Los *cross-encoders* evaluados (BGE-rr y Cohere) no solo no mejoran sino que en algunos casos degradan el rendimiento, lo que sugiere que la efectividad del *reranking* depende de la **calidad relativa de la primera etapa**: cuando la recuperación híbrida ya posiciona correctamente la

mayoría de los documentos relevantes, el *reranker* tiene poco margen de mejora. La contribución diferenciadora de esta tesis es la cuantificación de este efecto en un *pipeline* **conversacional multi-turno**, donde la interacción entre *reranking* y calidad de la primera etapa se amplifica por la mayor ambigüedad de las consultas.

7.2.4. Sensibilidad de hiperparámetros

Cormack et al. [2009] propusieron $k = 60$ sin un análisis formal de sensibilidad; los resultados de EA5 aportan evidencia empírica de que, en dominios especializados multi-turno, el rendimiento de RRF es esencialmente invariante a k en el rango $[20, 100]$, **validando empíricamente** el valor canónico de Elasticsearch. Análogamente, la insensibilidad de la profundidad de recuperación (EA6) indica que la fusión híbrida ya coloca los documentos relevantes en las primeras posiciones independientemente del tamaño total del *pool*.

7.3. Implicaciones prácticas y teóricas

7.3.1. Implicaciones para el despliegue en producción

Priorizar la fusión sobre el *reranking*. Invertir en una primera etapa híbrida de alta calidad (modelo disperso aprendido + modelo denso) tiene mayor retorno que añadir un *reranker*.

No usar el historial completo. Enviar el historial completo es peor que enviar solo el último turno. Con presupuesto, reescribir con un LLM es la mejor opción.

Implementar *fallback* para la reescritura. 241 consultas empeoraron con reescritura automática. Comparar la similitud semántica entre consulta original y reescrita permite detectar cuándo recurrir al último turno.

El valor por defecto $k = 60$ no requiere ajuste. Adoptándolo directamente se simplifica la configuración del sistema sin penalización.

7.4. Limitaciones del estudio

Las principales limitaciones son: **escala moderada** (777 consultas limita la detección de efectos pequeños); **diseño OFAT** (no captura interacciones, como la posible ganancia del *reranking* combinado con recuperadores individuales); **corpus monolingüe** en inglés con conversaciones de media 7 turnos (la transferibilidad a otros idiomas o diálogos largos no está garantizada); y **ausencia de evaluación extremo a extremo** (no se midió el impacto en la calidad de la respuesta generada).

7.5. Líneas futuras de investigación

Las limitaciones identificadas sugieren tres líneas prioritarias de trabajo futuro.

Evaluar interacciones mediante diseño factorial fraccionado. Cubrir las interacciones reescritura × *reranking* y fusión × profundidad, que el diseño OFAT no pudo capturar.

Crear un mecanismo de *fallback* de reescritura. Detectar cuándo la reescritura automática altera la intención original y decidir si usar la versión reformulada o el turno directamente, reduciendo los 241 casos de degradación identificados.

Ampliar la validez externa. Evaluar en corpus en **español** y en conversaciones largas (>20 turnos); integrar con un modelo generativo para obtener una **evaluación de extremo a extremo**.

Capítulo 8

Conclusiones y Trabajo Futuro

Esta tesis diseñó un estudio de ablación controlado con siete experimentos (EA1–EA7), 31 configuraciones únicas y cuatro dominios especializados de MT-RAG (777 consultas), validado con Wilcoxon, Holm-Bonferroni y Cliff's δ.

8.1. Síntesis de los hallazgos

El trabajo experimental produjo cinco hallazgos principales que, en conjunto, modelan la comprensión que actualmente tenemos sobre los *pipelines* de recuperación conversacional en dominios especializados.

1. La fusión híbrida es el componente más rentable del *pipeline*. Se demostró que la fusión híbrida SPLADE + Voyage incrementa la relevancia en un +0.089 de nDCG@10 promedio frente al mejor modelo denso individual (Voyage), con significancia estadística en los cuatro dominios evaluados. Este resultado valida la idea de que las señales léxicas expandidas y las señales semánticas densas capturan información **complementaria y no redundante**, y que combinarlas mediante un operador (que mejor aún, no necesita de calibración) como RRF produce ganancias consistentes sin importar el dominio temático.

2. Cómo se formula la consulta importa tanto como qué recuperador se usa. La diferencia entre el mejor y el peor modo de consulta (ΔnDCG@10 = 0.227) duplica la diferencia entre el mejor y peor recuperador individual (0.125). Concatenar el historial provocó una caída de 18 puntos respecto al último turno.

3. Un LLM comercial iguala o supera la reescritura de referencia del *benchmark*. Command-R igualó e incluso superó en ClapNQ a la reescritura GT de los organizadores (generada con Mixtral 8x7B Instruct), a un costo de aproximadamente $0.50 por cada mil consultas. No obstante, 241 de 777 consultas empeoraron con la reescritura automática, lo que señala la necesidad de un mecanismo de *fallback*.

4. Los hiperparámetros del *pipeline* son muy robustos. Solo 1 de 76 pruebas en EA5–EA7 alcanzó significancia: $k = 60$ no requiere ajuste. Además, la profundidad puede reducirse de top-300 a top-100 sin pérdida, y el *reranking* no justifica su costo sobre una primera etapa híbrida bien construida.

5. Las conclusiones de mayor impacto son transferibles entre dominios. Los estudios con efectos significativos (EA1 y EA3) mostraron alta concordancia inter-dominio (Kendall $\tau = 0.796$ y 1.000), confirmando que las recomendaciones principales son **transferibles entre dominios**.

8.2. Respuesta a las preguntas de investigación

PI1: **Sí.** SPLADE + Voyage superó al mejor modelo individual en los cuatro dominios (15/24 pruebas significativas; mayor ganancia en FiQA +0.131). H1 **confirmada**.

PI2: **Sí.** La reescritura de los organizadores mejora en FiQA y Govt; Command-R iguala e incluso supera a la reescritura de referencia de los organizadores (0.519 vs. 0.497 en media). H2 **confirmada**.

PI3: **No.** Solo 1/16 pruebas significativa ($k = 1$ en FiQA). $k = 60$ no necesita *tuning*. H3 **refutada**.

PI4: **No mejora.** 0/48 pruebas de *reranking* significativas. H4a **refutada** y H4b **confirmada**: el *reranking* es innecesario sobre fusión híbrida bajo el contexto de estos modelos evaluados.

PI5: La frontera de Pareto ubica al Híbrido SPLADE + Voyage como configuración dominante (nDCG@10 0.497, $0.12/1K). Con presupuesto adicional, Command-R + Híbrido eleva a 0.519; sin APIs externas, SPLADE + BGE-1.5 alcanza 0.473.

PI6: **Sí, para las decisiones de mayor impacto** ($\tau \geq 0.796$ en EA1 y EA3). La elección del modelo de reescritura muestra menor concordancia ($\tau = 0.500$) y puede requerir adaptación por dominio.

8.3. Contribuciones

Las contribuciones de esta tesis pueden agruparse en tres principalmente. Desde el punto de vista **empírico**: primer estudio de ablación controlado en recuperación conversacional multi-turno con validación estadística formal (Wilcoxon + Holm-Bonferroni + Cliff's δ), cuantificación del efecto de concatenar el historial completo (-0.18 nDCG@10) y evidencia de que el *reranking* es prescindible sobre fusión híbrida (0 de 48 pruebas significativas). Desde la perspectiva **metodológica**: validación empírica de la robustez de $k = 60$ en RRF y construcción de una frontera de Pareto calidad–latencia–costo como herramienta de decisión. En **reproducibilidad**: código, datos y configuraciones publicados en el repositorio abierto (`https://github.com/Vania-Janet/mtrag_semeval2026`).

8.4. Limitaciones y trabajo futuro

Las limitaciones se detallan en la sección 7.4.

En síntesis, esta tesis demostró que la decisión de cómo **fusionar** señales de recuperación y cómo **formular la consulta** tiene mayor impacto que añadir componentes costosos como el *reranking*. La fusión híbrida y la reescritura con LLMs son los pilares de un buen sistema conversacional en dominios especializados; los hiperparámetros del operador de fusión no merecen optimización; y el reordenamiento es prescindible cuando la primera etapa es suficientemente buena.

Apéndice A

Muestras de datos y ejemplos cualitativos

Este anexo presenta ejemplos concretos del benchmark MT-RAG y de las salidas del sistema de recuperación. El objetivo es ilustrar los principales patrones de éxito y fallo identificados en el análisis cualitativo. Todos los ejemplos corresponden a salidas reales del sistema, seleccionadas manualmente para ilustrar fenómenos representativos.

A.1. Estructura de una conversación multi-turno

Cada conversación en el benchmark MT-RAG es un diálogo de entre 2 y 10 turnos almacenado en formato JSONL. La Tabla A.1 muestra un ejemplo del dominio ClapNQ (ID: `dd6b6ffd`).

Tabla A.1: Ejemplo de conversación multi-turno del dominio ClapNQ (ID: `dd6b6ffd`).

Turno	Consulta del usuario	Observación
1	Where do the Arizona Cardinals play this week?	Consulta directa; marcada como UNANSWERABLE por los anotadores.
2	Do the Arizona Cardinals play any games outside the United States?	Misma entidad central; cambia el foco informativo.
3	Are the Arizona Cardinals the same team as the Chicago Cardinals?	Foco histórico; introduce entidad relacionada.
4	How many teams are currently in the National Football League?	Ampliación temática hacia la liga en general.

Formato JSONL con campos `conversation_id`, `turn`, `input`, `targets`, `contexts` y anotaciones de calidad (`Question Type`, `answerability`).

A.2. Comparación de métodos de reescritura

La Tabla A.2 compara la calidad de la reescritura producida por los tres métodos evaluados en EA4 para consultas de tres dominios distintos, cada uno con un tipo de dificultad diferente.

En los tres casos, Command-R resuelve correctamente el referente pronominal y produce la reformulación más completa. Flan-T5 también resuelve la referencia, aunque con formulaciones más simples. El método Few-shot mejorado, pese a recibir instrucciones explícitas de producir únicamente una consulta reescrita (véase Apéndice B), en ocasiones genera texto tipo documento hipotético para los dominios Cloud y FiQA. Este comportamiento emergente no intencionado explica parte de su variabilidad de desempeño en EA4.

A.3. Casos de éxito y fallo en la recuperación

Se presentan tres escenarios que ilustran el comportamiento de la configuración recomendada (SPLADE+Voyage, RRF, top-10) ante consultas de distinta dificultad.

Tabla A.2: Ejemplos de reescritura por dominio y fenómeno ilustrado (EA4).

Dom.	Consulta + contexto	Método	Reescritura	Fenómeno
CLAPNQ	"what did he do?" *(ctx: Lord Linlithgow)*	Command-R	*What were Lord Linlithgow's actions during the Quit India Movement?*	Correferencia pronominal (persona)
		Few-shot	*What were Lord Linlithgow's actions during the Quit India Movement?*	
		Flan-T5	*What did Lord Linlithgow do during the Quit India Movement?*	
CLOUD	"What benefits does it offer?" *(ctx: Red Hat OpenShift)*	Command-R	*What are the benefits of Red Hat OpenShift?*	Correferencia pronominal (objeto)
		Few-shot	*Red Hat OpenShift provides several benefits, including enhanced security...* †	
		Flan-T5	*What benefits does Red Hat OpenShift offer?*	
FIQA	"How is it calculated?" *(ctx: enterprise value)*	Command-R	*What is the formula for calculating enterprise value?*	Correferencia + dominio especializado
		Few-shot	*Enterprise value is calculated by adding the market cap and debt...* †	
		Flan-T5	*How is the value of a company calculated?*	

Configuración base: SPLADE+Voyage, RRF, top-10. Command-R: Cohere Command-R vía API (réplica). Few-shot mejorado: mismo modelo con *prompt* optimizado por dominio. Flan-T5: `google/flan-t5-large` ejecutado localmente (véase Apéndice B). † En estos casos el modelo ignoró la regla de producir únicamente la consulta reescrita y generó en cambio un texto tipo documento hipotético (comportamiento emergente, no intencionado, similar a HyDE); se muestra el inicio del texto generado. El *prompt* del modo *few-shot* mejorado sí instruye explícitamente *"Output ONLY the rewritten query"* (véase Apéndice B, §B.3).

A.3.1. Caso 1: Recuperación exitosa (CLAPNQ, `dd6b6ffd`, turno 4)

Consulta

"How many teams are currently in the National Football League?"

Reescritura

Consulta ya auto-contenida; no requiere resolución de correferencia.

Pasaje recuperado (rango 1)

"The NFL currently has 32 teams, organized into two conferences (AFC and NFC) of 16 teams each. . . "

Resultado

nDCG@10 = 1.000.

Interpretación

Cuando la consulta no requiere resolución de correferencia, el sistema recupera correctamente el pasaje relevante en primera posición. Este es el escenario ideal y representa la mayoría de las consultas auto-contenidas del benchmark.

A.3.2. Caso 2: Éxito parcial con correferencia (FIQA)

Consulta original

"Is it tax deductible?"

Contexto

Turnos previos sobre contribuciones a un plan traditional 401(k).

Reescritura (Command-R)

"Are traditional 401(k) contributions tax deductible?"

Pasaje recuperado (rango 3)

"Traditional 401(k) contributions are made pre-tax, reducing your taxable income in the year of the contribution. . . "

Resultado

Recuperación parcial: el pasaje relevante aparece en la posición 3; las posiciones 1–2 contienen documentos relacionados pero no exactamente relevantes.

Interpretación

La reescritura resuelve la correferencia correctamente, pero el ranking confunde documentos relacionados con documentos exactamente relevantes. El problema está en la etapa de ordenamiento, no en la cobertura.

A.3.3. Caso 3: Fallo por dependencia de contexto a larga distancia (CLOUD)

Consulta original (turno 6)

"And what about the latency issue I mentioned?"

Contexto

Conversación extensa sobre configuración de Azure Functions; cold-start latency bajo el Consumption plan fue mencionada en el turno 2.

Reescritura (Command-R)

"How can cold-start latency be reduced in Azure Functions?"

Problema

La reescritura pierde el detalle específico (cold-start latency bajo el Consumption plan) mencionado 4 turnos atrás. El sistema recupera documentación general de Azure Functions, no el artículo específico sobre latencia de arranque en frío.

Resultado

Fallo total: ninguno de los 10 primeros documentos es relevante.

Interpretación

Este fallo no proviene del recuperador aislado, sino de una reescritura que no puede acceder a contexto mencionado varios turnos atrás. Ilustra la limitación central de los sistemas de reescritura basados en LLM: la calidad de recuperación depende directamente de la memoria conversacional del modelo de reescritura.

Apéndice B

Prompts completos para reescritura de consultas

Este apéndice muestra los *prompts* utilizados en el estudio EA4 para los tres reescritores automáticos implementados en `scripts/generate_rewrites.py`. Para Flan-T5 se muestra el prompt tal como se envía al *pipeline* de `text2text-generation`. Para Command-R réplica y *few-shot* mejorado, el prompt corresponde al `preamble` enviado como parámetro de sistema en la API de Cohere. El código fuente completo está disponible en:

`https://github.com/Vania-Janet/mtrag_semeval2026`

B.1 Flan-T5 (modo `local`)

Flan-T5 recibe como entrada una cadena de texto que concatena el historial de la conversación y la instrucción de condensación. El *prompt* enviado al modelo sigue la plantilla:

```
Summarize the conversation into a single search query that captures
the user's latest intent. Conversation: {historia de turnos}
Summary:
```

donde `{historia de turnos}` se construye a partir de los mensajes del usuario

y el agente concatenados en orden cronológico.

B.2 Command-R réplica (modo `replica`)

El *preamble* base (dominios ClapNQ y Govt comparten la estructura; Cloud y FiQA añaden reglas de dominio marcadas con †):

```
You are an expert search-query rewriter. Your task is query condensation:
given a multi-turn conversation between a user and a chatbot, rewrite the
user's LAST question into a single standalone search query that captures
the full intent without needing any prior context.

Rules:
1. Output ONLY the rewritten query -- no explanation, no preamble.
2. Resolve all pronouns and references using conversation history.
3. Preserve the user's original keywords and terminology.
4. Do NOT answer the question.
5. Keep the query concise and natural.
```

Reglas adicionales por dominio:

- **Cloud:** `6. Keep the rewritten query under 30 tokens. 7. Preserve technical terms, product names, and cloud service identifiers.`
- **FiQA:** `6. Keep the rewritten query under 25 tokens. 7. Preserve financial terminology: ticker symbols, fund names, ratios, and regulatory terms exactly as stated.`
- **Govt:** `6. Preserve all named entities: agency names, program titles, legislation names, and acronyms. 7. Maintain formal register appropriate for government documents.`

B.3 *Few-shot* mejorado (modo `improved`)

El *preamble* base del modo mejorado difiere del réplica en la regla 5 (autocontenido explícito) y en la resolución de correferencias más amplia (*ellipsis*, referencias implícitas). Al final se insertan 3 ejemplos GT del mismo dominio con turno ≥ 3.

```
You are an expert at conversational query condensation for information
retrieval. Rewrite the user's LAST question into a standalone search query
that will retrieve the best document from a {domain_desc} corpus.

Rules:
1. Output ONLY the rewritten query.
2. Resolve all coreferences (pronouns, ellipsis, implicit references).
3. Preserve domain-specific keywords exactly.
4. Do NOT answer the question.
5. The query should be self-contained: a reader with no conversation
   context must understand exactly what information is needed.
{domain_rules}

Here are examples of good rewrites:
{examples}
```

donde `{domain_desc}` y `{domain_rules}` se instancian por dominio:

- **ClapNQ:** `general-knowledge` (sin reglas adicionales).
- **Cloud:** `cloud-computing documentation 6. Keep the query under 30 tokens. 7. Preserve cloud service names, API references, and error codes.`
- **FiQA:** `financial question-answering 6. Keep the query under 25 tokens. 7. Keep financial jargon intact; do NOT simplify technical terms. 8. If the user asks about a specific ticker or fund, include it.`
- **Govt:** `government reports and policy documents 6. Preserve all named entities: agencies, programs, legislation. 7. Use formal register.`

`{examples}` contiene los primeros 3 ejemplos del mismo dominio cuyo identificador de turno es ≥ 3, con el formato:

```
Conversation:
  User: {mensaje turno n − 1}
  User: {mensaje turno n}
Rewrite: {reescritura GT}
```

Apéndice C

Detalles de implementación

El código fuente completo del sistema MT-RAG —incluyendo los módulos de recuperación dispersa y densa, las funciones de fusión (RRF e interpolación lineal con normalización min-max), la clase `HybridRetriever` que orquesta ambos recuperadores, los 55 archivos YAML de configuración de experimentos y el archivo `base.yaml` con los valores por defecto— se encuentra disponible en el repositorio del proyecto:

`https://github.com/Vania-Janet/mtrag_semeval2026`

La Tabla C.1 lista las dependencias principales.

Requisitos de hardware y costo. Los requisitos mínimos son: GPU NVIDIA con 8 GB de VRAM (recomendado: RTX 4090 con 24 GB), 32 GB de RAM y 50 GB de disco. Las APIs externas requeridas son VoyageAI (embeddings densos), Cohere (reescritura y *reranking*) y, opcionalmente, OpenAI (LLMRewriter de línea base). El costo total de ejecutar los 55 experimentos es inferior a 5 USD en llamadas de API. La guía detallada de instalación y ejecución se encuentra en el archivo `README.md` del repositorio.

Tabla C.1: Dependencias principales del proyecto (Python 3.11, CUDA 12.1).

Categoría	**Paquete**	**Versión**
ML / Deep Learning	`torch`, `transformers`, `sentence-transformers`	2.9.1, 4.47.1, 5.2.0
Recuperación	`faiss-cpu`, `pytrec_eval`	1.13.2, 0.5
APIs de embedding	`cohere`, `voyageai`	5.20.1, 0.3.7
Cómputo científico	`numpy`, `scipy`, `pandas`	1.26.4, 1.17.0, 2.3.3

Apéndice D

Tablas de resultados extendidas

Para cada estudio de ablación con resultados significativos se presenta la tabla de pruebas estadísticas pareadas (Wilcoxon con corrección Holm-Bonferroni) y tamaños de efecto (Cliff's δ). Para EA1 se incluye además la tabla de concordancia inter-dominio (τ de Kendall), pues es el único estudio donde todos los pares de dominios son estadísticamente significativos. Los hallazgos principales se discuten en el Capítulo 6.

EA1: Comparación de modelos de recuperación

Tabla D.1: Pruebas pareadas para EA1_baselines

Sistema B	Dom.	Δ media	p Wilcoxon	p_{adj}	δ Cliff	IC 95 %
BGE-1.5	clapnq	-0.0233	0.0765	0.3957	-0.045 (N)	[-0.0576, 0.0121]
	cloud	+0.0235	0.3568	1.0000	+0.042 (N)	[-0.0197, 0.0670]
	fiqa	+0.0390	0.0384*	0.3072	+0.063 (N)	[0.0053, 0.0739]
	govt	-0.0179	0.3541	1.0000	-0.028 (N)	[-0.0623, 0.0269]
BGE-M3	clapnq	**-0.0928**	0.0000***	0.0000***	-0.152 (S)	[-0.1291, -0.0583]
	cloud	**-0.0667**	0.0042**	0.0461*	-0.100 (N)	[-0.1070, -0.0272]
	fiqa	-0.0390	0.0565	0.3957	-0.075 (N)	[-0.0804, 0.0013]
	govt	**-0.1071**	0.0000***	0.0000***	-0.165 (S)	[-0.1495, -0.0646]
BM25	clapnq	**-0.2743**	0.0000***	0.0000***	-0.437 (M)	[-0.3184, -0.2302]
	cloud	**-0.1379**	0.0000***	0.0000***	-0.231 (S)	[-0.1810, -0.0948]
	fiqa	**-0.1832**	0.0000***	0.0000***	-0.362 (M)	[-0.2307, -0.1355]
	govt	**-0.1390**	0.0000***	0.0000***	-0.215 (S)	[-0.1891, -0.0894]
Hybrid S+B	clapnq	+0.0303	0.0658	0.3957	+0.046 (N)	[0.0005, 0.0604]
	cloud	**+0.0831**	0.0000***	0.0005***	+0.139 (N)	[0.0401, 0.1247]
	fiqa	**+0.0950**	0.0000***	0.0001***	+0.174 (S)	[0.0575, 0.1330]
	govt	+0.0513	0.0098**	0.0984	+0.080 (N)	[0.0131, 0.0895]
Hybrid S+V	clapnq	**+0.0410**	0.0002***	0.0030**	+0.074 (N)	[0.0212, 0.0616]
	cloud	**+0.0960**	0.0000***	0.0000***	+0.146 (N)	[0.0636, 0.1277]
	fiqa	**+0.1306**	0.0000***	0.0000***	+0.241 (S)	[0.0979, 0.1627]
	govt	**+0.0888**	0.0000***	0.0000***	+0.133 (N)	[0.0619, 0.1165]
Hybrid S+V + BGE-rr	clapnq	+0.0322	0.0207*	0.1867	+0.059 (N)	[0.0004, 0.0637]
	cloud	**+0.0863**	0.0000***	0.0003***	+0.138 (N)	[0.0484, 0.1245]
	fiqa	**+0.0927**	0.0001***	0.0013**	+0.156 (S)	[0.0491, 0.1372]
	govt	**+0.0458**	0.0038**	0.0461*	+0.073 (N)	[0.0137, 0.0781]
Hybrid S+V + Cohere-rr	clapnq	**+0.0449**	0.0017**	0.0239*	+0.080 (N)	[0.0160, 0.0739]
	cloud	**+0.0705**	0.0000***	0.0009***	+0.127 (N)	[0.0367, 0.1048]
	fiqa	**+0.0899**	0.0000***	0.0005***	+0.151 (S)	[0.0517, 0.1299]
	govt	**+0.0535**	0.0030**	0.0385*	+0.082 (N)	[0.0209, 0.0878]
SPLADE	clapnq	+0.0022	0.7984	1.0000	+0.006 (N)	[-0.0298, 0.0349]
	cloud	**+0.0733**	0.0003***	0.0055**	+0.114 (N)	[0.0297, 0.1159]
	fiqa	**+0.0811**	0.0007***	0.0098**	+0.137 (N)	[0.0368, 0.1260]
	govt	+0.0378	0.1043	0.4170	+0.056 (N)	[0.0000, 0.0764]

Baseline: Voyage. $\alpha = 0.05$. Corrección Holm–Bonferroni aplicada a 32 comparaciones. $^{*}p < 0.05$, $^{**}p < 0.01$, $^{***}p < 0.001$. Magnitud de δ: N=negligible, S=small, M=medium, L=large.

Tabla D.2: Consistencia inter-dominio (τ de Kendall) — EA1_baselines

Dominio A	Dominio B	τ	p_{adj}	Concordante
clapnq	cloud	0.722	0.0177*	✓
clapnq	fiqa	0.722	0.0177*	✓
clapnq	govt	0.889	0.0015**	✓
cloud	fiqa	0.889	0.0015**	✓
cloud	govt	0.722	0.0177*	✓
fiqa	govt	0.833	0.0034**	✓
$\bar{\tau}$ medio		**0.796**		

EA2: Operadores de fusión

Tabla D.3: Pruebas pareadas para EA2_fusion

Sistema B	Dom.	Δ media	p Wilcoxon	p_{adj}	δ Cliff	IC 95 %
Linear α=0.3	clapnq	**-0.0388**	0.0007***	0.0044**	-0.072 (N)	[-0.0611, -0.0165]
	cloud	-0.0205	0.0370*	0.0684	-0.036 (N)	[-0.0508, 0.0100]
	fiqa	**-0.0496**	0.0005***	0.0043**	-0.097 (N)	[-0.0796, -0.0200]
	govt	**-0.0484**	0.0001***	0.0010**	-0.080 (N)	[-0.0737, -0.0236]
Linear α=0.5	clapnq	**-0.0388**	0.0007***	0.0044**	-0.072 (N)	[-0.0611, -0.0165]
	cloud	-0.0227	0.0228*	0.0684	-0.039 (N)	[-0.0529, 0.0081]
	fiqa	**-0.0496**	0.0005***	0.0043**	-0.097 (N)	[-0.0796, -0.0200]
	govt	**-0.0510**	0.0000***	0.0005***	-0.084 (N)	[-0.0762, -0.0260]
Linear α=0.7	clapnq	**-0.0388**	0.0007***	0.0044**	-0.072 (N)	[-0.0611, -0.0165]
	cloud	-0.0227	0.0228*	0.0684	-0.039 (N)	[-0.0529, 0.0081]
	fiqa	**-0.0496**	0.0005***	0.0043**	-0.097 (N)	[-0.0796, -0.0200]
	govt	**-0.0510**	0.0000***	0.0005***	-0.084 (N)	[-0.0762, -0.0260]

Baseline: RRF (k=60). $\alpha = 0.05$. Corrección Holm–Bonferroni aplicada a 12 comparaciones. $^{*}p < 0.05$, $^{**}p < 0.01$, $^{***}p < 0.001$. Magnitud de δ: N=negligible, S=small, M=medium, L=large.

EA3: Modos de consulta

Tabla D.4: Pruebas pareadas para EA3_query_mode

Sistema B	Dom.	Δ media	p Wilcoxon	p_{adj}	δ Cliff	IC 95 %
Full context	clapnq	**-0.1976**	0.0000***	0.0000***	-0.292 (S)	[-0.2527, -0.1425]
	cloud	**-0.2014**	0.0000***	0.0000***	-0.320 (S)	[-0.2565, -0.1484]
	fiqa	**-0.1800**	0.0000***	0.0000***	-0.330 (S)	[-0.2293, -0.1311]
	govt	**-0.1539**	0.0000***	0.0000***	-0.221 (S)	[-0.2169, -0.0908]
Full history	clapnq	**-0.1976**	0.0000***	0.0000***	-0.292 (S)	[-0.2527, -0.1425]
	cloud	**-0.2014**	0.0000***	0.0000***	-0.320 (S)	[-0.2565, -0.1484]
	fiqa	**-0.1800**	0.0000***	0.0000***	-0.330 (S)	[-0.2293, -0.1311]
	govt	**-0.1539**	0.0000***	0.0000***	-0.221 (S)	[-0.2169, -0.0908]
Rewrite (GT)	clapnq	+0.0309	0.1380	0.2759	+0.038 (N)	[-0.0023, 0.0636]
	cloud	+0.0164	0.2211	0.2759	+0.022 (N)	[-0.0114, 0.0452]
	fiqa	**+0.0677**	0.0009***	0.0034**	+0.128 (N)	[0.0286, 0.1074]
	govt	**+0.0598**	0.0044**	0.0133*	+0.085 (N)	[0.0225, 0.0985]

Baseline: Last turn. $\alpha = 0.05$. Corrección Holm–Bonferroni aplicada a 12 comparaciones. $^{*}p < 0.05$, $^{**}p < 0.01$, $^{***}p < 0.001$. Magnitud de δ: N=negligible, S=small, M=medium, L=large.

EA4: Variantes de reescritura

Tabla D.5: Pruebas pareadas para EA4_rewrite

Sistema B	Dom.	Δ media	p Wilcoxon	p_{adj}	δ Cliff	IC 95 %
Command-R replica	clapnq	**+0.0760**	0.0015**	0.0123*	+0.118 (N)	[0.0358, 0.1178]
	cloud	+0.0195	0.4715	1.0000	+0.028 (N)	[-0.0253, 0.0655]
	fiqa	-0.0200	0.2126	1.0000	-0.049 (N)	[-0.0641, 0.0248]
	govt	+0.0095	0.7124	1.0000	+0.018 (N)	[-0.0335, 0.0516]
Few-shot improved	clapnq	+0.0585	0.0206*	0.1443	+0.082 (N)	[0.0222, 0.0965]
	cloud	+0.0020	0.8940	1.0000	+0.002 (N)	[-0.0436, 0.0472]
	fiqa	-0.0243	0.2650	1.0000	-0.052 (N)	[-0.0679, 0.0198]
	govt	+0.0145	0.4918	1.0000	+0.026 (N)	[-0.0280, 0.0570]
Flan-T5 (local)	clapnq	**-0.0870**	0.0003***	0.0023**	-0.126 (N)	[-0.1315, -0.0440]
	cloud	**-0.0981**	0.0001***	0.0008***	-0.151 (S)	[-0.1436, -0.0540]
	fiqa	**-0.1263**	0.0000***	0.0000***	-0.238 (S)	[-0.1690, -0.0832]
	govt	**-0.1041**	0.0000***	0.0002***	-0.148 (S)	[-0.1501, -0.0591]

Baseline: GT rewrite. $\alpha = 0.05$. Corrección Holm–Bonferroni aplicada a 12 comparaciones. $^{*}p < 0.05$, $^{**}p < 0.01$, $^{***}p < 0.001$. Magnitud de δ: N=negligible, S=small, M=medium, L=large.

Frontera de Pareto

Tabla D.6: Frontera de Pareto calidad–latencia–costo (tabla completa)

Configuración	nDCG@10	Lat. (s) /query	Costo USD/1K	P_{QL}	P_{QC}	P_{3D}	Score
top-500	0.500	0.11	0.12	✓		✓	0.940
top-200	0.500	0.11	0.12				0.939
k=20	0.502	0.57	0.12	✓	✓	✓	0.850
k=40	0.500	0.57	0.12				0.845
k=100	0.501	0.58	0.12				0.845
Hybrid S+V	0.500	0.58	0.12				0.844
top-100	0.500	0.58	0.12				0.844
SPLADE	0.460	0.47	0.00			✓	0.818
BGE-rr depth=50	0.476	0.61	0.00			✓	0.817
BGE-rr depth=200	0.476	0.61	0.00				0.817
BGE-1.5	0.417	0.14	0.00			✓	0.814
k=1	0.480	0.56	0.12				0.813
BGE-rr depth=100	0.476	0.64	0.00				0.812
Hybrid S+B	0.476	0.65	0.00		✓	✓	0.811
Hybrid S+V + BGE-rr	0.476	0.63	0.12				0.793
Voyage	0.413	0.10	0.12	✓		✓	0.792
Linear α=0.3	0.461	0.57	0.12				0.779
Linear α=0.7	0.460	0.57	0.12				0.777
Linear α=0.5	0.460	0.57	0.12				0.777
Last turn	0.457	0.59	0.12				0.768
Command-R replica	0.523	0.77	0.62	✓	✓	✓	0.756
Few-shot improved	0.515	0.76	0.62	✓		✓	0.743
BGE-M3	0.335	0.21	0.00				0.660
Flan-T5 (local)	0.397	0.67	0.12				0.650
Cohere depth=200	0.476	0.60	1.00				0.642
Cohere depth=100	0.476	0.60	1.00				0.642
Cohere depth=50	0.476	0.60	1.00				0.642
Hybrid S+V + Cohere-rr	0.477	0.58	1.12				0.626
Full history	0.274	0.62	0.12				0.452
Full context	0.274	0.63	0.12				0.450
BM25	0.228	1.59	0.00				0.200

P_{QL}: Pareto calidad–latencia. P_{QC}: Pareto calidad–costo. P_{3D}: Pareto 3D. Score: compuesto ponderado (calidad 50 %, latencia 30 %, costo 20 %). Configuración recomendada en **negritas**.

Bibliografía

Vaibhav Adlakha, Shehzaad Dhuliawala, Kaheer Suleman, Harm de Vries, and Siva Reddy. TopiOCQA: Open-domain Conversational Question Answering with Topic Switching. *Transactions of the Association for Computational Linguistics*, 10:468–483, 2022. doi: 10.1162/tacl_a_00471. URL https://aclanthology.org/2022.tacl-1.27/.

Klejda Alushi, Jan Strich, Chris Biemann, and Martin Semmann. Comprehensive comparison of RAG methods across multi-domain conversational QA. In Selene Baez Santamaria, Sai Ashish Somayajula, and Atsuki Yamaguchi, editors, *Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (Volume 4: Student Research Workshop)*, pages 233–247, Rabat, Morocco, March 2026. Association for Computational Linguistics. ISBN 979-8-89176-383-8. doi: 10.18653/v1/2026.eacl-srw.17. URL https://aclanthology.org/2026.eacl-srw.17/.

Raviteja Anantha, Svitlana Vakulenko, Zhucheng Tu, Shayne Longpre, Stephen Pulman, and Srinivas Chappidi. Open-Domain Question Answering Goes Conversational via Question Rewriting. In Kristina Toutanova, Anna Rumshisky, Luke Zettlemoyer, Dilek Hakkani-Tur, Iz Beltagy, Steven Bethard, Ryan Cotterell, Tanmoy Chakraborty, and Yichao Zhou, editors, *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 520–534. Association for

Computational Linguistics, 2021. doi: 10.18653/v1/2021.naacl-main.44. URL https://aclanthology.org/2021.naacl-main.44/.

BAAI. BGE-base-en-v1.5: General embedding model, 2024. URL https://huggingface.co/BAAI/bge-base-en-v1.5. Hugging Face model card. Accessed: April 10, 2026.

Beijing Academy of Artificial Intelligence. BGE-Reranker-v2-m3: Multilingual reranking model. Hugging Face Model Repository, 2024. URL https://huggingface.co/BAAI/bge-reranker-v2-m3. Part of FlagEmbedding project. Accessed: April 10, 2026.

Alessio Benavoli, Giorgio Corani, and Francesca Mangili. Should we really use post-hoc tests based on mean-ranks? *Journal of Machine Learning Research*, 17(5):1–10, 2016. URL https://www.jmlr.org/papers/volume17/benavoli16a/benavoli16a.pdf.

Bosch. Booklet No. 11 – Design of Experiments (DOE). Technical report, Robert Bosch GmbH, 2010. URL https://assets.bosch.com/media/global/bosch_group/purchasing_and_logistics/information_for_business_partners/downloads/quality_docs/general_regulations/bosch_publications/booklet-no11-design-of-experiments-doe_en.pdf.

Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. In Lun-Wei Ku, Andre Martins, and Vivek Srikumar, editors, *Findings of the Association for Computational Linguistics: ACL 2024*, pages 2318–2335. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.findings-acl.137. URL https://aclanthology.org/2024.findings-acl.137/.

Yiruo Cheng, Kelong Mao, Ziliang Zhao, Guanting Dong, Hongjin Qian, Yongkang Wu, Tetsuya Sakai, Ji-Rong Wen, and Zhicheng Dou. CORAL: Benchmarking

multi-turn conversational retrieval-augmented generation. In *Findings of the Association for Computational Linguistics: NAACL 2025*, pages 1308–1330, Albuquerque, New Mexico, 2025. Association for Computational Linguistics. doi: 10.18653/v1/2025.findings-naacl.72.

Norman Cliff. Dominance statistics: Ordinal analyses to answer ordinal questions. *Psychological Bulletin*, 114(3):494–509, 1993. ISSN 1939-1455. doi: 10.1037/0033-2909.114.3.494.

Cohere. Rerank API — Cohere documentation. Cohere Documentation, 2025. URL `https://docs.cohere.com/reference/rerank`. Endpoint used: `rerank-v3.5`. Accessed: April 10, 2026.

Gordon V. Cormack, Charles L A Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '09, pages 758–759. Association for Computing Machinery, 2009. ISBN 978-1-60558-483-6. doi: 10.1145/1571941.1572114. URL `https://dl.acm.org/doi/10.1145/1571941.1572114`.

Jeffrey Dalton, Chenyan Xiong, and Jamie Callan. CAsT 2019: The Conversational Assistance Track Overview. In *TREC*, 2019. URL `https://trec.nist.gov/pubs/trec28/papers/OVERVIEW.CAsT.pdf`.

Jeffrey Dalton, Chenyan Xiong, and Jamie Callan. TREC CAsT 2020: The conversational assistance track overview. In *Proceedings of the Twenty-Ninth Text REtrieval Conference (TREC 2020)*. NIST, 2021.

Gabriel de Souza P. Moreira, Ronay Ak, Benedikt Schifferer, Mengyao Xu, Radek Osmulski, and Even Oldridge. Enhancing Q&A text retrieval with ranking models: Benchmarking, fine-tuning and deploying rerankers for RAG. In *Proceedings of the 1st Workshop on GenAI and RAG Systems for Enterprise at CIKM 2024*, 2024.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 4171–4186, 2019. doi: 10.18653/v1/N19-1423.

Matouš Eibich, Shivay Nagpal, and Alexander Fred-Ojala. ARAGOG: Advanced RAG output grading. *arXiv preprint arXiv:2404.01037*, 2024.

Elastic NV. *Superior relevance with Elastic Learned Sparse EncodeR and hybrid scoring*, May 2023. URL `https://www.elastic.co/blog/whats-new-elasticsearch-8-8-0`. General Availability: May 23, 2023.

Ahmed Elgohary, Denis Peskov, and Jordan Boyd-Graber. Can You Unpack That? Learning to Rewrite Questions-in-Context. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 5918–5924. Association for Computational Linguistics, 2019. doi: 10.18653/v1/D19-1605. URL `https://aclanthology.org/D19-1605/`.

Hakan Emekci and Daniel Quillan Roxas. Dissecting medical RAG: Why reranking matters more than complexity in question answering. *Black Sea Journal of Engineering and Science*, 9(2):549–561, 2026. doi: 10.34248/bsengineering.1849342.

Thibault Formal, Benjamin Piwowarski, and Stéphane Clinchant. SPLADE: Sparse Lexical and Expansion Model for First Stage Ranking. In *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 2288–2292. Association for Computing Machinery, 2021. doi: 10.1145/3404835.3463098.

Thibault Formal, Carlos Lassance, Benjamin Piwowarski, and Stéphane Clinchant. From distillation to hard negative sampling: Making sparse neural IR models

more effective. In *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 2353–2359. ACM, 2022.

Luyu Gao, Xueguang Ma, Jimmy Lin, and Jamie Callan. Precise Zero-Shot Dense Retrieval without Relevance Labels. In Anna Rogers, Jordan Boyd-Graber, and Naoaki Okazaki, editors, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1762–1777. Association for Computational Linguistics, 2023. doi: 10.18653/v1/2023.acl-long.99. URL https://aclanthology.org/2023.acl-long.99/.

Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2024. Comprehensive survey with over 1 000 citations; no formal conference publication at time of writing.

Michael Glass, Gaetano Rossiello, Md Faisal Mahbub Chowdhury, Ankita Naik, Pengshan Cai, and Alfio Gliozzo. Re2G: Retrieve, rerank, generate. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 2701–2715. Association for Computational Linguistics, 2022.

Sture Holm. A Simple Sequentially Rejective Multiple Test Procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979. ISSN 0303-6898. URL https://www.jstor.org/stable/4615733.

Gautier Izacard, Mathilde Caron, Lucas Hosseini, Sebastian Riedel, Piotr Bojanowski, Armand Joulin, and Edouard Grave. Unsupervised dense information retrieval with contrastive learning. *Transactions on Machine Learning Research*, 2022. doi: 10.48550/arXiv.2112.09118. URL https://openreview.net/forum?id=jKN1pXi7b0.

Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446, October 2002. ISSN 1046-8188. doi: 10.1145/582415.582418. Paper seminal que introduce las métricas DCG (Discounted Cumulative Gain) y NDCG (Normalized DCG) para evaluación de sistemas de recuperación de información con relevancia graduada.

Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547, 2021.

Mandar Joshi, Omer Levy, Luke Zettlemoyer, and Daniel Weld. BERT for coreference resolution: Baselines and analysis. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 5803–5808. ACL, 2019.

Ehsan Kamalloo, Nandan Thakur, Carlos Lassance, Xueguang Ma, Jheng-Hong Yang, and Jimmy Lin. Resources for brewing beir: Reproducible reference models and statistical analyses. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 1431–1440. ACM, 2024. doi: 10.1145/3626772.3657862.

Andrej Karpathy. Llm wiki, April 2026. URL `https://gist.github.com/karpathy/442a6bf555914893e9891c11519de94f`. GitHub Gist Idea File.

Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense Passage Retrieval for Open-Domain Question Answering. In Bonnie Webber, Trevor Cohn, Yulan He, and Yang Liu, editors, *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.emnlp-main.550. URL `https://aclanthology.org/2020.emnlp-main.550/`.

Yannis Katsis, Sara Rosenthal, Kshitij Fadnis, Chulaka Gunasekara, Young-Suk Lee, Lucian Popa, Vraj Shah, Huaiyu Zhu, Danish Contractor, and Marina

Danilevsky. MTRAG: A Multi-Turn Conversational Benchmark for Evaluating Retrieval-Augmented Generation Systems, 2025. URL https://www.qeios.com/read/PHS6YN.

M. G. Kendall. A New Measure of Rank Correlation. *Biometrika*, 30(1/2):81–93, 1938. ISSN 0006-3444. doi: 10.2307/2332226. URL https://www.jstor.org/stable/2332226.

William Lammers and Pietro Badia. *Fundamentals of Behavioral Research Textbook*. University of Central Arkansas, 2004. URL https://uca.edu/psychology/files/2013/08/Ch13-Experimental-Design_Multiple-Independent-Variables.pdf.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474. Curran Associates, Inc., 2020.

Jiangyi Lin, Yaxin Fan, Xiaomin Chu, Peifeng Li, and Qiaoming Zhu. Multi-granularity prompts for topic shift detection in dialogue. In *Advanced Intelligent Computing Technology and Applications. ICIC 2023*, volume 14092 of *Lecture Notes in Computer Science*, pages 511–522. Springer, 2023. doi: 10.1007/978-981-99-4752-2_42. URL https://dl.acm.org/doi/10.1007/978-981-99-4752-2_42.

Sheng-Chieh Lin, Jheng-Hong Yang, Rodrigo Nogueira, Ming-Feng Tsai, Chuan-Ju Wang, and Jimmy Lin. Multi-Stage Conversational Passage Retrieval: An Approach to Fusing Term Importance Estimation and Neural Query Rewriting. *ACM Trans. Inf. Syst.*, 39(4):48:1–48:29, 2021. ISSN 1046-8188. doi: 10.1145/3446426. URL https://dl.acm.org/doi/10.1145/3446426.

Charles X. Ling, Jianfeng Gao, Huajie Zhang, Weining Qian, and HongJiang Zhang. Improving Encarta search engine performance by mining user logs. *International*

Journal of Pattern Recognition and Artificial Intelligence, 16(8):1101–1116, 2002. doi: 10.1142/S0218001402002179. Describe el motor de búsqueda léxico basado en coincidencias exactas de keywords de Microsoft Encarta.

Xueguang Ma, Liang Wang, Nan Yang, Furu Wei, and Jimmy Lin. Fine-tuning LLaMA for multi-stage text retrieval. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2024.

Christopher Manning, Prabhakar Raghavan, and Hinrich Schuetze. *Introduction to Information Retrieval*. Cambridge University Press, 2009. URL `https://nlp.stanford.edu/IR-book/pdf/irbookonlinereading.pdf`.

Kelong Mao, Zhicheng Dou, Fengran Mo, Jiewen Hou, Haonan Chen, and Hongjin Qian. Large language models know your contextual search intent: A prompting framework for conversational search. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 1211–1225, 01 2023. doi: 10.18653/v1/2023.findings-emnlp.86.

Fengran Mo, Kelong Mao, Yutao Zhu, Yihong Wu, Kaiyu Huang, and Jian-Yun Nie. ConvGQR: Generative query reformulation for conversational search. In Anna Rogers, Jordan Boyd-Graber, and Naoaki Okazaki, editors, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 4998–5012, Toronto, Canada, July 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.acl-long.274. URL `https://aclanthology.org/2023.acl-long.274/`.

Niklas Muennighoff, Nouamane Tazi, Loic Magne, and Nils Reimers. MTEB: Massive text embedding benchmark. In Andreas Vlachos and Isabelle Augenstein, editors, *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2014–2037, Dubrovnik, Croatia, May 2023. Association for Computational Linguistics. doi:

10.18653/v1/2023.eacl-main.148. URL https://aclanthology.org/2023.eacl-main.148/.

Niklas Muennighoff, Hongjin Su, Liang Wang, Nan Yang, Furu Wei, Tao Yu, Amanpreet Singh, and Douwe Kiela. Generative representational instruction tuning. arXiv preprint arXiv:2402.09906, 2024. URL https://arxiv.org/abs/2402.09906.

Rodrigo Nogueira and Kyunghyun Cho. Passage re-ranking with BERT. In *arXiv preprint arXiv:1901.04085*, 2019. First publicly available BERT-based reranker; widely adopted as baseline in MS MARCO and TREC-CAR.

OpenAI. Does ChatGPT tell the truth?, 2024. URL https://help.openai.com/en/articles/8313428-does-chatgpt-tell-the-truth. Accessed: 2024-05-07.

OpenAI. Introducing GPT-OSS. OpenAI Blog, 2025. URL https://openai.com/index/introducing-gpt-oss/. Accessed: April 13, 2026.

Ronak Pradeep, Sahel Sharifymoghaddam, and Jimmy Lin. Rankzephyr: Effective and robust zero-shot listwise reranking is a breeze!, 2023. URL https://arxiv.org/abs/2312.02724.

Chen Qu, Liu Yang, Cen Chen, Minghui Qiu, W. Bruce Croft, and Mohit Iyyer. Open-retrieval conversational question answering. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '20, page 539–548, New York, NY, USA, 2020. Association for Computing Machinery. ISBN 9781450380164. doi: 10.1145/3397271.3401110. URL https://doi.org/10.1145/3397271.3401110.

Zackary Rackauckas. Rag-fusion: A new take on retrieval augmented generation. *International Journal on Natural Language Computing*, 13:37–47, 02 2024. doi: 10.5121/ijnlc.2024.13103.

Stephen Robertson and Hugo Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond. *Found. Trends Inf. Retr.*, 3(4):333–389, 2009. ISSN 1554-0669. doi: 10.1561/1500000019. URL https://doi.org/10.1561/1500000019.

Stephen E. Robertson, Steve Walker, Susan Jones, Micheline Hancock-Beaulieu, and Mike Gatford. Okapi at TREC-3. In *Overview of the Third Text REtrieval Conference (TREC-3)*, pages 109–126. NIST, 1995. URL https://www.microsoft.com/en-us/research/publication/okapi-at-trec-3/.

Jeanine Romano, Jeffrey D. Kromrey, Jesse Coraggio, and Jeff Skowronek. Appropriate statistics for ordinal level data: Should we really be using t-test and cohen's *d* for evaluating group differences on the NSSE and other surveys? In *Annual Meeting of the Florida Association of Institutional Research*, pages 1–33, Cocoa Beach, FL, February 2006. Paper presented February 1–3, 2006.

Tetsuya Sakai. Statistical reform in information retrieval? *ACM SIGIR Forum*, 48(1):3–12, 2014. ISSN 0163-5840. doi: 10.1145/2641383.2641385. URL https://dl.acm.org/doi/10.1145/2641383.2641385.

G. Salton, A. Wong, and C. S. Yang. A vector space model for automatic indexing. *Commun. ACM*, 18(11):613–620, 1975. ISSN 0001-0782. doi: 10.1145/361219.361220. URL https://dl.acm.org/doi/10.1145/361219.361220.

Michael Shen, Muhammad Umar, Kiwan Maeng, G. Edward Suh, and Udit Gupta. Towards understanding systems trade-offs in retrieval-augmented generation model inference. *arXiv preprint arXiv:2412.11854*, December 2024. Cornell University and NVIDIA. Presenta taxonomía detallada y caracterización de trade-offs entre latencia, throughput y memoria en RAG, revelando ineficiencias en deployment de sistemas RAG a escala.

Weiwei Sun, Lingyong Yan, Xinyu Ma, Shuaiqiang Wang, Pengjie Ren, Zhumin Chen, Dawei Yin, and Zhaochun Ren. Is ChatGPT good at search? investigating

large language models as re-ranking agents. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 14918–14937. Association for Computational Linguistics, 2023. URL https://aclanthology.org/2023.emnlp-main.923.pdf.

Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A heterogenous benchmark for zero-shot evaluation of information retrieval models. In *Advances in Neural Information Processing Systems*, volume 35. Curran Associates, Inc., 2021.

Christophe Van Gysel and Maarten de Rijke. Pytrec_eval: An extremely fast Python interface to trec_eval. In *Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '18, pages 873–876, New York, NY, USA, 2018. ACM. doi: 10.1145/3209978.3210065. URL https://doi.org/10.1145/3209978.3210065.

Christopher C. Vogt and Garrison W. Cottrell. Fusion via a linear combination of scores. *Information Retrieval*, 1(3):151–173, October 1999. doi: 10.1023/A:1009982513445. URL https://cseweb.ucsd.edu/~gary/pubs/info-retrieval-1999.pdf. University of California San Diego.

Voyage AI. Voyage-3-large: The new state-of-the-art general-purpose embedding model. Voyage AI Blog, January 2025. URL https://blog.voyageai.com/2025/01/07/voyage-3-large/. Accessed: April 10, 2026.

Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. Improving text embeddings with large language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2024a. URL https://aclanthology.org/2024.acl-long.642/.

Xiaohua Wang, Zhenghua Wang, Xuan Gao, Feiran Zhang, Yixin Wu, Zhibo Xu, Tianyuan Shi, Zhengyuan Wang, Shizheng Li, et al. Searching for best practices

in retrieval-augmented generation. *arXiv preprint arXiv:2407.01219*, 2024b. URL https://aclanthology.org/2024.emnlp-main.981/.

Frank Wilcoxon. Individual Comparisons by Ranking Methods. *Biometrics Bulletin*, 1(6):80–83, 1945. ISSN 0099-4987. doi: 10.2307/3001968. URL https://www.jstor.org/stable/3001968.

Shengyao Zhuang, Xueguang Ma, Bevan Koopman, Jimmy Lin, and Guido Zuccon. PromptReps: Prompting large language models to generate dense and sparse representations for zero-shot document retrieval. arXiv preprint arXiv:2404.18424, 2024. URL https://arxiv.org/abs/2404.18424.